

中图分类号：TP242

单位代码：11414
学 号：2017314006



中国石油大学
CHINA UNIVERSITY OF PETROLEUM

博士学位论文

题 目 行走过程中人体膝关节角度连续

预测与步态识别

学科专业 机械工程

研究方向 机器人技术

博 士 生 刘显文

指导教师 张仕民教授

二〇二三年六月

Continuous prediction of knee joint angle and gait recognition during human walking

**Dissertation submitted to
China University of Petroleum, Beijing
in partial fulfillment of the requirements
for the degree of
Doctor of Engineering**

**By
LIU XIANWEN
(Mechanical Engineering)**

**Dissertation Supervisor
Prof. Zhang Shimin**

June, 2023

摘 要

随着我国人口老龄化问题的日益严重,由心血管疾病引发的中风在老年群体中发病率较高。中风能让老年患者不同程度地丧失日常生活自理能力,如果不加以防治,可能导致肌肉萎缩,进而完全丧失活动能力,对患者生理和心理产生负面影响。近年来,机器人智能技术和运动功能康复技术相结合,产生了外骨骼机器人。外骨骼机器人能够为老年患者和运动功能障碍患者提供运动辅助和康复训练,从而提高患者的自理能力和生活质量。目前,下肢外骨骼机器人在人机交互方面取得了一定的研究成果,由被动接受人体意图逐渐演变为主动理解人体意图。然而,下肢外骨骼机器人在人体运动意图的实时、连续识别和步态识别等方面仍然存在问题,这些问题影响了人机协同运动的柔顺度。

本文以康复训练和助老助残等相关领域的下肢外骨骼机器人为研究背景,以解决人机协调运动控制技术中人体运动意图和步态识别等关键问题为研究目标,以行走运动中膝关节运动和步态为研究对象探索人体运动意图和步态识别新方法,具体研究内容包括以下几个方面:

(1) 针对人体运动意图识别问题,首次提出基于表面肌电(surface Electromyography, sEMG)信号和髋关节角度的多源信号融合方法并以膝关节运动为研究对象进行角度的连续预测。依据人体解剖学结构,选取大腿部位与膝关节运动相关的4块肌肉并进行sEMG信号采集;针对sEMG信号存在噪声和模糊性强等特点,依次使用滤波和归一化的预处理方法并进行特征提取。

(2) 本文以髋关节角度和4通道sEMG信号的肌电特征为实验数据,将其以时间序列信号形式分别输入到卷积神经网络(Convolutional Neural Network, CNN)、递归神经网络(Recurrent Neural Network, RNN)和长短期记忆(Long and Short Term Memory, LSTM)网络回归模型中对膝关节角度进行预测,采用平均绝对误差、均方根误差和 R^2 分数评估模型性能。同时,基于三种回归模型,本文还对仅采用肌电特征和仅采用髋关节角度进行膝关节角度预测的结果进行了对比。结果表明,基于多源信号融合方法的LSTM回归模型性能最好。

(3) 本文将基于足底压力信号的阈值法与基于加速度信号的连续小波变换相结合,提出了一种精度高、鲁棒性好的复合步态识别算法,通过实验验证了该复合步态识别算法具有高识别精度且能够实现对多个步态阶段和异常步态的识别。

(4) 本文将膝关节角度连续预测结果作为控制输入对 Indego 外骨骼机器人进行位置控制。通过对比和分析受试者不穿戴外骨骼地面行走和穿戴外骨骼以不同速度行走的步态、膝关节角度和肌电特征, 验证人体意图识别方法用于外骨骼机器人控制的可行性。

本文以解决人机协调运动控制技术中人体运动意图和步态识别等关键问题为研究目标, 以行走运动中膝关节运动和步态为研究对象提出了多源信号融合的膝关节角度连续预测和复合步态识别方法并通过实验验证本文所提方法的可行性。

关键词: 表面肌电信号; 特征提取; 多源信号融合; 膝关节角度预测; 步态识别

Continuous prediction of knee joint angle and gait recognition during human walking

ABSTRACT

With the increasingly serious aging problem of China's population, stroke caused by cardiovascular disease has a higher incidence rate in the elderly population. Stroke can cause varying degrees of loss of daily living ability in elderly patients. Without prevention and treatment, it may lead to muscle atrophy and ultimately complete loss of mobility, having negative impacts on the patient's physical and mental health. In recent years, the combination of robot artificial intelligence technology and motion functional rehabilitation technology has led to the development of exoskeleton robots. Exoskeleton robots can provide movement assistance and rehabilitation training for elderly and patients with movement disorders, thereby improving their ability to perform daily activities and quality of life. Currently, lower limb exoskeleton robot has made some achievements in human-robot interaction, gradually evolving from passively receiving human intention to actively understanding it. However, there are still problems with real-time and continuous human intention recognition and gait recognition in lower limb exoskeleton robot, which affect the compliance of human-robot cooperative movement.

This article takes lower limb exoskeleton robots used in fields such as rehabilitation training and assisting the elderly and disabled as the research background. The research goal is to solve key issues in human-robot coordinated motion control technology, such as human movement intention and gait recognition, and explore new methods for recognizing human movement intention and gait through the study of knee joint motion and gait during walking. The specific research content includes the following aspects:

(1) To address the problem of human movement intent recognition, a novel multi-source signal fusion method based on surface electromyography signals and hip joint angles is proposed for the first time. The study focuses on continuous prediction of knee joint angles, using them as the research object. Four muscles in the thigh related to knee

joint movement are selected based on human anatomical structure, and surface Electromyography (sEMG) signals are collected. To address the characteristics of sEMG signals, such as noise and fuzziness, preprocessing methods such as filtering and normalization are applied in sequence, followed by feature extraction.

(2) In this study, hip joint angle and features of 4-channel sEMG signals are used as experimental data. They are input into convolutional neural network (CNN), recurrent neural network (RNN) and long short-term memory (LSTM) regression models as time series signals for knee joint angle prediction. Model performance is evaluated by using mean absolute error, root mean square error, and R^2 score. In addition, based on three regression models, this study compares the results of using only sEMG features and only hip joint angles for knee joint angle prediction. The results show that the LSTM regression model based on the multisource signal fusion method has the best performance.

(3) In this study, a high-precision and robust composite gait recognition algorithm is proposed by combining the threshold method based on plantar pressure signals and continuous wavelet transform based on acceleration signals. Experimental results demonstrate that this composite gait recognition algorithm has high recognition accuracy and can identify multiple gait phases and abnormal gaits.

(4) Knee joint prediction result is used as control input for position control of the Indego exoskeleton robot. By comparing and analyzing the gait, knee joint angles, and EMG features of participant walking on the ground without wearing the exoskeleton and walking at different speeds while wearing the exoskeleton, the feasibility of using human intention recognition method for exoskeleton robot control is demonstrated.

The research goal is to solve key issues in human-robot coordinated motion control technology, and proposes a multi-source signal fusion method for continuous prediction of knee joint angle and composite gait recognition, with walking motion and knee joint movement as the research objects. The feasibility of the proposed method is verified through experiments.

Key Words: sEMG signal; Feature extraction; Multi-source signal fusion; Knee joint angle prediction; Gait recognition

创 新 点

1. 考虑 sEMG 信号在人体意图识别中的不足和人体下肢关节角度的耦合性,首次提出将基于 sEMG 信号和髋关节角度的多源信号融合方法用于膝关节角度连续预测。该方法不仅提高了膝关节角度连续预测精度还减少了传感器数量,增加人体舒适度的同时更利于人机协同。(见第 4 章 4.3.1)

2. 提出了一种基于阈值法和连续小波变换的复合步态识别方法,该方法在具有高识别精度和鲁棒性的同时还免去了关键参数计算所需的大量、重复性实验验证,具有实际应用价值。(见第 5 章 5.2.3)

3. 为客观评估不同速度下外骨骼机器人的位置跟踪结果和助力效果,提出了在相同步态相内分别对膝关节角度、肌肉的肌电特征进行对比分析,进而验证本文提出的人体意图识别方法的可行性和外骨骼的辅助效果。(见第 6 章 6.4)

目 录

第 1 章 绪论.....	1
1.1 研究背景和研究意义.....	1
1.2 人体运动意图和步态识别研究现状	3
1.2.1 基于生物力信号的意图识别研究现状	3
1.2.2 基于 EEG 信号的意图识别研究现状.....	5
1.2.3 基于 sEMG 信号的意图识别研究现状	7
1.2.4 步态识别研究现状.....	10
1.3 论文的主要研究内容与结构安排	11
第 2 章 行走的下肢运动分析	14
2.1 人体解剖学结构.....	14
2.2 人体行走的步态特征.....	18
2.3 行走的下肢运动模型.....	21
2.3.1 人体行走下肢运动学和动力学数据.....	21
2.3.2 下肢外骨骼系统运动学模型.....	23
2.3.3 下肢外骨骼系统动力学模型.....	28
2.4 本章小结.....	30
第 3 章 基于人体行走的信号获取和处理	31
3.1 sEMG 信号的产生机理和特点	32
3.2 人体行走运动信号获取.....	33
3.2.1 肌肉选取.....	33
3.2.2 运动信号采集.....	34
3.3 sEMG 信号预处理	36
3.3.1 滤波.....	37
3.3.2 信号归一化.....	37
3.4 sEMG 信号特征提取	39
3.4.1 滑动窗口	39
3.4.2 特征提取.....	40
3.5 信号处理结果.....	42
3.6 本章小结.....	44
第 4 章 多源信号融合的膝关节角度预测	45
4.1 卷积神经网络.....	46
4.2 递归神经网络和长短期记忆网络	52
4.2.1 RNN 模型	52
4.2.2 LSTM 网络模型	54

4.3 膝关节预测算法模型.....	56
4.3.1 模型输入预处理.....	56
4.3.2 膝关节预测回归模型.....	58
4.4 膝关节预测结果与分析.....	60
4.4.1 评估标准.....	60
4.4.2 结果与分析.....	61
4.5 本章小结.....	69
第 5 章 人体行走的步态识别	70
5.1 步态识别算法.....	70
5.1.1 阈值法.....	70
5.1.2 连续小波变换法.....	71
5.1.3 复合步态识别算法.....	74
5.2 步态识别实验.....	76
5.3 基于复合步态识别算法的步态识别结果与分析	77
5.3.1 步态识别结果.....	77
5.3.2 步态识别结果分析.....	83
5.4 本章小结.....	84
第 6 章 下肢外骨骼实验	85
6.1 PD 控制理论和建模	86
6.2 下肢外骨骼实验.....	87
6.3 下肢外骨骼实验结果分析	91
6.4 本章小结.....	101
第 7 章 总结与展望	102
7.1 总结.....	102
7.2 展望.....	103
参考文献.....	105

第 1 章 绪 论

1.1 研究背景和研究意义

由于人均寿命增加和生育率下降,全球人口老龄化问题愈加严重。据统计,全世界 60 岁以上老人将由 2017 年的 9.62 亿增长到 2050 年的 21 亿^[1]。国家统计局第七次全国人口普查结果表明,总人口数较 2010 年第六次全国人口普查增长 4.63%,其中 0~14 岁人口占比增长 1.35%,15~59 岁人口占比减少 6.79%,60 岁及以上人口占比增长 5.44%,65 岁及以上人口占比增长 4.63%^[2];这表明目前我国人口老龄化问题较为严重且逐步加剧。特别是老年人口中常伴随的多种脑血管疾病会使患者不同程度地丧失日常生活自理能力甚至简单的运动能力,如果不加以防治,可能导致患者肌肉萎缩并最终完全丧失活动能力,给家庭和社会造成严重的负担。而且,老年患者的下肢功能障碍会对其日常生活和心理健康产生严重影响^[3-5]。下肢功能障碍造成的影响主要体现在:(1)生理上,患者长期卧床无法运动会造成肌肉萎缩、关节畸形、下肢痉挛、压疮等并发症,影响了生活质量、生理机能和生理职能。(2)心理上,患者容易出现抑郁、焦虑等不良情绪,对康复治疗丧失信心;此现象在语言功能障碍患者身上表现尤为明显,严重影响了患者的社会功能、情感智能及精神健康。(3)经济上,由卧病在床造成的经济负担以及运动丧失造成经济来源损失是因病返贫的重要因素之一。

研究表明,对下肢功能障碍患者进行重复性运动训练有助于刺激大脑皮层运动功能的重组和重建,诱导脑神经可塑性进而促进康复^[6]。将机器人智能技术引入到运动功能康复训练领域,以康复医学理论为指导,产生了外骨骼机器人。外骨骼不同于传统的工业机器人,其设计和控制充分考虑了意图的预测性、系统的功效性、操作的自然性、操作者的可接受性、人体安全性和主动参与等因素。与传统的理疗师相比,机器人训练具有高密度和重复训练时的高精度等特点^[7]。多年来的研究证明,下肢功能障碍患者辅以适当的康复器械和开展适当的康复训练,是患者肢体功能的恢复最有效的手段之一。

下肢外骨骼机器人是一种人机一体化康复和助力装备,它综合了模式识别、信息感知和智能控制等先进技术。基于人体运动意图和步态等信息,下肢外骨骼机器人通过控制各关节处的驱动器和执行器来完成关节角度、角速度甚至力、力矩等参数的调整,进而实现对人体助力。由此可见,在下肢外骨骼机器人技术研究中,如

何准确获取人体运动信息并进一步分析识别出人体运动意图和步态等信息尤为重要；它能帮助外骨骼实时跟踪人体运动并适时提供辅助，最终实现外骨骼和人体的协调运动。如图 1.1 所示，人体运动意图识别和步态识别在人机协同控制中至关重要，是实现高效人机共融的基础，是提升人体舒适性和安全性的关键。目前，下肢外骨骼机器人在人机交互方面取得了一定的研究成果，外骨骼由被动接受人体意图逐渐演变为主动理解人体意图。然而，在人体运动意图的实时、连续识别和步态识别等方面仍然存在问题，这些问题影响了人机协同运动的柔顺度和外骨骼的辅助效果。




图 1.1 人机协同控制原理

Fig. 1.1 Human-robot cooperative control method

本文以康复训练和助老助残等相关领域的下肢外骨骼机器人为研究背景，以解决人机协调运动控制技术中人体运动意图识别和步态识别等关键问题为研究目

标，基于对该领域研究现状的具体分析给出了本文的研究内容和所用的具体方法，从而为基于人体意图识别的外骨骼机器人控制提出新的研究方法和思路。

1.2 人体运动意图和步态识别研究现状

人体运动是一种复杂的运动，但是也具有一定的规律性和周期性。包括肌肉力和关节力矩在内的广义力是人体运动的来源，它直接反映了人体的运动意图。但是目前与肌肉相关的参数很难从人体进行测量，肌肉力及其对应关节力矩的机理分析仍是该领域研究的重点和热点。此外，中枢神经系统、肌肉-骨骼系统和周围神经系统中的可测量物理量（或状态变量）都可以用来表示人体运动意图。该状态变量包括人体的离散状态，如站立、坐下等日常动作；还包括连续的运动量，如力、运动速度或者加速度等。目前，常见的人体运动意图识别指的是对人体动作模式的识别，动作模式包括人体行走、跑步、跳跃、上下楼梯和越障等动作。传统的机器学习算法，如支持向量机、决策树和随机森林等，在这类离散问题上取得了较好的分类效果；且基于识别得到的下肢动作模式，外骨骼能够执行预定的完整动作。但是，这种宏观运动的识别方法不能满足外骨骼机器人的实际应用；在人机交互中，重要的是对肢体或者关节连续提取特定的信息。本文所述的人体运动意图识别是通过测量和分析人体生物力或者电信号，对行走过程中的运动量如关节角度/角速度、关节力/力矩等进行连续识别；此过程中，采用合适的传感器获取人体运动意图对外骨骼机器人的控制效果影响巨大。目前，根据信号类型差异，人体运动意图连续识别方法包括：基于生物力学信号识别方法和基于生物电信号识别方法^[8]。生物电信号包括大脑皮层或者头皮表面记录的脑电（Electroencephalogram, EEG）信号和骨骼肌收缩产生的 sEMG 信号，其它生物电信号的采集和解码技术仍不够成熟且研究较少。

1.2.1 基于生物力信号的意图识别研究现状

人体穿戴外骨骼运动时，人体和外骨骼或者外界环境之间会产生相对运动和相互作用力，这类物理交互层面的信号源被称为生物力信号。生物力信号可以通过集成了陀螺仪、倾角传感器和加速度计为一体的惯性传感器（Inertial Measurement Unit, IMU）、编码器和拉/压力传感器等测量^[9]；此类传感器获取人体运动时的关节角度/角速度、接触力/力矩和足底压力等信号，本文将此类信号统称为生物力信号。相比于 sEMG 信号和 EEG 信号等生物电信号，生物力信号实际应用成本低，传感器安装方便、鲁棒性和稳定性更好。而且，由于生物力信号反映人体实时运动

状态,能为外骨骼机器人提供人体动作幅度和动作变化程度等信息,受到了国内外学者和机构的广泛研究。例如,在外骨骼机器人辅助人体行走研究中,通过 IMU 采集和分析肢体摆动中的角度、角速度和角加速度信号能够判断肢体运动状态^[10];而且,基于交互力信息和步态信息能够实现以人体为主导的外骨骼机器人控制。

在人体运动意图识别方面,人机交互过程中的交互力信号是最常用的特征之一。如图 1.2 (a) 所示, Hocoma 公司研制的 Lokomat 下肢康复外骨骼机器人系统通过安装在膝关节和髋关节处的扭矩传感器对人机交互力进行实时测量;基于该交互力信息可以实现关节轨迹、外骨骼驱动力矩或者阻抗控制中的阻抗参数的自动调节,提高了康复过程中受试者的参与度^[11,12]。如图 1.2 (b) 所示,美国特拉华大学的 Banala^[13,14]等研发了用于运动障碍患者康复训练的下肢动力外骨骼(ALEX);ALEX 集成的力和力矩传感器能测量患者和外骨骼之间的人机交互力,基于交互力信号的力场控制器能够实现患者主动控制^[15]。如图 1.2 (c) 所示,eLEGS 是美国 Berkeley Bionics 公司于 2010 年推出的一款平地行走下肢康复外骨骼,作用是辅助偏瘫患者或者运动能力障碍患者直立行走;该外骨骼系统使用多种传感器检测人体运动,如脚底压力传感器和电位计用来检测步态相位,躯干的加速度计和陀螺仪用来测量躯干在矢状面内的角度^[16,17]。如图 1.2 (d) 所示,中国科学技术大学余永课题组研制了一种下肢助力外骨骼,该外骨骼通过人机接触部位的二维力传感器和足底压力传感器检测人体运动,最终完成外骨骼的控制^[18];2010 年课题组研制的单腿七自由度二代样机设计了特殊的柔性双足感知系统,该系统依靠足底压力传感器对人体运动意图进行识别^[19]。如图 1.2 (e) 所示,浙江大学的靳新兴进行了液压助力外骨骼机器人方面的研究,该外骨骼系统通过足底压力传感器和力传感器实现了对步态特征和人机交互力矩的获取并最终识别人体运动意图^[20]。如图 1.2 (f) 所示,哈尔滨工业大学的陈朝峰研发了基于多源传感系统的可穿戴外骨骼机器人 HEXO (HIT EXOskeleton);多源传感系统中的增量式编码器用来检测外骨骼机器人髋关节和膝关节屈伸运动转角;关节力矩传感器用来检测外骨骼机器人髋关节和膝关节关节力矩;IMU 传感器用来检测外骨骼机器人下肢关节角加速度,以此解决基于关节编码器得到的角加速度精度不足问题;单维力传感器用来检测人体的足底压力信息,进而确定当前步态相位;六维力传感器用来检测外骨骼机器人运动时的人机交互力,进而识别人体运动意图并保证人机交互的舒适性^[21]。



图 1.2 基于生物力信号的外骨骼机器人研究^[11-21]

Fig. 1.2 Exoskeleton robot research based on biological-force signals

虽然基于生物力信号的人体运动意图识别技术较为成熟且得到了广泛应用，但是力信号只有当人体有了动作或者改变动作后才能反映出来，即存在滞后性强的固有缺陷。而且，下肢外骨骼机器人系统本身存在机电延迟，基于生物力信号的意图识别方法会影响人机协调运动的灵活性。通过建立人体的运动轨迹和动力学模型，采用预测算法可以补偿这种缺陷。但是，由于人体运动和所处环境的不确定性，仅靠力信号仍难以实现高效、自然的人机协同。生物电信号是随时间变化的物理量，是载有行为信息的神经元传输到相关组织或者器官时所激发的电位和，并不依赖于肢体的物理运动。而且，生物电信号在人体运动前产生，能够较好的解读出人体意图和平衡初始运动意图与信号可解释性之间的关系。相对于生物力信号，生物电信号具有时效性强和保真度高等特点，能映射人体的日常活动并完成所希望的控制方式，甚至提供人体运动的预判。

1.2.2 基于 EEG 信号的意图识别研究现状

EEG 信号是大脑活动产生的生物电信号之一，可以通过头皮表面放置的电压敏感电极来记录。人脑是一个极其复杂的动力系统，EEG 信号既可以反映大脑在

没有分配特定任务情况下的自发活动,也可以反映诱发电位,即由大脑感觉刺激而诱发的电位。如图 1.3 所示,基于 EEG 信号的脑机接口 (Brain-Machine Interface, BMI) 是人脑与外部设备之间的通信接口^[22,23],是一种不需要任何外围肌肉活动的通信和控制系统。大脑活动在 BMI 系统中被转化为控制信号,从而使患者能够与周围环境互动。目前, BMI 主要用于机器人控制、游戏交互设计、情感评估、疲劳评估和医疗系统等领域。在外骨骼机器人领域,美国匹兹堡大学的 Flesher^[24]等研发了一种双向 BMI 来记录运动皮层的神经活动,通过体感皮层内的微弱刺激产生触觉并进行反馈进而改善机器人手臂的控制性能。意大利那不勒斯费德里科二世大学的 Arpaia^[25]等提出了一种可穿戴的机器人远程控制仪器,基于仪器中的 BMI 系统,患者可控制真人大小的机器人运动,进而提高了康复的参与度和有效性。上海交通大学的学者基于稳态视觉诱发的 BMI 技术识别人体行走意图,进而控制外骨骼机器人辅助受试者完成行走、停止和加减速等典型行走模式;且基于该技术可以进行不同行走模式的在线切换,实现了步态的实时控制^[26]。基于上肢外骨骼机器人,东华大学的刘志辉通过对 EEG 信号的记录和分析,探索上肢外骨骼机器人康复训练效果的评测方法并进行实验验证,实验证明 EEG 信号能够用于中风患者的康复效果评估^[27]。西北工业大的王海莲针对下肢外骨骼机器人感知需要,研究了基于 EEG 信号的检测和分析方法并用于人体运动意图识别,最终通过实验证明所提方法在下肢外骨骼机器人协同控制中的可行性^[28]。




图 1.3 BMI 及其应用

Fig. 1.3 BMI and its application

然而，EEG 信号具有空间分辨率差、信号复杂和信噪比差等缺点，且很难准确、稳定地获取相应活动的信号^[29]。此外，EEG 信号容易受到外界环境干扰，如果人脑意识不集中也会影响测量结果。因此，基于 sEMG 信号的人体意图识别比 EEG 信号更简单。

1.2.3 基于 sEMG 信号的意图识别研究现状

sEMG 信号是神经元和皮肤表面浅表肌肉电活动的综合效应，包含了肢体大量运动信息。当携带人体意图的神经元信息传递到相关肌肉，sEMG 信号就会被激活并直接反映出人体的运动意图。sEMG 的客观测量优势使得它理论上可以直接评估肌肉活动。而且作为一种非入侵技术，除了生理学和生物力学方面的研究，sEMG 信号还被广泛应用于运动科学、康复和人体工程学等领域^[30-32]。在外骨骼机器人领域，对 sEMG 信号解码得到的人体意图分为离散动作模式分类和连续运动意图识别^[33, 34]；离散动作模式分类只能用于判断外骨骼机器人的运动方向，而连续运动意图识别由于能对运动量的具体数值进行实时预测而更具研究价值。连续运动意图识别，即运动意图回归是建立 sEMG 信号到控制器连续参考轨迹的映射，参考轨迹包括关节角度/速度或者力/力矩等。基于 sEMG 信号的连续运动意图识别方法大致可分为肌肉骨骼模型预测法和基于机器学习的运动意图回归方法。

如图 1.4 所示，肌肉骨骼模型的基础框架是肌肉-肌腱的静力学和动力学，模型输入量为 sEMG 信号，输出量可以是关节角度、角速度或者力矩等。肌肉骨骼模型中应用最广泛的是 Hill 模型^[35-37]。Zhang^[38]等结合改进的 Hill 型肌肉模型、sEMG 信号和超声成像信号来预测踝关节背屈力矩，通过比较预测得到的踝关节力矩和实际测量的踝关节力矩验证了改进的 Hill 型肌肉模型预测的有效性。Karavas^[39]等采用 sEMG 信号驱动肌肉骨骼模型来预测膝关节力矩和轨迹等，受试者根据预测得到的关节力矩和轨迹能够完成外骨骼机器人自主和直观地控制。Guillaume^[40]等将基于 sEMG 信号驱动的肌肉骨骼模型合成到人机交互界面中，使中风和脊髓不完全损伤患者能够自动、实时地控制外骨骼机器人中的多个关节；而且，该人机交互界面能够根据 sEMG 信号实时预测踝关节和膝关节力矩，最后外骨骼插件将该关节力矩转化为控制指令。基于 Hill 型肌肉骨骼模型，浙江大学的研究人员将 sEMG 信号与人体关节角度信号结合，采用回归的方法来预测关节扭矩，该方法应用于外骨骼机器人辅助人体肘关节屈伸时能够实现人体运动意图的准确识别^[41]。然而，sEMG 信号驱动的肌肉骨骼模型未知参数多，计算量大且识别

难度高，针对受试者之间不同的生理参数往往需要进行大量的前期实验。因此，sEMG 信号驱动的肌肉骨骼模型预测存在时效性和普适性差的缺点。




图 1.4 基于肌肉骨骼模型的人体意图识别

Fig. 1.4 Human intention recognition based on musculoskeletal model

另一方面，以机器学习为核心的运动意图回归方法通过构建 sEMG 信号和肢体连续运动之间的映射实现对人体运动意图识别，其中应用最广泛的是神经网络算法。如图 1.5 所示，首先采集人体运动时的 sEMG 信号并进行预处理，然后通过机器学习算法对预处理的信号解码得到人体运动意图，最后将人体运动意图信号作为控制信号实现外骨骼机器人或者假肢的控制。Raj^[42]等使用径向基函数神经网络对人体手臂的运动进行识别，基于 sEMG 信号特征预测得到的肘关节角度和角速度具有较高的精度。为了对人体下肢姿态进行预测，Zhang^[43]等使用 BP 神经网络建立了 sEMG 信号与踝、膝和髋关节角度之间的映射，结果表明不同运动中预测得到的关节角度平均误差均小于 9°。浙江大学的王卫星研究了基于 sEMG 信号的手腕运动连续识别并将其应用于上肢外骨骼机器人，实现了 sEMG 信号-角度参数的连续回归和 sEMG 信号-方向的连续分类^[44]。中国科学技术大学的李国欣提出了一种基于人体肌肉协同模型的自适应主动控制方案，实现了人体运动意图的连续识别和上肢假肢机器人的协同运动；基于以 sEMG 信号为输入的肌肉协同模型，作者将复杂的肢体运动信息建模为低维肌肉群的运动原语信息进而解码出人体连续运动意图；作者还使用肌肉激活-力映射模型将肢体健康受试者的 sEMG 信号映射为假肢机器人的力信号^[45]。但上述经典的回归模型由于存在不确定性强、泛化

能力差和误差累积大等缺点，识别精度较低。同时，sEMG 信号也有信号微弱、信噪比小、容易受到工频噪声和外界环境干扰的特点。因此，如何对原始 sEMG 信号进行处理进而提取其中的有效特征，以及如何设计连续运动意图的识别框架来提升回归模型的精度和鲁棒性也是本文的研究内容之一。




图 1.5 基于 sEMG 和机器学习的人体意图识别

Fig. 1.5 Human intention recognition based on sEMG signal and machine learning

除了上述方法外，也有研究人员采用 sEMG 信号与生物力信号结合的方法对人体意图进行识别。如图 1.6 (a) 所示，日本筑波大学研发的 HAL 外骨骼将 sEMG 信号和足底压力信号等作为控制信号源来调整外骨骼辅助力矩，用于对健康人体助力或帮助脊髓不完全损伤和中风等行动障碍患者完成日常活动^[46,47]。如图 1.6 (b) 所示，中科院深圳研究所的刘笃信基于电驱动下肢外骨骼系统进行了多模态融合控制策略的研究；作者使用压力信号、关节角度信号、sEMG 信号、EEG 信号和深度摄像机对人体运动信息进行检测，通过信号融合和模式区分实现外骨骼的运动规划^[48]。但上述研究中都是关于离散运动模式的识别，将基于 sEMG 信号与生物力信号等的多源信号融合方法用于人体运动意图连续识别，尤其是本研究中膝关节角度连续预测方面的研究还没有人展开。



(a) 筑波大学
HAL 外骨骼机器人

(b) 中科院深圳研究
所外骨骼机器人

图 1.6 基于多源信号融合的外骨骼机器人系统^[46-48]

Fig. 1.6 Exoskeleton robot system based on multi-source signals

1.2.4 步态识别研究现状

步态是人体行走的特征之一和人体意图识别的前提，对外骨骼的运动助力和康复训练都至关重要。在外骨骼系统中，通常使用足底压力信号分析行走状态和步态相位。根据外骨骼系统不同的步态相位采用不同的控制算法可以使外骨骼和人体运动更协调。在步态识别的传感器中，除了足底压力传感器外，还包括地面传感器和体传感器等，其中非穿戴式传感器占 40%，IMU 占 37.5%，其它穿戴式传感器占 22.5%^[49]。由于非穿戴式传感器不适合用于下肢外骨骼机器人，所以本研究只对穿戴式的步态识别方法进行调研。

穿戴式步态识别方法具有低成本、便携和低功耗等特点，且不会对人体行走产生附加影响，在步态识别中得到了广泛的应用^[50, 51]。穿戴式步态识别方法使用布置在人体多个部位的传感器采集人体运动信息，提取运动信息中的有效特征，建立人体步态特征和步态之间的映射关系。步态识别的可穿戴传感器通常也可分成生物力信号传感器和生物电信号传感器两类，生物力信号传感包括 IMU、力传感器和力敏电阻（Force Sensitive Resistor, FSR）等，生物电信号传感器包括 sEMG 传感器和 EEG 传感器^[52, 53]。

生物力信号传感器中，FSR 具有其成本低、后处理简单、灵敏度高和线性度好的特点，在步态识别中应用广泛。基于设置的压力阈值，对 FSR 测得的足底压力信号分析可以得到步态周期的子阶段。Macleod^[54]等基于 FSR 传感器研发了一种低成本和便携的步态评估装置来记录步态的时空参数。Yu^[55]等使用 FSR 传感器测

量足底压力信号，基于该信号提出了一种自适应、实时的步态识别新方法；实验结果表明，该方法可用于自适应、实时的步态识别，且与传统方法相比具有较高的可靠性。Zhang^[56]等设计了一种低成本、高度集成的足底压力测量装置，该装置中的FSR传感器在步态识别时响应快、灵敏度高且稳定性好。IMU传感器由于集成度高、可测多种物理量，是步态识别中应用最广泛的传感器。将IMU传感器布置在受试者身上可以捕捉运动相关的特征，使用卷积神经网络和模糊逻辑等算法可以识别人体姿态和异常步态^[57-59]。IMU传感器常被用来识别摆动相方位或者足跟着地（Heel Strike, HS）和脚趾离地（Toe Off, TO）两个步态事件；IMU传感器对HS和TO识别准确率高且在步态终止方面识别性能较好。但是，FSR和IMU传感器在步态识别方面仍然存在不足；FSR仅限于对时间参数的估计，且足底压力达不到设定阈值时会导致识别失败，鲁棒性较差；而IMU对其它步态事件和步态阶段的识别能力较差。生物电信号传感器中，Wei^[60, 61]等使用sEMG信号和EEG信号中的信号特征实现了对七个步态阶段的识别，且该方法在不同行走速度下具有较好的鲁棒性。Yao^[62]等提出了一种基于sEMG信号和深度神经网络的步态识别方法，该方法与传统分类器的步态识别结果相比具有更高的稳定性和准确性。由于可穿戴传感器的巨大优势，已成为下肢外骨骼机器人或者人体假肢步态识别中最常用的方法，而采用多种可穿戴传感融合和算法融合的方法来提高步态识别精度更成了研究重点。此外，生物力信号传感器与生物电信号相比具有原理简单、抗干扰能力强和精度高等优点，在步态识别中被广泛使用。

如上所述，虽然业界学者在人体意图识别和步态识别方面开展了大量研究并取得了一定的成果，但是由于受试者、环境和算法等非理想因素的限制，识别精度和鲁棒性仍然不够。且在下肢外骨骼系统中，减少传感器数量更利于人机交互的实现和增加患者的舒适度。因此，设计传感器数量少，识别精度高、鲁棒性强和时效性好的人体运动意图识别和步态识别方法仍是亟待解决的问题。

1.3 论文的主要研究内容与结构安排

基于上述研究现状，本文将重点研究实时、连续的人体运动意图识别方法和高精度、鲁棒性强的步态识别方法，以此来解决人机协调运动控制技术中的关键问题。作为人体运动意图识别和步态识别新方法的探索，本文以人体行走过程中膝关节运动和步态为研究对象进行研究；膝关节运动是人体下肢运动重要的关节之一，也

是下肢外骨骼机器人控制研究的重点。本文的具体研究内容和研究方法如图 1.7 所示。




图 1.7 本文的主要研究内容和方法

Fig. 1.7 Main research contents and methods in this paper

本文研究主要包括两方面，一是膝关节角度的连续预测，二是行走过程中的步态识别。膝关节角度连续预测可以帮助实现外骨骼机器人的位置控制，步态识别可以帮助外骨骼机器人判断运动趋势和方向，二者相结合有利于实现高效、自然的人机协同。考虑 sEMG 信号在人体意图识别中的不足和人体下肢关节角度的耦合性，首次提出将基于 sEMG 信号和髋关节角度的多源信号融合方法用于膝关节角度连续预测。针对 sEMG 信号模糊性和不确定性强的特点，本研究首先对 sEMG 信号进行预处理和特征提取，然后将肌电特征和髋关节角度信号融合并以时间序列信号形式输入到回归模型，最终实现膝关节角度的连续预测。在步态识别方面，本文将阈值法和连续小波变换相结合，提出了一种精度高、鲁棒性强的复合步态识别算法。最后，在 Indego 下肢外骨骼机器人上进行位置控制实验，验证所提方法在下肢外骨骼机器人实际应用中的可行性。

根据上述研究内容，对其进行拓展得到论文的结构安排，将人体行走特征、行走运动信号获取和处理、膝关节角度连续预测、步态识别及外骨骼机器人实验分别作一章进行详细论述，加上绪论和总结与展望，全文总共分为如下 7 章：

（1）第一章：绪论。先阐述本课题的研究背景和研究意义，然后介绍和分析了国内外相关研究现状，基于研究现状中存在的问题提出了本文的研究目标、研究内容，并对论文结构做安排。

（2）第二章：介绍了人体下肢的解剖学结构、行走的步态特征和下肢运动学、动力学模型等相关理论，为后面的研究奠定理论基础。

（3）第三章：基于进行人体行走的信号获取和处理。根据解剖学结构，对行走实验中大腿部位的 4 通道 sEMG 信号、下肢关节角度和足底压力信号进行采集，并对 sEMG 信号进行预处理和肌电特征提取。

（4）第四章：基于多源信号融合的膝关节角度连续预测。将第三章得到的肌电特征和髌关节角度信号融合并以时间序列信号形式分别输入到 CNN、RNN 和 LSTM 回归模型，实现膝关节角度连续预测。同时，基于三种回归模型，还比较了仅采用肌电特征预测和仅采用髌关节角度预测的结果。采用平均绝对误差、均方根误差和 R^2 分数对回归模型的性能进行分析和评估。

（5）第五章：人体行走步态识别。采集了行走过程中足部加速度和足底压力信号，将基于足底压力信号的阈值法和基于足部加速度的连续小波变换法相结合，设计了一种复合步态识别算法，并通过实验验证该方法的有效性和鲁棒性。

（6）第六章：下肢外骨骼机器人实验研究。将第四章中预测得到的膝关节角度作为输入信号，控制下肢外骨骼机器人以不同的速度行走。将受试者穿戴外骨骼在不同速度下行走与不穿戴外骨骼正常行走的步态、膝关节角度和肌肉的肌电特征进行对比，验证了所提方法可行性的同时还分析了机器人的辅助效果。

（7）第七章：总结全文工作并展望未来的研究内容。

第2章 行走的下肢运动分析

行走是人体下肢最重要的活动之一，也是下肢外骨骼机器人辅助人体运动的最终目标。人体行走靠骨骼、肌肉和关节三者之间的密切协作完成；肌肉通过不断收缩和舒张将力量传递到骨骼，使身体推动向前；同时骨骼和关节支撑身体重量并保持稳定。对人体运动解剖学结构进行解释可以更好地了解人体的骨骼、关节和肌肉对行走的影响。人体行走是通过双摆的策略来实现，两条腿的协调运动存在足部始终与地面接触，双足的这种周期性离地和在地状态产生了步态。作为重要行走特征之一，步态特征分析在意图识别和外骨骼控制过程中发挥着重要作用。同时，人体行走下肢的运动学和动力学数据和外骨骼机器人系统的运动学和动力学建模能够为后面章节人体意图识别和外骨骼机器人实验提供参考。

2.1 人体解剖学结构

参照人体解剖学理论，下肢骨骼主要包括股骨、胫骨、腓骨和骨盆等^[63]，具有髋、膝和踝关节三个关节，图 2.1 为人体下肢骨骼结构。骨盆和股骨的连接处为髋关节；股骨和胫骨的连接处为膝关节；胫骨和腓骨的连接处为踝关节。目前，多数下肢外骨骼机器人的髋关节和膝关节为主动自由度，踝关节为被动自由度，即只对髋关节和膝关节提供助力。

在三维空间内，首先将人体运动简化为转动、平动和复合运动，然后针对不同的运动进行分析和研究。基于人体解剖学结构，人体运动可以分为在矢状面、冠状面和水平面内的运动^[64]。三种面相互垂直（图 2.2），矢状面将肢体纵切成左右两半；冠状面将人体纵切成前后两半；水平面将人体切成上下两半^[65]。将矢状面内指向人体前方的轴定义为矢状轴，冠状面内指向人体左侧的轴定义为冠状轴，垂直向上的轴定义为垂直轴。人体下肢在矢状面内的运动为本文研究重点。

髋关节的外展和内收如图 2.3 所示，该动作在人体的冠状面内完成，正常行走外展的角度为 $0^{\circ}\sim 6^{\circ}$ ，内收的角度为 $0^{\circ}\sim 8^{\circ}$ 。踝关节的外展和内收如图 2.4 所示，该动作同样在人体的冠状面内完成，正常行走外展的角度为 $0^{\circ}\sim 5^{\circ}$ ，内收的角度为 0° 。髋关节的外旋和内旋如图 2.5 所示，该动作在人体的水平面内完成，正常行走时髋关节外旋角度 $0^{\circ}\sim 7^{\circ}$ ，内旋角度为 $0^{\circ}\sim 3^{\circ}$ 。踝关节的外旋和内旋如图 2.6 所示，该动作在人体的水平面内完成，正常行走时踝关节外旋和内旋均为 0° 。




图 2.1 人体下肢骨骼结构

Fig. 2.1 Bone structure of human lower limb




图 2.2 人体基本面图

Fig. 2.2 Basic plane of human body




图 2.3 髋关节外展和内收

Fig. 2.3 Hip joint abduction and adduction



图 2.4 踝关节外展和内收

Fig. 2.4 Ankle joint abduction and adduction




图 2.5 髋关节外旋和内旋

Fig. 2.5 Hip joint external and internal rotation




图 2.6 踝关节外旋和内旋

Fig. 2.6 Ankle joint external and internal rotation

髋关节是一个球状关节，具有三个自由度，其运动可以分解为冠状面、水平面和矢状面内的运动。如图 2.7 (a) 所示，髋关节在矢状面内的运动包括髋关节的屈和伸。髋关节的中立位为大腿与冠状面平行位置，定义大腿向前远离冠状面的运动方向为正（伸展），定义大腿向后远离冠状面的运动方向为负（屈曲），人体正常行走的髋关节的屈伸角度一般为 $-30^{\circ}\sim+30^{\circ}$ 。

膝关节是人体下肢最复杂和最大的关节，其常见运动是围绕冠状轴在矢状面内的屈和伸，如图 2.7 (b) 所示。膝关节的中立位为小腿和大腿角度为 0° 时，将小腿向后远离大腿中轴线的方向定义为屈曲运动，小腿向前远离大腿中轴线的方向定义为伸展运动，人体正常行走的屈曲角度一般为 $-60^{\circ}\sim 0^{\circ}$ 。膝关节的屈伸运动是本文人体运动意图识别的研究对象和下肢外骨骼机器人的辅助对象。

如图 2.7 (c) 所示，踝关节在矢状面内绕冠状轴的运动为足部的背屈和趾屈。踝关节的中立位为脚掌与小腿垂直时，将踝关节的背屈定义为脚掌与小腿夹角减小的方向，踝关节的趾屈定义为脚掌与小腿夹角增大的方向。人体正常行走时背屈最大角度约 4° ，趾屈的最大角度约 -12° ，人体背屈和趾屈的极限角度均为 20° 。




图 2.7 矢状面内下肢关节运动

Fig. 2.7 Lower limb joint movement in sagittal plane

人体下肢各关节自由度与外骨骼机器人控制输入和外骨骼辅助时的安全性有关。如表 2.1 所示，展示了人体下肢髋、膝和踝关节各自由度在正常行走和最大运动范围时相应的关节角度范围^[66]。

表 2.1 下肢关节运动范围
Table 2.1 Range of lower joint motion

关节名称	自由度	正常行走角度范围	极限角度范围
髋关节	屈曲	0°~30°	0°~125°
	伸展	-30°~0°	-45°~0°
	内收	0°~8°	0°~31°
	外展	0°~6°	0°~53°
	内旋	0°~3°	0°~15°
	外旋	0°~7°	0°~30°
膝关节	屈曲	-60°~0°	-159°~0°
	伸展	0°	0°
	背屈	0°~4°	0°~20°
踝关节	趾屈	-12°~0°	-20°~0°
	内收	0°	0°~30°
	外展	0°~5°	0°~40°
	内旋	0°	0°~30°
	外旋	0°	0°~50°

人体的肌肉分为心肌、骨骼肌和平滑肌；骨骼肌在神经支配下的收缩或者舒张带动肢体完成日常活动^[67]。人体下肢关节运动涉及多个肌肉群的协同工作，通过测量和分析相关肌肉群的 sEMG 信号对人体下肢动作模式等的识别得到了广泛应用。所以，了解矢状面内各关节运动相关的肌肉群是人体下肢运动意图识别的基础。它包括与髋关节屈伸、膝关节屈伸和踝关节的趾屈、背屈相关的肌肉群，人体下肢肌肉群分布如图 2.8 所示。其中，屈髋关节为髂腰肌、股直肌、缝匠肌、阔筋膜张肌和耻骨肌等，伸髋关节为臀大肌、股二头肌和半腱肌等；屈膝关节为股薄肌、缝匠肌、腓肠肌和股二头肌等，伸膝关节为股内、外侧肌等；踝关节背屈和趾屈为腓肠肌和比目鱼肌^[68]。




图 2.8 下肢肌肉群

Fig. 2.8 Muscle groups of lower limb

2.2 人体行走的步态特征

人体行走是通过周期性的腿部机械运动，使身体从一处安全有效地转移到另一处。行走主要在人体矢状面内完成，步态是其行为特征。同时，行走也是在神经系统对运动系统的支配与控制下完成的高度自动化的均匀、稳定、协调和对称的运动，具有重复性、周期性和约束性的特点。行走时双下肢更替前行的姿态大致一样，循环呈现，即重复性；由于肌肉肌腱和骨骼的牵制，导致肢体运动被局限在特定范围，即局限性；行走时单步耗时和姿态大致相同，每步均可视为一个特定周期，即周期性。基于人体行走的三种特性，选择一个典型步态周期及其下肢在特定运动范围内的姿态即可实现对步态的研究。将人体足部不同部位与地面接触的瞬间定义为不同的步态事件（Gait Event），主要有足跟着地（HS）、足跟离地（Heel Off, HO）、脚趾着地（Toe Strike, TS）和脚趾离地（TO）等；两个步态事件形成的区间称为步态相位（Gait Phase），如站立相（Stance）和摆动相（Swing）等。

将人体自然的步态周期定义为下肢同一侧足跟着地到二次着地之间的时间间隔。如果考虑双腿步态相位，步态周期可分为单足支撑阶段和双足支撑阶段；单足支撑阶段占 80%~90%，双足支撑阶段占 10%~20%^[69]。单腿支撑阶段只有一条腿承受身体全部重量，另一条腿呈现摆动姿态并不与地面接触；双腿支撑阶段，不存在摆动姿态，由两腿共同承担身体全部重量。

目前对步态分析的研究表明，对于单腿而言，一个完整的步态周期可分为站立相和摆动相两个阶段（图 2.9），其中站立相占 60%，摆动相占 40%^[70]。单次步态

循环中，站立相又分为 4 个子阶段，分别为承载阶段（Loading Phase, LR）、站立相中期（Mid-Stance, MSt）、站立相末期（Terminal-Stance, TSt）和预摆动相（Pre-Swing, PSw）；摆动相分为 3 个子阶段，分别为初始摆动相（Initial-Swing, ISw）、摆动相中期（Mid-Swing, MSw）和摆动相末期（Terminal-Swing, TSw）；上述子阶段在单个步态循环中的占比分别是 10%、20%、20%、10%、13%、14%和 13%^[71]。




图 2.9 单腿的完整步态周期

Fig. 2.9 A complete gait cycle of one leg

（1）站立相：占 60%，表示足部与地面存在相互作用力的阶段。

站立相早期：即承载阶段，占 10%。起点为足跟与地面接触，结束为脚趾即将着地。这一阶段，由于足跟与地面接触使得下肢运动减速，且人体重心随着全脚掌着地由足跟向全足逐渐转移。

站立相中期：占 20%。起始点为脚趾着地，结束为足跟即将离地。这一阶段，支撑足完全着地并支撑人体全部重量。

站立相末期：占 20%。起始点为足跟离地，结束为脚掌中部即将离地。这一阶段，双腿开始共同支撑人体重量。

预摆动相：占 20%。起始点为脚掌中部离地，结束为脚趾即将离地。这一阶段，下肢加速蹬离地面，人体重心逐渐向位于承载阶段的腿偏移。

（2）摆动相：占 40%，表示足部脱离地面开始摆动的时期。

摆动相早期：占 13%。单腿足部全部离开地面并进行屈髋和屈膝动作，在矢状面内向前运动速度增大。

摆动相中期：占 14%。单腿的足部完全离开地面并朝前摆动。

摆动相末期：占 13%。单腿在矢状面内向前运动的速度降低，踝关节背屈准备足跟着地。

人体行走过程中足部与地面接触时的冲击载荷随着步态相位的变化而改变，通常使用压力传感器测量这一压力变化，该压力信号可用于站立相步态识别。作为步态特征之一，足底压力又叫地面接触力（Ground Contact Forces, GCFs），通常分为足跟、脚掌中部和脚趾三大区域^[72]，如图 2.10 所示。单个步态循环时，随着步态相位的变化，足跟、脚掌中部和脚趾与地面的接触面积也在周期性变化，进而导致足跟、脚掌中部和脚趾部位的足底压力周期性变化。




图 2.10 足底压力分布示意图

Fig. 2.10 Schematic diagram of plantar pressure distribution

图 2.11 描述了单个步态周期内足底压力与各关节角度的关系，图中的各个关节角度和足底压力位于人体下肢同一侧。图 2.11 中，足跟着地之后，人体行走时全身的重量和惯性力全部由位于站立相的足部承受，此刻的足底压力在垂直方向 y 分量上最大，且在人体重心逐渐转移过程中出现极大值；随着人体重心向前，整个足部逐渐与地面完全接触， y 分量上的压力减小并出现波谷；在预摆动相阶段，随着脚趾加速蹬离地面， y 分量上的压力出现另一极大值。足底压力在垂直方向具有典型的双峰性质^[73]，在其它两个方向的压力值较小且不具有典型特征。因此，垂直方向的足底压力测量和分析是识别步态相位的重要手段之一。




图 2.11 步态循环中关节角度和足底压力

Fig. 2.11 Joint angle and plantar pressure in gait cycle

此外，人体步态还受到行走习惯、疾病、性别和年龄等因素的影响^[74]。例如，对于下肢运动功能受损的患者来说，会减小摆动相来保持肢体稳定。同样，年龄大的患者也会通过减小摆动相来保持行走稳定。与健康人相比，步态异常患者有明显的步态不对称临床表现，患者的下肢负重能力明显下降；在异常侧下肢，患者通常表现为站立相的减少和摆动相的延长。脚趾拖拉是步态异常患者最明显特征，且会造成下肢在摆动相时很僵硬。因此，为了准确识别不同受试者的步态相位和区分异常步态，需要保证步态识别算法的鲁棒性。

2.3 行走的下肢运动模型

2.3.1 人体行走下肢运动学和动力学数据

人体行走下肢的运动学和动力学数据，如关节角度/角速度和关节力/力矩等能够用于机器人假肢或外骨骼机器人控制，还能用于运动医学、运动生理学和人体工程学等多种场合，在本研究中能够为膝关节角度连续预测和外骨骼机器人实验提供参考。

人体最最常见的运动模式是行走，成年人正常行走速度约为 1.3m/s。对于不完全脊髓损伤患者来说，研究人员定义行走速度 $\leq 0.44\text{m/s}$ 为有限社区行走（Limit Community Ambulation），步行速度 $> 0.4\text{m/s}$ 为全社区行走（Full Community Ambulation）^[75]。基于临床步态数据^[76]，得到受试者在跑步机上以不同速度行走的关节角度和角速度如图 2.12 所示。图 2.12 中，当人体在跑步机上行走时速度从 0.5m/s 增加到 2.6m/s 时，矢状面踝关节的最大转角从 20°增加到 38°，膝关节最大转角从 54°增加到 60°，髌关节最大转角从 15°增加到 18°，说明下肢关节转角与行

走速度成正相关。行走速度增加同样导致关节角速度增加,当人体在跑步机上行走时速度从 0.5m/s 增加到 2.6m/s 时,矢状面踝关节的最大角速度从 112°/s 增加到 302°/s,膝关节最大角速度从 250°/s 增加到 500°/s,髋关节最大角速度从 105°/s 增加到 200°/s。

基于图 2.12 中的关节角度和角速度数据,利用逆动力学方法计算得到的不同行走速度下关节扭矩如图 2.13 所示,图中各关节的功率表示为关节速度和关节扭矩的乘积。图 2.13 中,当人体在跑步机上行走时速度从 0.5m/s 增加到 2.6m/s 时,踝关节最大力矩从 1.1 N·m/kg 增加到 1.6 N·m/kg,膝关节最大力矩从 0.2 N·m/kg 增加到 1.5 N·m/kg,髋关节最大力矩从 0.5 N·m/kg 增加到 1.7 N·m/kg。对于关节功率来说,当人体在跑步机上行走时速度从 0.5m/s 增加到 2.6m/s 时,踝关节的最大功率从 0.8W/kg 增加到 4.3W/kg,膝关节最大功率从 0.4W/kg 增加到 4W/kg,髋关节最大功率从 0.3W/kg 增加到 2.8W/kg。即人体行走速度的增加同样代表了下肢关节力矩和功率的增加。




图 2.12 关节角度和角速度^[76]

Fig. 2.12 Joint angle and angular velocity




图 2.13 关节力矩和功率^[76]

Fig. 2.13 Joint torque and power

2.3.2 下肢外骨骼系统运动学模型

下肢外骨骼机器人是以人体解剖学结构、运动数据和动力数据为基础进行设计，由人体穿戴并由人主导、向人提供辅助，并协助人体完成日常运动的工具。受试者穿戴外骨骼后成为一个独立的外骨骼系统，该系统具有多变量、非线性、强耦合和冗余自由度的特点^[77]。对人体穿戴外骨骼后的下肢进行运动学和动力学建模能够确定机器人的相关参数、优化机器人控制算法并提高机器人性能。

运动学分析的目的是深入研究外骨骼机器人的耦合连杆之间各运动量的相互关系，分为正运动学和逆运动学。已知求解对象的几何参数和关节相位，对末端轨迹的分析为正运动学；已知求解对象的几何参数和末端轨迹，对关节相位的分析为逆运动学。正运动学和逆运动学分析是外骨骼机器人误差分析、工作空间分析和动力分析等的基础。

Denavit-Hartenberg (D-H) 法^[78]通常被用于简化机器人模型，目前国内外机器人正运动学建模大多是基于 D-H 法^[79, 80]。按照人体下肢运动分为支撑相和摆动相的分解，同样根据外骨骼是否与地面接触将其运动分为闭式链（站立相）和串联机

械臂（摆动相）进行分析。在动力学建模时，站立相的外骨骼机器人下肢与地面接触形成的闭式链分析较为复杂，因此采用拆分法并就摆动腿进行建模。下肢外骨骼机器人摆动腿不考虑与地面的接触力，可以视为具有转动自由度的串联机器人，由3个转动关节和2个刚性连杆组成（图2.14），D-H法对应的连杆坐标及参数定义如下：

（1） z_{i-1} 轴表示 i 的方向， z_i 轴表示 $i+1$ 的方向。 z_{i-1} 和 z_i 二者公垂线分别与 z_i 交于 O_i ，与 z_{i-1} 交于 $O_{i'}$ 。

（2）连接 O_i 和 $O_{i'}$ 并将其作为 x_i 轴，方向由关节 i 指向 $i+1$ 。根据右手定则可以确定 y_i 轴。

建立了D-H连杆坐标系后，局部坐标系 $i-1$ 和 i 的关系可由以下参数进行定义：

- （1） a_i ：表示 O_i 与 $O_{i'}$ 之间的距离；
- （2） α_i ：表示 z_{i-1} 和 z_i 的角度差，将绕 x_i 顺时针方向定义为负；
- （3） d_i ：表示 $O_{i'}$ 沿 z_{i-1} 的坐标；
- （4） θ_i ：表示 x_{i-1} 和 x_i 的角度差，将绕 z_{i-1} 顺时针方向定义为负。




图 2.14 D-H 法参数定义

Fig. 2.14 Parameter definition of D-H method

其中， a_i 和 α_i 是常数，由相邻连杆连接关系决定。参数 θ_i 和 d_i 中只有一个是变量，由关节类型决定；前者表示转动型，后者表示移动型。由于本研究中为转动

关节，所以变量为 θ_i 。基于以上参数，坐标系 i 和坐标系 $i-1$ 之间的变换可以分两步计算得到：

(1) 基于坐标系 $i-1$ ，沿 z_{i-1} 移动 d_i 并绕 z_{i-1} 转动 θ_i ，即可实现将坐标系 $i-1$ 转换到 i' 。用齐次变换矩阵表示该变换为：

$$A_i^{i-1} = \begin{bmatrix} c_{\theta_i} & -s_{\theta_i} & 0 & 0 \\ s_{\theta_i} & c_{\theta_i} & 0 & 0 \\ 0 & 0 & 1 & d_i \\ 0 & 0 & 0 & 1 \end{bmatrix} \quad (2.1)$$

式中， s_{θ_i} 表示 $\sin\theta_i$ ， c_{θ_i} 表示 $\cos\theta_i$ ，下同。

(2) 基于坐标系 i' ，沿 $x_{i'}$ 移动 a_i 并绕 $x_{i'}$ 转动 α_i ，即可实现将坐标系 i' 转换到 i 。用齐次变换矩阵表示该变换为：

$$A_i^i = \begin{bmatrix} 1 & 0 & 0 & a_i \\ 0 & c_{\alpha_i} & -s_{\alpha_i} & 0 \\ 0 & s_{\alpha_i} & c_{\alpha_i} & 0 \\ 0 & 0 & 0 & 1 \end{bmatrix} \quad (2.2)$$

所以连杆 i 和连杆 $i-1$ 之间的变换表示为：

$$A_i^{i-1} = A_i^{i'} A_i^i = \begin{bmatrix} c_{\theta_i} & -s_{\theta_i} c_{\alpha_i} & s_{\theta_i} s_{\alpha_i} & a_i c_{\theta_i} \\ s_{\theta_i} & c_{\theta_i} c_{\alpha_i} & -c_{\theta_i} s_{\alpha_i} & a_i s_{\theta_i} \\ 0 & s_{\alpha_i} & c_{\alpha_i} & d_i \\ 0 & 0 & 0 & 1 \end{bmatrix} \quad (2.3)$$

本研究中，下肢外骨骼机器人简化模型时不考虑踝关节自由度，只考虑髋关节和膝关节在矢状面内的自由度。同时，将外骨骼腰部与穿戴者连接位置看作下肢外骨骼摆动腿的固定基座^[81]，在进行摆动腿建模时，只考虑髋关节转动自由度。因此，该外骨骼系统的摆动腿可简化为图 2.15 所示的两自由度连杆结构。

参照上文分析，可以得到该摆动腿的 D-H 参数如表 2.2 所示。根据式 2.3 中的推导，得到图 2.15 中连杆 1 和 2 的变换矩阵如式 2.4 和 2.5 所示。




图 2.15 摆动腿坐标系

Fig. 2.15 Coordinate of swing leg

表 2.2 摆动腿 D-H 参数

Table 2.2 D-H parameters of swing leg

i	α_i	a_i	d_i	θ_i
1	0	l_1	0	θ_1
2	0	l_2	0	θ_2

$${}^0_1T = \begin{bmatrix} c_{\theta_1} & -s_{\theta_1} & 0 & l_1 c_{\theta_1} \\ s_{\theta_1} & c_{\theta_1} & 0 & l_1 s_{\theta_1} \\ 0 & 0 & 1 & 0 \\ 0 & 0 & 0 & 1 \end{bmatrix} \quad (2.4)$$

$${}^1_2T = \begin{bmatrix} c_{\theta_2} & -s_{\theta_2} & 0 & l_2 c_{\theta_2} \\ s_{\theta_2} & c_{\theta_2} & 0 & l_2 s_{\theta_2} \\ 0 & 0 & 1 & 0 \\ 0 & 0 & 0 & 1 \end{bmatrix} \quad (2.5)$$

由式 2.4 可得 A 点的位置和姿态分别为：

$$\begin{cases} x_A = l_1 c_{\theta_1} \\ y_A = l_1 s_{\theta_1} \\ z_A = 0 \end{cases} \quad (2.6)$$

$$R_A = \begin{bmatrix} c_{\theta_1} & -s_{\theta_1} & 0 \\ s_{\theta_1} & c_{\theta_1} & 0 \\ 0 & 0 & 1 \end{bmatrix} \quad (2.7)$$

由式 2.4 与式 2.5 相乘得到摆动腿末端相对于参考坐标系的齐次变换矩阵：

$${}^0_2T = \begin{bmatrix} c_{\theta_{12}} & -s_{\theta_{12}} & 0 & l_2 c_{\theta_{12}} + l_1 c_{\theta_1} \\ s_{\theta_{12}} & c_{\theta_{12}} & 0 & l_2 s_{\theta_{12}} + l_1 s_{\theta_1} \\ 0 & 0 & 1 & 0 \\ 0 & 0 & 0 & 1 \end{bmatrix} \quad (2.8)$$

上式中， $\theta_{12} = \theta_1 + \theta_2$ 。由式 2.8 可得 B 点的位置和姿态分别为：

$$\begin{cases} x_B = l_2 c_{\theta_{12}} + l_1 c_{\theta_1} \\ y_B = l_2 s_{\theta_{12}} + l_1 s_{\theta_1} \\ z_B = 0 \end{cases} \quad (2.9)$$

$$R_B = \begin{bmatrix} c_{\theta_{12}} & -s_{\theta_{12}} & 0 \\ s_{\theta_{12}} & c_{\theta_{12}} & 0 \\ 0 & 0 & 1 \end{bmatrix} \quad (2.10)$$

基于 A 点和 B 点位置得到其速度为：

$$\begin{cases} \dot{x}_A = -l_1 s_{\theta_1} \dot{\theta}_1 \\ \dot{y}_A = l_1 c_{\theta_1} \dot{\theta}_1 \\ \dot{x}_B = -l_2 s_{\theta_{12}} (\dot{\theta}_1 + \dot{\theta}_2) + l_1 s_{\theta_1} \dot{\theta}_1 \\ \dot{y}_B = l_2 c_{\theta_{12}} (\dot{\theta}_1 + \dot{\theta}_2) + l_1 c_{\theta_1} \dot{\theta}_1 \end{cases} \quad (2.11)$$

基于式 2.11 得到其加速度为：

$$\begin{cases} \ddot{x}_A = -l_1 c_{\theta_1} \dot{\theta}_1^2 - l_1 s_{\theta_1} \ddot{\theta}_1 \\ \ddot{y}_A = -l_1 s_{\theta_1} \dot{\theta}_1^2 + l_1 c_{\theta_1} \ddot{\theta}_1 \\ \ddot{x}_B = -l_2 c_{\theta_{12}} (\dot{\theta}_1 + \dot{\theta}_2)^2 - l_2 s_{\theta_{12}} (\ddot{\theta}_1 + \ddot{\theta}_2) - l_1 c_{\theta_1} \dot{\theta}_1^2 - l_1 s_{\theta_1} \ddot{\theta}_1 \\ \ddot{y}_B = -l_2 s_{\theta_{12}} (\dot{\theta}_1 + \dot{\theta}_2)^2 + l_2 c_{\theta_{12}} (\ddot{\theta}_1 + \ddot{\theta}_2) - l_1 s_{\theta_1} \dot{\theta}_1^2 + l_1 c_{\theta_1} \ddot{\theta}_1 \end{cases} \quad (2.12)$$

由式 2.6 和 2.9 求得 θ_1 , θ_2 的角度为:

$$\begin{cases} \theta_1 = \arctan\left(\frac{y_A}{x_A}\right) \\ \theta_2 = \pi - \arccos\left(\frac{l_1^2 + l_2^2 - (x_B^2 + y_B^2)}{2l_1 l_2}\right) \end{cases} \quad (2.13)$$

根据髋、膝关节转角和定义的广义坐标 θ_1 , θ_2 之间的关系, 得到摆动腿髋、膝关节转角为:

$$\begin{cases} q_h = \theta_2 \\ q_k = \pi / 2 + \theta_1 \end{cases} \quad (2.14)$$

2.3.3 下肢外骨骼系统动力学模型

下肢外骨骼机器人分为被动控制和主动控制两种控制模式, 被动控制不考虑人机交互力, 由外骨骼带动人体完成各种动作^[82]。建立被动控制的动力学模型, 可以了解各下肢关节的动力学关系和关节力对机器人的影响。本研究采用拉格朗日法进行外骨骼系统动力学建模, 它是一种基于能量平衡的建模方法^[83], 不考虑连杆之间的约束反力, 避免了单个连杆的运动学加速度和角速度求解, 推导过程相对简单。

拉格朗日法假设了一个具有 n 根杆件的机械臂系统, 广义位置和广义速度可以分别表示为 q 、 $\dot{q}$ 。拉格朗日函数 $\Lambda = K - P$, K 和 P 分别表示系统总动能和势能^[84]。若 Q 表示总的外部集中力, 则拉格朗日动力学方程为:

$$\frac{d}{dt}\left(\frac{\partial \Lambda}{\partial \dot{q}}\right) - \frac{\partial \Lambda}{\partial q} = Q, \quad i = 1, 2, \dots, n \quad (2.15)$$

基于图 2.15 中的坐标系，根据 2.3.2 中所述的运动学计算方法，求得连杆 1 和 2 质心速度的平方：

$$\begin{aligned} v_1^2 &= \dot{x}_1^2 + \dot{y}_1^2 \\ v_2^2 &= \dot{x}_2^2 + \dot{y}_2^2 \end{aligned} \quad (2.16)$$

将连杆 1 和 2 质心处的速度分别代入式 2.16 得到式 2.17：

$$\begin{aligned} v_1^2 &= l_{c1}^2 \dot{\theta}_1^2 \\ v_2^2 &= \dot{\theta}_1^2 l_1^2 + l_{c2}^2 (\dot{\theta}_1 + \dot{\theta}_2)^2 + 2l_1 l_{c2} c_{\theta_2} \dot{\theta}_1 (\dot{\theta}_1 + \dot{\theta}_2) \end{aligned} \quad (2.17)$$

又连杆 1 和 2 的动能可以表示为式 2.18：

$$\begin{aligned} K_1 &= \frac{1}{2} (I_1 \dot{\theta}_1^2) + \frac{1}{2} (m_1 v_1^2) \\ K_2 &= \frac{1}{2} (I_2 \dot{\theta}_2^2) + \frac{1}{2} (m_2 v_2^2) \end{aligned} \quad (2.18)$$

将连杆 1 和 2 质心速度的平方 v_1^2 、 v_2^2 分别代入式 2.18 可得：

$$\begin{aligned} K_1 &= \frac{1}{2} I_1 \dot{\theta}_1^2 + \frac{1}{2} m_1 l_{c1}^2 \dot{\theta}_1^2 \\ K_2 &= \frac{1}{2} [I_2 \dot{\theta}_2^2 + m_2 l_1^2 \dot{\theta}_1^2 + m_2 l_{c2}^2 (\dot{\theta}_1 + \dot{\theta}_2)^2] + m_2 l_1 l_{c2} c_{\theta_2} \dot{\theta}_1 (\dot{\theta}_1 + \dot{\theta}_2) \end{aligned} \quad (2.19)$$

系统的总动能可以表示为 $K=K_1+K_2$ 。同理，基于图 2.15 中的坐标系，分别求得连杆 1 和 2 的重力势能，则该二连杆结构系统的总势能为：

$$\begin{aligned} P &= P_1 + P_2 \\ &= m_1 g l_{c1} c_{\theta_1} + m_2 g (l_1 c_{\theta_1} + l_{c2} c_{\theta_2}) \end{aligned} \quad (2.20)$$

结合拉格朗日函数 Λ 、式 2.15、式 2.19 和式 2.20，得到下肢外骨骼机器人二连杆结构的拉格朗日动力学标准表达式为：

$$\tau = \begin{bmatrix} \tau_1 \\ \tau_2 \end{bmatrix} = M(\theta) \ddot{\theta} + C(\theta, \dot{\theta}) \dot{\theta} + G(\theta) \quad (2.21)$$

式 2.21 中，惯性矩阵 $M(\theta)$ 可以表示为：

$$M(\theta) = \begin{bmatrix} m_1 l_{c1}^2 + m_2(l_1^2 + l_{c2}^2 + 2l_1 l_{c2} c_{\theta_2}) + I_1 + I_2 & m_2(l_{c2}^2 + l_1 l_{c2} c_{\theta_2}) + I_2 \\ m_2(l_{c2}^2 + l_1 l_{c2} c_{\theta_2}) + I_2 & m_2 l_{c2}^2 + I_2 \end{bmatrix} \quad (2.22)$$

式 2.21 中, 科式力矩阵 $C(\theta, \dot{\theta})$ 可以表示为:

$$C(\theta, \dot{\theta}) = \begin{bmatrix} -m_2 l_1 l_{c2} s_{\theta_2} \dot{\theta}_2 & -m_2 l_1 l_{c2} s_{\theta_2} \dot{\theta}_{12} \\ m_2 l_1 l_{c2} s_{\theta_2} \dot{\theta}_2 & 0 \end{bmatrix} \quad (2.23)$$

式 2.21 中, 重力矩阵 $G(\theta)$ 可以表示为:

$$G(\theta) = \begin{bmatrix} m_1 l_{c1} g c_{\theta_1} + m_2 g (l_1 c_{\theta_1} + l_{c2} c_{\theta_2}) \\ m_2 l_{c2} g c_{\theta_2} \end{bmatrix} \quad (2.24)$$

基于惯性矩阵, 科式力矩阵和重力矩阵的已知参数, 通过式 2.21 可求得各个关节所需的驱动力 τ 。下肢外骨骼机器人髋关节和膝关节的驱动力表示为:

$$\begin{aligned} \tau_1 = & \left[m_1 l_{c1}^2 + I_1 + m_2(l_1^2 + l_{c2}^2 + 2l_1 l_{c2} c_{\theta_2}) + I_2 \right] \ddot{\theta}_1 \\ & + \left[m_2(l_{c2}^2 + l_1 l_{c2} c_{\theta_2}) + I_2 \right] \ddot{\theta}_2 - m_2 l_1 l_{c2} s_{\theta_2} (2\dot{\theta}_1 \dot{\theta}_2 + \dot{\theta}_2^2) \\ & + m_1 g l_{c1} c_{\theta_1} + m_2 g (l_1 c_{\theta_1} + l_{c2} c_{\theta_2}) \\ \tau_2 = & \left[m_2(l_{c2}^2 + l_1 l_{c2} c_{\theta_2}) + I_2 \right] \ddot{\theta}_1 + (m_2 l_{c2}^2 + I_2) \ddot{\theta}_2 \\ & + m_2 l_1 l_{c2} s_{\theta_2} \dot{\theta}_1^2 + m_2 g l_{c2} c_{\theta_2} \end{aligned} \quad (2.25)$$

2.4 本章小结

本章首先分析了人体的解剖学结构, 了解了骨骼、关节和肌肉之间的关系以及它们在下肢运动中的作用, 并根据研究需求对矢状面内髋、膝关节运动相关的肌肉群、运动学和动力学数据进行了详细描述。其次, 对下肢运动特征之一的步态相位进行详细解释, 为后面章节的步态识别和外骨骼机器人控制等提供理论基础。最后, 对外骨骼机器人系统进行了基于 D-H 法的运动学建模和基于拉格朗日方程的动力学建模, 为下肢外骨骼机器人实验提供理论支撑。

第3章 基于人体行走的信号获取和处理

在生物电信号中，sEMG 信号比其它信号相比具有分辨率高，信号简单、稳定和容易测量等优点。但是，目前仅使用 sEMG 信号对人体运动意图预测的精度和可靠性仍然值得改进。在之前的研究中，相关研究人员基于 Hill 型肌肉骨骼模型和 sEMG 信号进行了运动量的连续预测^[85, 86]。其基本方法都是基于 sEMG 信号对肌肉骨骼模型的参数进行校准，以最小化估计运动量与实际运动量之间的差异，然后建立 sEMG 信号和运动量之间的映射。但是，Hill 型肌肉骨骼模型的建立基于许多假设和简化，例如恒定的肌肉激活和肌肉线性特征等。而且，Hill 型肌肉骨骼模型是复杂的多维系统，过多的计算和参数识别使其不具有实时性，不适用于实时、连续的人体运动意图识别。为此，基于机器学习算法来建立运动量和 sEMG 信号之间的映射模型可以避免搭建肌肉骨骼模型带来的计算量。其中，常见的是用 CNN、SVR（Support Vector Regression）等机器学习算法直接从 sEMG 信号中提取特征。但利用机器学习算法提取特征存在特征维数高和特征差异性不强等问题，这些问题将导致模型训练变慢而且会降低预测的准确性。相关研究人员用 SVR 等机器学习算法直接对 sEMG 信号进行特征提取并用于关节角度连续预测，其结果的均方根误差在 5° 左右^[87-90]。为了提高膝关节角度连续预测精度，避免通过机器学习算法直接从 sEMG 信号中提取特征，本研究采用数学方法计算了平均绝对值（Mean Absolute Value, MAV），波形长度（Waveform Length, WL），过零次数（Zero Crossings, ZC）和斜率符号变化（Slope Sign Changes, SSC）四个最常用的肌电特征^[91]。

本章设计了人体行走实验，对大腿部位与膝关节运动相关的 4 通道 sEMG 信号、下肢关节角度信号以及足底压力信号进行采集。由于 sEMG 信号存在噪声，且容易受到给定检测条件的影响，所以对其采用滤波和归一化的数据预处理方法；考虑到预处理的 sEMG 信号仍具有很强的模糊性，直接用作膝关节角度预测时精度低，所以对预处理的 sEMG 信号提取了 MAV、WL、ZC 和 SSC 四种时域肌电特征。在后面的章节中，本文将基于本章获取的肌电特征和关节角度信号，进行人体膝关节角度的连续预测。

3.1 sEMG 信号的产生机理和特点

人体运动功能主要由神经系统和运动系统协调配合来完成^[92]。骨骼肌作为运动功能实现的基础,其活动受到各级神经系统的精确调控。每根骨骼肌纤维都对应着 α 运动神经元并被其控制。当神经冲动下行时,运动神经元被激活和募集,相应的骨骼肌完成收缩和兴奋,运动指令被转化为肢体语言^[93]。如图 3.1 所示,单个 α 运动神经元具有支配若干肌纤维的能力,生理学上把这种结构总称为一个运动单元。




图 3.1 肌电信号产生机理

Fig. 3.1 Generation mechanism of EMG signal

皮肤表面电极测得的肌电信号由骨骼肌纤维收缩产生,但最终起源于 α 运动神经元。 α 运动神经元在大脑的神经支配或者外界刺激下引起神经冲动,并沿图 3.1 中所示的运动单元通道到达末端执行器-肌纤维,进而引发动作电位。此过程中,肌纤维在特定运动单元中的响应基本上是一致的,且在不同运动单元间彼此独立;这表明利用传感器测得的皮肤浅表肌电信号本质上是全部运动单元形成的肌纤维响应或者说动作电位在时空层面的综合叠加。sEMG 信号是肌电信号的一种,用来表示体表的所有动作电位。sEMG 信号贯穿于肌肉的收缩动作,在肌肉收缩前 20~200ms 产生^[94, 95]。作为肌肉收缩的控制信号, sEMG 信号与人体期望的运动相关并配和完成各肢体的协同动作;因此将 sEMG 信号用于人体运动意图的详细分析是可行的。此外, sEMG 信号最突出的优势是非侵入性,即不会对人体造成伤害,可按需随时采集,无需专业人员或者医师参与。

虽然，由于受试者和肌肉群的不同，sEMG 信号或多或少存有差异，但仍具备以下共同之处：

（1）作为一种交流电压信号，sEMG 信号幅值及其部分时域特征的幅值与肌肉力基本上成正相关。

（2）作为一种低频信号，原始 sEMG 信号的能量大多分布在 10~1000Hz，超过 300Hz 急剧减少。原始 sEMG 信号的多数频带位于 50~150Hz 的区间。

（3）虽然 sEMG 信号是多个动作电位的叠加，但其电压幅值仍然很微弱，位于 $2\mu\text{V}$ ~ 5mV 之间。对于单个运动单元来说，健康肌肉活动时产生的电位幅值位于 $100\mu\text{V}$ ~ 2mV 之间，但始终低于 5mV 。

（4）sEMG 信号的统计学特征会随时间发生改变，是一种具有很大不确定性的非平稳随机信号。而且，sEMG 信号是多个运动单元产生的频率、传播方向不同的若干动作电位的综合叠加，即使是对同一肌肉不同时间的测量结果也存在差异。

（5）当人体执行的相同动作，即使是受试者不同，相关肌肉群 sEMG 信号波形却很相似，说明这些肌肉群在相同的动作中发出的 sEMG 信号存在规律；而在不同动作中，与动作相关的肌肉群 sEMG 信号波形存在差异。基于人体运动时 sEMG 信号在不同肌肉群的差异性和相同肌肉群的规律性，使得利用与动作相关肌肉群的 sEMG 信号来识别人体意图成为可能。

3.2 人体行走运动信号获取

3.2.1 肌肉选取

人体行走时涉及多个肌肉群的协同作用，大腿部位的肌肉群体积大、动作明显，同时考虑到对小腿截肢残疾患者的适用性，最终选择大腿部位的肌肉群。根据第二章的内容可知，大腿部位的几个主要肌肉包括股直肌、股内/外侧肌、股二头肌、缝匠肌、股薄肌、阔筋膜张肌和半腱肌。其中，股直肌、股内/外侧肌和股二头肌的位置方便传感器安装和信号采集，而且它们与髋关节和膝关节的屈伸运动相关，最终选择了这 4 块肌肉。股直肌、股内/外侧肌和股二头肌在人体下肢的位置如图 3.2 所示。




图 3.2 与运动意图相关肌肉

Fig. 3.2 Muscles related to motion intention

股直肌是位于大腿前部一块长而且硕大的肌肉。股直肌呈梭形，沿大腿直下，其浅层纤维呈双侧翼状排列，深层纤维直行（直肌）至深层腱膜。股直肌穿过膝关节和髋关节，是一种双向作用肌肉，主要功能是屈髋和伸膝。

股四头肌包括股内/外侧肌、股中间肌和股直肌。股内/外侧肌位于大腿前方内侧和外侧，帮助膝盖伸展。股内侧肌开始于股骨前内侧，下部纤维附着在膝盖骨的内侧，控制着膝盖骨的位置。股外侧肌是股四头肌中最大、最强大的肌肉，覆盖着整个大腿外侧，下端通过股四头肌共同的肌腱连接髌骨和胫骨。

股二头肌是大腿后部一块较长的肌肉，起始于自坐骨结节，一直延伸至腓骨近端。股二头肌同时穿过髋关节和膝关节，能在髋关节处帮助大腿伸展和外旋，在膝关节处帮助小腿屈曲、外旋和稳定骨盆。

3.2.2 运动信号采集

基于选定的大腿部位肌肉群，需要使用 sEMG 传感器采集行走过程中的 sEMG 信号。sEMG 信号采集用的是 Delsys 公司的 Trigno EMG 型传感器，它是一种能够无线传输信号的传感器（ $\leq 40\text{m}$ ）。该传感器具有 10~850Hz 带宽且传感器内部延迟小于 500us。sEMG 传感器在受试者股直肌、股/内外侧肌和股二头肌处的布置如图 3.3 所示，本次实验中传感器的采样频率为 1200Hz。sEMG 信号的幅频特性易受皮肤表面状况和采样位置等外界条件影响。因此，在放置 sEMG 传感器之前，需要去除电极安放位置的毛发并用酒精清洁皮肤；且由于肌纤维具有方向，将传感器电极与肌纤维同向放置在其肌腹处可以采集到幅值最高、波形和质量最佳的 sEMG 信号。




图 3.3 传感器布置

Fig. 3.3 Sensor placement

Xsens 公司的 MTw Awinda 是一种便携和无线的 IMU 传感器。该传感器质量为 16g，尺寸为 $47 \times 30 \times 13\text{mm}$ ，传感器延时为 30ms，工作温度范围为 $0 \sim 50^\circ\text{C}$ 。使用该传感器进行关节角度信号采集时的采样频率是 100Hz。为了测量受试者的髋关节和膝关节角度，分别将 IMU 传感器布置在受试者的背部、大腿外侧和小腿内侧。Novel 公司的 Pedar 系统（图 3.4）是一种准确可靠的足底压力分布测量系统，该系统通过多个传感器集成的 Pedar 鞋垫对足底压力进行测量。鞋垫厚度为 1.9mm，尺寸为 $150 \times 100 \times 40\text{mm}$ ，质量为 360g。使用该系统进行足底压力信号采集时的采样频率是 100Hz。



图 3.4 Pedar 足底压力测量系统

Fig. 3.4 The Pedar system

传感器布置完毕后，受试者被要求静止站立 30s 来进行初始化关节角度计算。然后，受试者在跑步机上以各自舒适的速度行走；当计算机发出数据采集的指令后，

各个传感器通过无线传输接收到指令开始同步采集。记录受试者在跑步机上行走 4 次的的数据（图 3.5），每次行走至少 5 分钟，不同实验之间允许休息以避免人体疲劳。如表 3.1 所示，总计 10 名健康成年受试者参加了本次实验。本次实验得到了阿尔伯塔大学伦理委员会的批准并取得了每位受试者的知情同意书。




图 3.5 跑步机行走实验

Fig. 3.5 Treadmill walking experiment

表 3.1 跑步机行走实验中受试者信息

Table 3.1 Participant information on treadmill walking experiment

受试者	P01	P02	P03	P04	P05	P06	P07	P08	P09	P10
年龄	28	23	27	21	26	25	29	30	25	21
身高 (cm)	167	173	175	178	168	168	177	173	180	180
体重 (kg)	70	68	67	70	64	66	50	73	66	89
速度 (m/s)	0.54	0.49	0.49	0.54	0.49	0.54	0.54	0.54	0.63	0.63

3.3 sEMG 信号预处理

sEMG 信号是运动单元产生的若干动作电位在皮肤浅表肌肉的综合叠加，它的幅值在一定程度上体现了神经肌肉活动和人体运动意图。原始 sEMG 信号是噪声信号和 sEMG 信号的叠加，噪声信号大多由工频噪声和运动伪影构成^[96]。对原始

sEMG 信号的特殊处理可以去除噪声，提高与 sEMG 信号定量分析相关的结果的可靠性和有效性。为此，本研究采用了滤波和归一化两种通用的 sEMG 信号预处理方法。

3.3.1 滤波

为了去除信号采集过程中的工频噪声，需要对原始 sEMG 信号进行陷波滤波处理。陷波滤波器如图 3.6 所示，它能去除信号中特定的成分或者频率（陷波频率），使该处幅频响应为 0，而对其他频率没有影响，即：

$$|H(e^{j\omega})| = \begin{cases} 1, \omega \neq \omega_c \\ 0, \omega = \omega_c \end{cases} \quad (3.1)$$

采用高、低截止频率分别为 61Hz 和 59Hz 的陷波滤波能够消除原始 sEMG 信号中 60Hz 的工频噪声。本研究采集的 sEMG 信号频率在 10~500Hz 之间，主频范围在 20~200Hz 之间，采用截止频率为 10Hz 和 300Hz 的带通滤波器（图 3.6）对其进行滤波处理。此带通滤波器的低截止频率能够消除运动或者汗水等造成的基线漂移，去除直流偏置；高截止频率能够去除高频随机噪声和运动伪影，防止采样信号重叠。




图 3.6 陷波滤波和带通滤波器

Fig. 3.6 Notch filter and bandpass filter

3.3.2 信号归一化

除了工频干扰外，sEMG 信号幅值还容易受到给定检测条件的影响，如不同的受试者和电极位置，甚至是同一肌肉位置不同时间的测量结果都有很大不同^[97]。

为了解决 sEMG 信号幅值的这种不确定性，方便比较不同肌肉、不同时间和不同个体之间的肌肉活动，需要对滤波后的 sEMG 信号进行归一化处理。sEMG 信号归一化是指在肌肉活动期间，将 sEMG 信号值表示为校准实验中肌肉活动的百分比；由此，关于 sEMG 信号的解释被转移到具有生物学意义的框架中^[98]。归一化可以解决 sEMG 信号随机性问题，便于对同一受试者的不同肌肉、不同受试者之间或者不同时间的 sEMG 信号进行比较。

sEMG 信号的归一化的常用方法有最大自主收缩法（Maximal Voluntary Contraction Method, MVC）、参考自主收缩法（Reference Voluntary Contraction Method, RVC）、均值动态法（Mean Dynamic Method）和峰值动态法（Peak Dynamic Method）等^[99, 100]。其中，MVC 和 RVC 需要进行额外的实验来获得肌肉的最大或者参考自主收缩，在老年患者或者肌无力患者间不适用；而且，受试者的疲劳、姿态和运动意图等会影响归一化结果的有效性和可靠性。

均值归一化表示单个运动周期内肌肉静止和动作时 sEMG 信号的平均值，可以表示为：

$$X_{norm} = \frac{X - X_b}{X_{mean} - X_b} \quad (3.2)$$

X 表示 sEMG 信号的当前值， X_{norm} 是均值归一化后的值， X_b 表示 sEMG 信号的基线（滤波后为 0）， X_{mean} 表示本次实验中 sEMG 信号均值。经过均值归一化后的 sEMG 信号整体可变性降低，无法给出关于肌肉活动水平的指示。而且，均值归一化容易受到低信噪比系统的影响和产生基线噪声。

峰值归一化是 sEMG 信号归一化处理常用方法，能降低不同受试者之间信号归一化后的差异，还能标记肌肉最活跃的时间段，适用于无法实现最大肌肉力量的临床患者。sEMG 信号的峰值归一化可以表示为：

$$X_{norm} = \frac{X - X_b}{X_{peak} - X_b} \quad (3.3)$$

X 表示 sEMG 信号的当前值， X_{norm} 是峰值归一化后的值， X_b 表示 sEMG 信号的基线（滤波后为 0）， X_{peak} 表示本次实验中 sEMG 信号峰值。

本文采用峰值归一化方法对滤波后的 sEMG 信号进行分析。图 3.7 表示某位受试者股直肌、股内外侧肌和股二头肌 sEMG 信号经过陷波滤波、带通滤波和峰

值归一化处理后的示意图；从图中可以看出经过预处理后的 sEMG 信号幅值在肌肉活动期间变化明显。




图 3.7 峰值归一化后的 sEMG 信号

Fig. 3.7 sEMG signals after peak normalization

3.4 sEMG 信号特征提取

3.4.1 滑动窗口

即使进行滤波和归一化处理，sEMG 信号仍然具有非稳态性。为减少 sEMG 信号随机和瞬态特性的影响，采用带步进的滑动窗口对其进行处理，如图 3.8 所示。对于人机交互系统中膝关节角度连续预测而言，由于 sEMG 信号相较于人体活动

具有 20~200ms 的提前量, 因此滑动窗口步长最大不应该超过 200ms。对于人机交互系统的实时性而言, 在下次步进之前, 即下个窗口内 sEMG 信号采集完成之前, 需要完成 sEMG 信号滤波、归一化、特征提取和预测结果输出等工作。对于滑动窗口宽度来说, 值越大, 读取的 sEMG 信号的平滑度越好, 但会带来信号处理延迟并使信号偏离真实值; 值越小, 会减少延迟但不会过滤高频噪声。由于滤波操作已经去除了 sEMG 信号的高频噪声, 所以应该尽量减小滑动窗口宽度以减小延迟并保证信号精度。相关研究中, 研究人员采用 20 个数据样本长度作为滑动窗口和步长大小来提取肌电特征并得到了较高的预测精度^[101-103]。因此, 本研究选择 20 个数据样本长度的滑动窗口和步长对 sEMG 信号进行处理。




图 3.8 滑动窗口和步长示意图

Fig. 3.8 Schematic diagram of sliding window and step size

3.4.2 特征提取

经过滤波和归一化处理后的 sEMG 信号虽然能够提供肌肉状态的有效信息, 但是仍具有很强的模糊性。将 sEMG 信号直接映射到膝关节角度时, 由于是宏观 sEMG 信号的非线性映射关系会导致结果不准确^[104]。对 sEMG 信号进行特征提取来用于模式识别和意图预测的技术已被广泛应用于动力外骨骼、康复机器人和症状诊断等领域。特征提取是对 sEMG 信号的降维, 以形成相关特征向量, 意图预测的精度几乎完全取决于特征的选择^[105, 106]。

目前, 肌电特征可以在时域、频域和时频域进行分析。相比于其它两种, 时域特征由于在低噪声的环境中有较好的信号分类性能且计算简单, 不需要任何变换就能实现, 在基于 sEMG 信号的控制系统中应用广泛。人体运动中肌肉的收缩和

舒张、与运动相关肌肉开始与结束的时间点和肌肉出力大小都可基于其时域特征进行分析。而且，本文使用的 sEMG 信号预处理方法去除了信号的部分频域信息。因此，本研究决定基于时域方法提取预处理后 sEMG 信号的有效特征。Hudgins 提出了时域内四个最突出的肌电特征，被称为 Hudgins 肌电特征集^[107]；它们分别是 MAV、WL、ZC 和 SSC，上述四个肌电特征被大量用于人体运动意图识别的研究。

肌肉的“工作”和“放松”状态通常由 sEMG 信号的阈值 T_s 来决定，超过阈值则表示肌肉被激活或者处于工作状态。阈值 T_s 能很好地避免由于信号波动、低电平噪声造成的过零次数和斜率符号变化。 T_s 可以通过式 3.4 计算：

$$T_s = \mu + J\sigma \quad (3.4)$$

由于本研究中 sEMG 信号通过滑动窗口进行读取，式中 μ 和 σ 分别表示滑动窗口内 sEMG 信号的均值和标准差。 J 是一个常量，对于常规信号处理通常取 $J=3$ 。

MAV 是滑动窗口内 sEMG 信号绝对值的均值，它表示了肌肉的收缩水平，可以通过以下公式计算得到：

$$M_{AV} = \frac{1}{N} \sum_{n=1}^N |x_n| \quad (3.5)$$

式中， x_n 表示滑动窗口内第 n 个 sEMG 信号， N 表示滑动窗口的长度，本研究中为 20 个样本长度。

WL 与肌肉活动时信号的波动相关，是信号复杂度的一个度量。WL 提供了滑动窗口内 sEMG 信号的频率、持续时间和波形振幅的混合信息，可以由以下公式计算得到：

$$W_L = \sum_{n=1}^N |x_n - x_{n-1}| \quad (3.6)$$

式中， x_n 和 x_{n-1} 分别表示滑动窗口内的第 n 和 $n-1$ 个 sEMG 信号， N 表示滑动窗口的长度为 20 个样本长度。

ZC 是与信号频率相关的简单计算方法。从数学的角度讲，当两个连续的信号样本具有不同的符号时就会发生过零；所以两个相邻信号发生过零时乘积为负，且

二者之差的绝对值需要大于阈值 T_s 。滑动窗口内 sEMG 信号过零次数由以下公式计算得到：

$$f_{ZC}(x_n, x_{n+1}) = \begin{cases} 1, \text{if } x_n * x_{n+1} < 0 \text{ 且 } |x_n - x_{n+1}| > T_s, \\ 0, \text{其它.} \end{cases} \quad (3.7)$$

式中， x_n 和 x_{n+1} 分别表示滑动窗口内的第 n 和 $n+1$ 个 sEMG 信号， T_s 表示滑动窗口内 sEMG 信号的阈值。

SSC 是与信号频率相关的量。sEMG 信号波形的斜率在滑动窗口内改变符号的次数，即斜率符号变化，由以下公式计算得到：

$$f_{SSC}(x_n, x_{n+1}) = \begin{cases} 1, \{x_n > x_{n-1} \text{ 且 } x_n > x_{n+1}\} \text{ 或 } \{x_n < x_{n-1} \text{ 且 } x_n < x_{n+1}\} \\ \text{且 } |x_n - x_{n+1}| \geq T \text{ 或 } |x_n - x_{n-1}| \geq T_s, \\ 0, \text{其它.} \end{cases} \quad (3.8)$$

3.5 信号处理结果

基于 20 个数据样本长度的滑动窗口和步长，对 sEMG 信号进行特征提取最终得到特定的肌电特征。为了直观呈现肌电特征和原始 sEMG 信号之间的关系，绘制了某位受试者 6s 时间内股直肌的原始 sEMG 信号和四种肌电特征示意图，如图 3.9 所示。从图 3.9 中可以看出，原始 sEMG 信号和 MAV、WL 特征之间有明显的映射关系；具体为，两种肌电特征的幅值在肌肉活动剧烈位置出现峰值，而在其它位置趋近于 0。而 ZC 和 SSC 特征与原始 sEMG 信号之间的映射关系无法通过肉眼分别，需要利用机器学习算法识别。

同样计算了相同时间内髌、膝关节角度（图 3.10）。髌关节角度表示为背部和大腿外侧的 IMU 传感器在人体矢状面内角度的差值；膝关节角度表示为大腿外侧和小腿内侧的 IMU 传感器在人体矢状面内角度的差值。从图 3.10 可知，本研究测得的髌、膝关节角度外形与第二章中图 2.12 所示的髌、膝关节角度相似，具体表现为单个步态循环内存在若干相同的波峰和波谷。从图 3.10 可知，髌、膝关节角度具有一定的周期性、规律性和耦合性，二者之间存在明显映射关系。相同时间内采集得到的足底压力如图 3.10 所示，呈周期性变化；对足底压力信号的处理和分析可以得到步态相位，进而为肌肉动作提供指示且可用于下肢外骨骼机器人的控制。




图 3.9 股直肌 sEMG 信号和肌电特征：(a) 原始 sEMG 信号；
(b) MAV；(c) WL；(d) ZC；(e) SSC

Fig. 3.9 Raw sEMG signal and its EMG characteristics of rectus femoris:
(a) raw sEMG signal; (b) MAV; (c) WL; (d) ZC; (e) SSC




图 3.10 髋、膝关节角度和足底压力示意图

Fig. 3.10 Hip, knee angle and plantar pressure

3.6 本章小结

本章首先介绍了 sEMG 信号的产生机理和特点。根据人体解剖学结构选取与膝关节运动相关的肌肉，然后完成数据采集实验。基于 sEMG 信号的相关特点，本章依次使用了陷波滤波、带通滤波和峰值归一化的预处理方法。考虑到预处理后的 sEMG 信号仍具有很强的模糊性，本章采用了滑动窗口对其进行读取，然后提取了 MAV、WL、ZC 和 SSC 四个时域内的特征。在后面章节的人体膝关节角度连续预测研究中，将以本章得到的肌电特征和关节角度为实验数据。而且，本章所用的 sEMG 信号预处理和特征提取方法，能够为 EEG 等其它生物电信号的处理和与之相关的模式识别等任务提供参考。

第 4 章 多源信号融合的膝关节角度预测

人体生物电信号如 EEG 和 sEMG 信号能够很好的反映人体意图且具有时效性。随着生物信息学技术的发展,通过 EEG 和 sEMG 来获取人体运动意图的研究得到广泛应用。然而,目前人体意图识别的研究主要集中于人体动作模式识别方面,即通过机器学习算法识别人体行走、下蹲和上下楼梯等运动模式^[108-111]。在外骨骼机器人领域,识别得到的人体运动模式可以作为指令控制机器人完成相应的运动;但该模式识别技术无法控制外骨骼机器人关节像人体关节一样连续、平稳地运动^[112],极大地影响了人机交互系统高效的协同运动。而且,人体下肢运动的关节角度和角速度、关节力和力矩具有连续性和时序性;为了提高机器人运动控制的协调性和平滑性,对上述运动量的连续预测尤为重要,但是其过程更加复杂,类似的研究也更少。

随着计算机技术的发展,以 CNN、RNN 和 LSTM 网络为代表的深度学习算法逐渐成为人体意图识别领域的研究热点。相对于传统分类算法,深度学习算法适合用来处理带有多层神经细胞的序列信息,能够在存在噪声时解码非静态肌电信号与运动学之间的连续性关系,在时序特征的运动学回归任务中具有很好的鲁棒性和准确性^[113]。基于 sEMG 信号的肌电特征,研究人员多采用 CNN 或者 LSTM 深度学习算法进行关节角度的连续预测^[114,115]。以本研究中膝关节角度连续预测为例,相关研究人员采用单侧下肢 9 通道 sEMG 信号的 MAV、WL、ZC 和 SSC 四种肌电特征作为 LSTM 回归模型的输入^[116,117];但上述研究中采用的传感器数量较多影响人机协同和人体舒适度,同时没有考虑截瘫患者的适用性;而且,如果只采用大腿部位 sEMG 信号肌电特征进行膝关节角度预测的精度较低。考虑人体下肢关节角度的耦合性,本研究首次提出将肌电特征和髌关节角度结合的多源信号融合方法,并将其用于膝关节角度连续预测。

基于上一章中得到的髌关节角度和大腿部位 4 通道 sEMG 信号的肌电特征,本章将时序形式的肌电特征和髌关节角度融合并作为深度学习模型的输入,建立了 CNN、RNN 和 LSTM 三种回归模型分别对膝关节角度进行连续预测。基于三种回归模型,还比较了仅采用髌关节角度、仅采用 sEMG 信号的肌电特征和采用多源信号融合方法在膝关节角度连续预测中的精度。

4.1 卷积神经网络

作为卷积神经网络中最重要的概念之一，感受野（Receptive Field）于 1962 年首次被 Hubel 和 Wiesel 提出^[118, 119]；基于该概念 Fukushima 和 Miyake 随后提出了神经认知机（Neocognitron）^[120]。神经认知机标志着神经网络领域的重要突破，它首次成功地模拟了人脑视觉系统的功能，包括物体识别、视觉辨别和空间感知等。此后，反向传播（Back Propagation Through Time, BPTT）算法在 1974 年被 Paul^[121]等提出。1997 年，Lecun^[122]等在此基础之上提出了 LeNet-5；作为一种经典的 CNN 算法模型，LeNet-5 在手写数字识别任务中表现较好。但是，由于当时缺乏大型训练数据和高性能计算机，CNN 发展缓慢。2006 年，Hinton^[123, 124]等发现具备若干隐藏层的人工神经网络拥有优异的特征学习能力，大大提高了神经网络的鲁棒性能。随后，更深层的网络结构如 Alex Net, VGG-Net, GoogleNet 等被提出，进一步提升了网络的识别精度、适用性和运行速度。

传统的 ANN 算法在网络结构上属于全连接，而 CNN 中的相邻层之间的神经元采用部分连接。部分连接是指网络中某层的某个神经元的信息源于上层的部分而非全部神经元，从而降低了模型复杂度。由于 CNN 部分连接的特性，相较于其它人工神经网络兼具框架简单、鲁棒性强、训练速度快和能够发掘数据潜在特征等优点。目前，CNN 依靠其优势在机器翻译、图像识别等方面被大量使用且卓有成效。基于 CNN 较强的特征挖掘和学习能力，本章将 CNN 模型用于膝关节角度连续预测，并将结果与 RNN 和 LSTM 网络进行对比。

虽然目前 CNN 结构很多，但基本构成大多相同，通常由卷积层、池化层、全连接层和输入、输出层构成^[125]。CNN 的每层都表示一种变换，通过不同的层数和层次的组合，CNN 可以提取出输入的局部特征和全局特征，实现更精确的识别和检测任务。如图 4.1 是一个经典的 CNN 结构，表示了对二维图像的处理过程。模型中的卷积层和池化层循环连接，即当前层的卷积层或者池化层与上一层的池化层或者卷积层相连，之后再连接一个池化层或者卷积层，按此顺序依次类推。卷积层和池化层可以重复多次并最终与全连接层相连。CNN 结构中各层的功能如下：

卷积层：使用一组卷积核对输入进行卷积操作，提取有用的特征。如图 4.1 所示，单个卷积层由多个特征面（Feature Map）构成，每个特征面都可以提取输入数据中的不同特征。通过叠加和组合这些特征面，可以得到更加复杂和抽象的特征表示，从而提高网络的识别能力。单个特征面又由多个神经元构成，每个神经元对应

一个特征面中的一个像素，特征面中的特征表示和提取通过神经元来完成。卷积运算本质上是一种加权平均的操作。在卷积神经网络中，卷积操作通常是针对输入数据和卷积核之间的局部区域进行的。利用卷积操作进行特征信息提取时，单个卷积操作拥有若干卷积核，这增加了卷积层的特征挖掘能力。卷积操作通过滑动窗口的方式让每个卷积核对输入层的各元素执行乘法运算，以此来挖掘输入层的各种特征，经过多层网络挖掘的特征变为高阶特征进而更易被处理和分析。CNN 结构中的卷积操作可以表示为式 4.1：

$$Y = f(\sum_{m=1}^M \sum_{n=1}^N W_{m,n} * x_{i+m,j+n} + b) \quad (4.1)$$

式中， M 和 N 表示卷积核的尺寸， W 表示权重， x 表示输入， b 表示偏置， $f(\cdot)$ 表示一个非线性的激活函数， Y 表示卷积操作后的输出特征面。卷积核上的当前位置通过 m 和 n 进行确定， i 和 j 表示卷积核在输入上滑动了 i 行和 j 列。 $f(\cdot)$ 通常使用 Sigmoid 函数、tanh 函数和 ReLU（Rectified Linear Units）函数。




图 4.1 经典 CNN 结构

Fig. 4.1 Classic CNN structure

公式 4.1 中的卷积操作通常是针对一定大小的滑动窗口进行的，每个滑动窗口对应一个像素。通过对滑动窗口中的像素进行加权计算，可以得到该位置的输出特征值，但滑动窗口可能出现“越界”的问题。例如，当要求特征面的个数和输入的长度一致时，滑动窗口在输入起始和结束的位置无法保证特征面长度。针对该问题，通常使用零填充来控制卷积操作中输出特征面的尺寸。若二维卷积运算中间层特征面尺寸为 $C_{in} * W_{in} * H_{in}$ ，卷积操作后输出特征面尺寸 $C_{out} * W_{out} * H_{out}$ 表示为：

$$\begin{aligned}
 C_{\text{out}} &= R \\
 W_{\text{out}} &= \frac{W_{\text{in}} - K + 2 * P}{S} + 1 \\
 H_{\text{out}} &= \frac{H_{\text{in}} - L + 2 * P}{S} + 1
 \end{aligned} \quad (4.2)$$

式 4.2 中, $K * L$ 表示卷积核大小, R 表示卷积核个数, S 表示滑动窗口的步长, P 表示零填充数量。

以二维卷积(图 4.2)为例对卷积操作的过程进行详细描述。图 4.2 中, 输入特征图和卷积核尺寸分别为 $6 * 6$ 和 $3 * 3$, 3 位零填充, 滑动窗口步长为 2, 无偏置。根据 4.2 式计算得到输出特征图尺寸为 $4 * 4$ 。



图 4.2 二维卷积运算示意图

Fig. 4.2 Schematic diagram of 2D convolution operation

激活函数 $f(\cdot)$ 能将卷积层或者全连接层的输出转化为非线性的形式, 增强网络对复杂模式和特征的学习能力。CNN 中通常采用以下几种激活函数:

(1) Sigmoid 函数




图 4.3 Sigmoid 函数及其导数

Fig. 4.3 Sigmoid function and its derivative

Sigmoid 函数的表达式为：

$$\sigma(x) = \frac{1}{1 + e^{-x}} \quad (4.3)$$

由图 4.3 可知该函数是连续可微，且能将输出映射到 0~1 之间。具体为，当输入逼近 $+\infty$ 或 $-\infty$ 时，经过 Sigmoid 变换后的输出逼近 1 或 0。基于 Sigmoid 函数的这一数学特征，可以判断神经网络内部信息能否向后传达；尤其是当网络层数较少时，能够充分地发挥其非线性激活的作用^[126]。而且，由于 Sigmoid 函数的连续和平滑特性，能平滑地将线性变换的结果转化为非线性的输出，从而防止神经网络训练中的梯度消失。

反向传播时，Sigmoid 函数导数表达式如下：

$$\dot{\sigma}(x) = \left(\frac{1}{1 + e^{-x}} \right)' = \sigma(x)(1 - \sigma(x)) \quad (4.4)$$

由图 4.3 可知，当函数输出逼近 0 或 1 时，其导数逼近 0，该现象被称为梯度消失。梯度消失会对反向传播算法产生影响，因为反向传播算法依赖于梯度计算来更新神经网络的权重参数。当梯度消失发生时，神经网络中某些层的梯度将变得非常小，导致这些层的权重参数无法得到有效的更新；这可能会导致神经网络无法收敛，或者需要很长时间才能收敛。

(2) tanh 函数

tanh 函数能将输出映射到-1~+1 之间，是 0 均值函数；它解决了 Sigmoid 函数恒正导致梯度震荡问题，效果比 Sigmoid 函数要好。tanh 函数的表达式为：

$$\tanh = \frac{e^x - e^{-x}}{e^x + e^{-x}} \quad (4.5)$$




图 4.4 tanh 函数及其导数

Fig. 4.4 tanh function and its derivative

(3) ReLU 函数

为了改善激活函数造成的梯度消失问题,可以用 ReLU (Rectified Linear Unit) 函数来代替 Sigmoid 函数和 tanh 函数。ReLU 函数及其导数都不包含复杂的数学计算,能减少计算时间。此外,ReLU 函数在 $x \leq 0$ 时函数值为 0,导致局部神经元输出为 0,即未被激活;该特性实现了神经网络的稀疏性,降低了内部参数的相互关联,在一定程度上改善过拟合并加快网络训练速度。




图 4.5 ReLU 函数及其导数

Fig. 4.5 ReLU function and its derivative

池化层:虽然 CNN 在卷积运算过程中采用卷积核在一定程度上降低了网络参数数量并减少了网络的复杂度,但实际的网络连接和参数数量仍然不少。池化层,又名下采样层,能够遵循特定规则对特征执行下采样,使得输出的特征图尺寸变小,可以实现数据的压缩并在一定程度上确保特征尺度不发生改变。假设 E_i 和 E_{i+1} 分别表示池化层的输入和输出,池化过程由以下公式表示:

$$E_{i+1} = s(E_i) \quad (4.6)$$

式 4.6 中, $s(\cdot)$ 表示池化函数,常见的包括均值池化 (Average-pooling) 和最大值池化 (Max-pooling) 等^[127]。以二维池化 (图 4.6) 为例对池化操作的过程进行详细描述。最大值池化是指将选定区域内特征元素最大值作为输出,舍弃其它特征元素;图 4.6 右上表示步长为 2 的 2×2 大小的最大值池化结果。均值池化是指计算选定区域的均值作为输出;图 4.6 右下表示步长为 2 的 2×2 大小的均值池化结果。




图 4.6 两种池化方式示意图

Fig. 4.6 Schematic diagram of two pooling methods

全连接层：也称为密集连接层，是神经网络中的一种基本层类型。它的作用是将上一层的所有神经元与当前层的所有神经元相互连接，形成一个全连接的神经网络结构。全连接层通常出现在卷积神经网络的最后一层或者全连接神经网络中，用于对前面的特征进行分类或者回归。为了有效地降低神经网络的过拟合风险，通常在全连接层间使用 Dropout 正则化技术^[128]。Dropout 技术是指在训练时随机忽略一部分神经元，从而减少神经网络中的参数数量和复杂度，使得网络鲁棒性更好、泛化能力更强。图 4.7 为全连接层不使用和使用 Dropout 技术的示意图， $n-1$ 层在 CNN 中通常表示池化层输出， n 和 $n+1$ 层均表示全连接层。图 4.7 右侧的阴影表示 n 层的某个神经元被 Dropout。




图 4.7 Dropout 前、后的全连接层

Fig. 4.7 Full connection layer before and after Dropout

输出层：位于神经网络框架的最后，可计算神经网络的损失，在本研究中用于最终的回归预测。网络损失通过输出层中的损失函数（Loss Function）来计算。在训练过程中，网络会不断根据损失函数计算出来的梯度信息进行参数更新，使得网络可以逐渐学习到数据之间的特征，提高预测准确率。当网络损失值降到一个较小的阈值时，认为网络已经收敛，可以停止训练并使用该网络进行预测。在回归问题中，神经网络的输出通常是一个实数或者一组实数，代表了对输入数据的预测值；本研究中输出层的输出节点即为网络的预测值。由于本研究属于需要精确预测的回归任务，采用均方误差（Mean Squared Error, MSE）作为损失函数，MSE 表示为：

$$M_{SE}(y, \hat{y}) = \frac{\sum_{i=1}^n (y_i - \hat{y}_i)^2}{n} \quad (4.7)$$

式中， y_i 和 $\hat{y}_i$ 分别为第 i 个样本的真实值和预测值， n 为总样本数。

4.2 递归神经网络和长短期记忆网络

进行人体意图预测的肌电特征、关节转角和力矩等运动量是基于时间序列的向量。递归神经网络与卷积神经网络相比具有时序性，更适合处理与时间序列相关的回归任务^[129]。RNN 起源于上世纪八十年代左右，经过发展逐步成为深度学习领域解决时序问题最热门的算法之一。1997 年 Hochreiter 和 Schmidhuber 提出了 LSTM 网络^[130]，LSTM 网络是 RNN 的一种。LSTM 网络模型通过门控机制避免了无用信息的累积，从而能解决 RNN 在处理长序列数据时存在的长期依赖问题。而且，LSTM 网络拥有更强的梯度传播能力和更好的泛化能力，可以避免 RNN 的梯度消失和梯度爆炸问题。因此，LSTM 网络与 RNN 相比在处理时间序列问题时具有更好的鲁棒性，在语音识别、机器问答、机器翻译等任务中得到了广泛的应用。

4.2.1 RNN 模型

RNN 的主要特点是具有记忆功能，可以记住之前的信息，并将其用于当前的计算^[131]。与传统机器学习方法不同，RNN 不需要过多的先验知识即可从数据中自动提取特征；与传统的神经网络不同，其特有的链式结构允许信息从上一时刻传递到下一时刻，并且这些信息通过循环结构能够持续保存。

RNN 模型整体框架如图 4.8 所示，把左侧的循环框架在时间步上展开得到右侧的展开图^[132]。图 4.8 中， x 表示网络的输入， t 时刻的输入记作 x_t ； S 表示隐藏层状态， t 时刻的隐藏层状态记作 S_t ， S_t 储存了 t 时刻前输入序列的相关信息。从展开图可以看出， S_t 是对时间序列的建模，它既依赖于 $t-1$ 时刻的“记忆”，又依赖于当前时刻的输入。 S_t 可以通过以下公式计算得到：

$$S_t = f(Ux_t + WS_{t-1}) \quad (4.8)$$

式中， $f(\cdot)$ 为隐藏层的激活函数。 t 时刻 RNN 的输出记作 O_t ，通过以下公式计算得到：

$$O_t = g(VS_t) \quad (4.9)$$

式中， $g(\cdot)$ 表示输出层的激活函数。




图 4.8 RNN 模型结构框架及其展开图

Fig. 4.8 RNN model structure and its expansion diagram

RNN 训练通常使用反向传播算法，其本质是采用梯度下降法对参数 U ， W ， V 进行训练。由于 RNN 具有时序结构，因此在反向传播过程中需要对整个序列进行展开（即将整个序列按时间展开成一条长向量），然后进行前向和反向传播。

在对时间序列建模时，虽然 RNN 理论上可以保存任意长度时间序列信息的“记忆”，但是 RNN 中链式结构的循环机制会因为梯度消失和梯度爆炸所引起的短期记忆而导致网络训练变得愈发困难；即随着循环次数的增加，训练时的梯度只能在有限的时间序列中向前传递，长时间序列中参数不再更新会导致网络失去学习能力；这使得基于历史数据建模的 RNN 只能利用有限的历史数据，导致了预测

的不准确。改进后的 RNN 即 LSTM 网络，一定程度上改善了 RNN 短期记忆问题，在基于人体生理信号的模式识别方面应用更广泛。

4.2.2 LSTM 网络模型

LSTM 网络保持了经典 RNN 的链式结构，但内部循环模块更为复杂，是由具备四层交互单元的网络层组成^[133]。邻近的 LSTM 单元彼此间通过隐藏状态实现信息的相互传递，此类信息归为短期信息。

如图 4.9 所示，在 LSTM 网络中，细胞状态可以由穿过细胞单元顶端的水平线表示，该细胞状态横贯于整个链式结构中，归为长期信息。为了保证网络传输过程中信息的不变性，作用在细胞状态上的指令都是简单的线性操作。LSTM 网络的最大特点是基于门控单元来判断是否对细胞状态信息进行保留，而门控单元的正常工作离不开激活函数。LSTM 网络中常用的激活函数包含 Sigmoid、tanh 和 ReLU 函数，激活函数的选择取决于模型的应用场景和需求。




图 4.9 LSTM 模型结构

Fig. 4.9 LSTM model Structure

每个 LSTM 单元都包含遗忘门、输入门和输出门三个门控单元（图 4.10）。门控单元通过执行不同的张量运算，可以从隐藏状态中学习要保留或者删除的信息。LSTM 门控单元使用 Sigmoid 函数作为激活函数，函数的输出被用来控制门控单元的输出。具体为，当 Sigmoid 函数输出为 1 表明输入的细胞状态信息全部保留，输出为 0 表明状态信息被删除且不会向后传递，输出为 0~1 表明状态信息的部分删除和保留。

f_t 、 i_t 和 o_t 为门控单元， h_{t-1} 和 h_t 为上一时刻和当前时刻隐藏层状态， C_{t-1} 和 C_t 为上一时刻和当前时刻细胞状态。LSTM 网络的具体实现是，根据上一时刻隐藏输出状态 h_{t-1} ， t 时刻之前的细胞状态 C_{t-1} 及当前时刻输入 x_t ，计算得到遗忘门 f_t 、输入门 i_t 、输出门 o_t 及候选向量 $\tilde{C}_t$ ：




图 4.10 LSTM 单元

Fig. 4.10 LSTM unit

$$\begin{aligned}
 f_t &= \sigma(x_t U^f + h_{t-1} W^f) \\
 i_t &= \sigma(x_t U^i + h_{t-1} W^i) \\
 o_t &= \sigma(x_t U^o + h_{t-1} W^o) \\
 \tilde{C}_t &= \tanh(x_t U^s + h_{t-1} W^s)
 \end{aligned} \tag{4.10}$$

上式中, U^f 、 U^i 、 U^o 和 U^s 分别为三种门控单元和新细胞状态对于当前时刻细胞输入 x_t 的权重; W^f 、 W^i 、 W^o 和 W^s 分别为三种门控单元和新细胞状态对于上一时刻细胞隐藏状态输出 h_{t-1} 的权重。三种门控单元通过 $\sigma(\cdot)$ 即 Sigmoid 函数进行更新, 候选向量通过 $\tanh(\cdot)$ 即 tanh 函数进行更新。遗忘门 f_t 决定了细胞状态中删除和保留哪部分信息; 输入门 i_t 决定了细胞状态中要更新的数值信息; 输出门 o_t 决定了细胞状态中需要输出到下个 LSTM 单元信息; 候选向量 $\tilde{C}_t$ 是将要添加到细胞状态的候选信息。基于遗忘门、输入门、上一时刻细胞状态和候选向量可实现全局状态的更新进而获得新的细胞状态 C_t :

$$C_t = \sigma(f_t * C_{t-1} + i_t * \tilde{C}_t) \tag{4.11}$$

其中, 此刻的细胞状态 C_t 是 C_{t-1} 和 $\tilde{C}_t$ 的加权和。 $i_t * \tilde{C}_t$ 为添加到全局细胞状态的新状态, $f_t * C_{t-1}$ 为从全局细胞状态中删除的细胞状态信息。基于细胞状态 C_t , 当前时刻 LSTM 单元的输出可以表示为:

$$h_t = \tanh(C_t) * o_t \tag{4.12}$$

式 4.12 中, 细胞状态 C_t 首先被 $\tanh$ 函数映射到 $-1 \sim +1$ 之间; 映射后的值乘以输出门的输出来决定哪些信息将传递给下个 LSTM 单元。

4.3 膝关节预测算法模型

4.3.1 模型输入预处理

基于上一章提取的 4 通道 sEMG 信号肌电特征和髌关节、膝关节角度, 构造输入矩阵 x (式 4.13) 作为 CNN、RNN 和 LSTM 三种回归模型的输入。同时, 为对比仅采用肌电特征或者仅采用髌关节角度对膝关节预测结果的影响, 还分别构造了输入矩阵 x_1 (式 4.13) 和 x_2 (式 4.13)。




图 4.11 膝关节预测模型的输入

Fig. 4.11 Input of knee joint prediction model

$$\begin{aligned} x &= f_1 \dots f_{16}, \theta_h + \theta_k \\ x_1 &= f_1 \dots f_{16} + \theta_k \\ x_2 &= \theta_h + \theta_k \end{aligned} \quad (4.13)$$

式中, $f_i, i=1, \dots, 16$ 表示从 4 通道 sEMG 信号中总共提取到的 16 个时域特征, θ_h 和 θ_k 分别表示髌关节和膝关节角度。根据机器学习中标签和特征的定义, 输入矩阵的最后一列, 即膝关节角度属于标签向量, 其余列属于特征向量。

实验总共采集了 10 名健康受试者的跑步机行走数据，分别建立各自的膝关节角度预测模型。根据第三章内容可知，通过滑动窗口对 sEMG 信号进行了读取操作。该处理会使信号样本数量减少，且 IMU 传感器(100Hz)和肌电传感器(1200Hz)采样频率不同。为了使髌、膝关节角度和肌电特征具有相同的样本长度，需要对髌、膝关节角度进行下采样处理。数量为 N 次的下采样过程可以表示为：

$$\theta_{down}(n) = \frac{1}{N} \sum_{i=nN-N+1}^{nN} \theta(i) \quad (4.14)$$

式中， $\theta_{down}(n)$ 是下采样后的髌、膝关节角度信号。

考虑到下采样后关节角度曲线的平滑性减小，采用滑动平均滤波（Simple Moving Average）^[134]对 $\theta_{down}(n)$ 进行平滑处理。

$$\begin{aligned} \theta_{SMA} &= \frac{\theta_{down}(n-k+1) + \theta_{down}(n-k+2) + \dots + \theta_{down}(n)}{k} \\ &= \frac{1}{k} \sum_{i=n-k+1}^n \theta_{down}(i) \end{aligned} \quad (4.15)$$

式中， $\theta_{down}(n)$ 代表下采样后关节角度， k 代表滑动窗口大小和加权平均系数， n 个数据点的滑动平均滤波本质上是前 k 个数据点的平均值。 k 值越大曲线越平滑，同时 θ_{SMA} 与原数据的差异越大，即精度越低。平滑后得到的数据 θ_{SMA} 将替代原有数据添加到整体数据序列中，因此不需要每次都进行完整求和。

回归模型的特征向量包含髌关节角度和四种肌电特征，它们之间具有不同的单位和尺度。输入变量之间的尺度差异可能会增加建模问题的难度，而且大的输入值（例如数百、数千的单位）可能导致学习大权重值的模型，进而在学习过程中表现不佳且会导致较高的泛化误差，在回归问题中还可能出现梯度爆炸和学习中断的风险。对特征向量进行归一化处理的目的是使得数据尺度相同，从而提高模型的训练速度、泛化能力和稳定性^[135]。若 u 和 l 分别表示归一化后数据新的上下限，对原数据 x 的归一化过程表示为：

$$x' = \frac{x - x_{\min}}{x_{\max} - x_{\min}}(u - l) + l \quad (4.16)$$

本研究中 u 和 l 分别取 1 和 0, 即将原数据缩放到 0~1 之间, 得到归一化后的新数据 x' 。 $x_{\max}$ 和 $x_{\min}$ 分别为原特征向量的上、下限。式 4.16 是一个线性变换, 保持了归一化后原特征向量值之间的距离比。

同时, 为了保证模型较好的泛化能力, 将每位受试者的输入矩阵划分为训练集, 验证和测试集^[136]。训练集用来训练模型, 让其学习输入和输出的映射关系, 占总样本数量的 80%。验证集占 15%, 用来评估模型的训练水平, 比如预测的误差和分类器的精度等, 以此来选择验证集上表现最优的模型。测试集占 5%, 是较验训练好的模型在新输入数据(测试数据)的性能, 即模型的稳定性、鲁棒性和泛化误差等。

4.3.2 膝关节预测回归模型

基于 CNN、RNN 和 LSTM 网络在处理人体生理学信号方面的优势和大量应用, 在本研究中分别对其建模然后进行膝关节角度预测, 探索预测精度最高的网络模型。模型建模过程中, 三种网络结构参数和训练过程中的参数对最终性能都有影响。因此确定模型参数前, 论文经过大量训练实验, 选择最佳性能参数作为最终的参数。由于本文主要研究多源融合方法的预测效果, 此处对参数训练的详细过程不做展开, 参数的具体值见下文的算法模型。

构建的膝关节预测 RNN/LSTM 模型(图 4.12)包含输入层、输出层、RNN/LSTM 层、展平层和全连接层。通过多源信号融合方法进行膝关节角度预测时, 输入层包含 17 个节点, 分别对应了输入矩阵的 17 个特征列。RNN/LSTM 层 1 配置了 32 个节点, 用来提取输入信号的特征。RNN/LSTM 层 2 节点数量与 RNN/LSTM 层 1 相同, 但双层结构通过增加网络深度的方式提高了模型的表达能力和泛化性能。展平层可以将多维的输入转化成一维传递给全连接层。全连接层 1、2 的参数设置为 128 和 32 个节点, 用于将非线性引入到网络中, 使得网络可以学习输入值和输出值之间的关系; 全连接层 3 的参数设置为 1 个节点, 用于将输出向量转换成标签向量, 即膝关节角度, 方便后续计算模型训练的损失。全连接层 1 和 2 间的 Dropout 率为 0.2。全连接层 2 和 3 间的 Dropout 率为 0.1。图 4.12 中全连接层的阴影单元表示通过 Dropout 技术去除的网络节点。




图 4.12 膝关节预测 RNN/LSTM 模型

Fig. 4.12 RNN/LSTM model for knee joint prediction

构建的膝关节预测 CNN 模型（图 4.13）包含输入层、输出层、卷积层、池化层、展平层和全连接层。卷积层 1 配置了 64 个节点，卷积核为 5，滑动窗口步长为 1。池化层 1 采用步长为 1，内核为 2 的最大值池化。双卷积层的配置具有提取多层次特征、减小特征图尺寸、增加非线性和参数共享的优点。卷积层 2 配置了 32 个节点，卷积核为 3，滑动窗口步长为 1。池化层 2 结构与池化层 1 相同。全连接层 1、2 的参数设置为 128 和 1 个节点，第一个全连接层将非线性引入到网络中，第二个全连接层将输出向量转换成标签向量。两个全连接层之间的 Dropout 率为 0.2。图 4.13 中全连接层的阴影单元表示通过 Dropout 技术去除的网络节点。




图 4.13 膝关节预测 CNN 模型

Fig. 4.13 CNN model for knee joint prediction

4.4 膝关节预测结果与分析

4.4.1 评估标准

本研究采用了平均绝对误差 (Mean Absolute Error, MAE)、均方根误差 (Root Mean Square Error, RMSE) 和 R^2 分数 (R-Squared Score) 三种评估标准来定量评估三种回归模型的膝关节角度连续预测精度, 以上三种评估标准被广泛用于基于机器学习的人体关节回归预测中^[137-139]。

(1) 平均绝对误差

MAE 用来衡量模型预测结果与真实结果之间差异, 表示为:

$$M_{AE} = \frac{\sum_{i=1}^n |y_i - \hat{y}_i|}{n} \quad (4.17)$$

式中, y_i 为第 i 个样本的真实值, $\hat{y}_i$ 是对应的预测值, n 为总样本数。

(2) 均方根误差

RMSE 也常被用来衡量模型预测结果与真实结果之间差异, 表示为:

$$R_{MSE} = \sqrt{\frac{\sum_{i=1}^n (y_i - \hat{y}_i)^2}{n}} \quad (4.18)$$

(3) R^2 分数

R^2 又称决定系数, 是一种用于评价回归模型预测能力的指标。 R^2 分数的范围在 0~1 之间, 越逼近 1 越表明模型预测精度高。 R^2 分数可以通过以下公式进行定义:

$$\begin{aligned} R_{\text{squared}} &= 1 - \frac{SSE}{SST} \\ SSE &= \sum_{i=1}^n (y_i - \hat{y}_i)^2 \\ SST &= \sum_{i=1}^n (y_i - \bar{y})^2 \end{aligned} \quad (4.19)$$

式中, SSE 表示真实值和预测值的残差平方和, SST 表示真实值与平均值的残差平方和。 SSE 反映了模型预测值与真实值之间的差异程度, 其值越小表示模型对

数据的拟合程度越好。 SST 反映了真实值与其平均值之间的差异程度，其值越大表示真实值的方差越大，数据点越分散。

4.4.2 结果与分析

本研究将 10 名受试者的多源融合信号、sEMG 信号肌电特征和髌关节角度数据样本分别按顺序分配 80% 为训练集，15% 为验证集和 5% 为测试集。考虑到关节角度具有时序性，未对数据进行打乱。为了方便对比模型的预测效果，CNN、RNN 和 LSTM 回归模型在不同预测方法中均采用了相同的训练参数，具体参数设置如表 4.1 所示：

表 4.1 模型参数设置

Table 4.1 Model parameter settings

参数	LSTM/RNN/CNN 模型
批次大小	64
是否打乱数据	否
优化器	Adam
学习率	0.001
迭代次数	100

表 4.1 中，批次大小、学习率和迭代次数经过手动调整并通过实验验证其能在基于多源信号融合方法的 CNN、RNN 和 LSTM 模型中发挥最好的效果。图 4.14 表示某位受试者基于多源信号融合的 CNN 和 LSTM 模型在表 4.1 的训练参数下膝关节预测均方误差变化趋势。从图 4.14 可知，两种模型在膝关节角度连续预测中的均方误差随着迭代周期的增加而减小，经过 80 个周期的迭代后趋近于稳定；在 100 个迭代周期后，LSTM 模型的验证集与训练集均方误差逐渐增大。因此，为了抑制模型训练中的过拟合，训练可在迭代 100 个周期后停止。

为了得到训练效果最好模型，首先将每位受试者的数据用 CNN、RNN 和 LSTM 模型分别训练 10 次，然后为每位受试者选择 10 次中的最优结果，即他们的最优预测模型。根据 10 位受试者最优预测模型，得到基于多源信号融合方法预测、基于 sEMG 信号预测和基于髌关节预测的平均绝对误差结果如表 4.2 所示。




图 4.14 不同迭代周期下 MSE 变化趋势

Fig. 4.14 Trends of MSE under different iteration cycles

表 4.2 基于不同预测方法的模型平均绝对误差 (°)

Table 4.2 MAE of models based on different prediction methods (°)

受试者	基于多源信号融合			基于 sEMG 信号			基于髌关节		
	CNN	LSTM	RNN	CNN	LSTM	RNN	CNN	LSTM	RNN
P1	2.58	2.67	2.65	3.71	3.95	3.72	4.35	5.34	5.56
P2	2.31	2.06	3.15	3.94	3.81	3.94	2.84	2.75	2.9
P3	2.25	2.06	2.12	4.37	3.97	4.05	1.95	1.92	1.94
P4	1.49	1.40	4.13	5.27	4.93	4.99	1.36	1.39	1.41
P5	1.66	1.42	1.47	3.07	2.67	2.94	1.65	1.55	1.62
P6	3.45	3.08	3.29	3.48	3.26	3.33	4.36	4.12	5.04
P7	1.88	1.81	1.84	2.55	2.35	2.46	2.04	1.99	2.07
P8	2.12	1.86	1.88	5.24	4.34	4.66	1.78	1.64	1.8
P9	1.98	1.78	1.87	2.78	2.52	2.55	2.40	2.18	2.25
P10	1.26	1.22	1.23	2.20	1.94	2.03	1.18	1.16	1.26
均值	2.10	1.94	2.36	3.66	3.37	3.47	2.39	2.40	2.59

从表 4.2 中的均值可以看出, 在 CNN 模型中, 基于多源信号融合的膝关节角度预测平均绝对误差比基于 sEMG 信号的预测和基于髌关节的预测分别减少了 42.62%和 12.13%; 在 LSTM 模型中, 该平均绝对误差分别减少了 42.43%和 19.17%;

在 RNN 模型中，该平均绝对误差分别减少了 31.99%和 8.88%。且从表 4.2 中可以看出，即使是采用相同的预测方法和同类模型，不同受试者之间的预测结果也有较大差别。

根据 10 位受试者最优预测模型，得到基于多源信号融合方法、基于 sEMG 信号预测和基于髌关节预测的均方根误差结果如表 4.3 所示。从表 4.3 中的均值可以看出，在 CNN 模型中，基于多源信号融合的膝关节角度预测均方根误差比基于 sEMG 信号的预测和髌关节的预测分别减少了 40.31%和 8.13%；在 LSTM 模型中，该均方根误差分别减少了 41.84%和 16.77%；在 RNN 模型中，该均方根误差分别减少了 40.57%和 19.22%。

表 4.3 基于不同预测方法的模型均方根误差 (°)

Table 4.3 RMSE of models based on different prediction methods (°)

受试者	基于多源信号融合			基于 sEMG 信号			基于髌关节		
	CNN	LSTM	RNN	CNN	LSTM	RNN	CNN	LSTM	RNN
P1	3.53	3.77	3.64	5.14	5.35	5.35	5.58	6.63	7.18
P2	3.14	2.90	3.15	5.20	5.00	5.18	4.22	4.05	4.20
P3	3.31	2.97	3.05	5.92	5.38	5.52	2.76	2.84	2.86
P4	2.31	2.05	2.19	7.11	6.73	6.82	2.05	2.09	2.11
P5	2.49	2.06	2.14	4.58	4.29	4.42	2.39	2.24	2.34
P6	4.99	4.46	4.76	4.97	4.61	4.75	6.00	5.76	6.87
P7	2.62	2.47	2.53	3.85	3.62	3.64	2.66	2.61	2.74
P8	3.51	2.98	3.21	7.34	6.37	6.58	2.63	2.50	2.67
P9	2.86	2.49	2.61	3.99	3.66	3.71	3.27	3.04	3.13
P10	1.70	1.66	1.67	3.02	2.82	2.86	1.69	1.65	1.84
均值	3.05	2.78	2.90	5.11	4.78	4.88	3.32	3.34	3.59

根据 10 位受试者最优预测模型，得到基于多源信号融合方法、基于 sEMG 信号预测和基于髌关节预测的 R^2 分数结果如表 4.4 所示。从表 4.4 中的均值可以看出，在 CNN 模型中，基于多源信号融合的膝关节角度预测 R^2 分数比基于 sEMG 信号的预测增加了 0.12，比基于髌关节的预测增加了 0.02；在 LSTM 模型中，基

于多源信号融合方法的 R^2 分数与二者相比分别增加了 0.11 和 0.03；在 RNN 模型中，基于多源信号融合方法的 R^2 分数与二者相比分别增加了 0.11 和 0.05。

表 4.4 基于不同预测方法的模型 R^2 分数
Table 4.4 R^2 of models based on different prediction methods

受试者	基于多源信号融合			基于 sEMG 信号			基于髌关节		
	CNN	LSTM	RNN	CNN	LSTM	RNN	CNN	LSTM	RNN
P1	0.90	0.89	0.90	0.79	0.78	0.78	0.76	0.66	0.60
P2	0.93	0.94	0.93	0.80	0.81	0.8	0.87	0.88	0.87
P3	0.91	0.93	0.92	0.72	0.77	0.77	0.94	0.94	0.93
P4	0.97	0.97	0.97	0.69	0.72	0.71	0.97	0.97	0.97
P5	0.96	0.97	0.97	0.86	0.88	0.87	0.96	0.97	0.96
P6	0.86	0.89	0.87	0.86	0.88	0.88	0.80	0.82	0.74
P7	0.95	0.95	0.95	0.89	0.90	0.90	0.95	0.95	0.94
P8	0.92	0.94	0.93	0.66	0.75	0.73	0.96	0.96	0.96
P9	0.94	0.96	0.95	0.89	0.91	0.90	0.93	0.94	0.93
P10	0.97	0.97	0.97	0.91	0.92	0.92	0.97	0.97	0.97
均值	0.93	0.94	0.94	0.81	0.83	0.83	0.91	0.91	0.89

绘制三种回归模型在基于多源信号融合、基于 sEMG 信号和基于髌关节角度预测的 MAV、RMSE 和 R^2 分数结果分别如图 4.15、图 4.16 和图 4.17 所示。从图 4.15、图 4.16 和图 4.17 中可知，三种评估标准都能说明基于多源信号融合方法要优于单独使用髌关节角度或者单独使用 sEMG 信号的预测方法。单独使用 sEMG 信号进行膝关节预测时，CNN、RNN 和 LSTM 网络的 MAV 结果分别是 $3.36 \pm 1.06^\circ$ 、 $3.47 \pm 0.98^\circ$ 和 $3.37 \pm 0.98^\circ$ ；RMSE 结果分别是 $5.11 \pm 1.38^\circ$ 、 $4.88 \pm 1.27^\circ$ 和 $4.78 \pm 1.24^\circ$ ； R^2 分数的结果分别是 0.81 ± 0.09 、 0.83 ± 0.08 和 0.83 ± 0.07 ；其中 RMSE 的结果与相关研究中得到的结果近似，但是本研究使用的 sEMG 信号通道数更少。单独使用髌关节角度进行膝关节预测时，CNN、RNN 和 LSTM 网络的 MAV 结果分别是 $2.39 \pm 1.14^\circ$ 、 $2.59 \pm 1.50^\circ$ 和 $2.40 \pm 1.33^\circ$ ；RMSE 结果分别是 $3.32 \pm 1.47^\circ$ 、 $3.59 \pm 1.92^\circ$ 和 $3.34 \pm 1.65^\circ$ ； R^2 分数的结果分别是 0.91 ± 0.08 、 0.89 ± 0.12 和 0.91 ± 0.10 ；该结果比单独使用 sEMG 信号预测的结果要好，这说明下肢运动时

髌关节和膝关节角度存在较强的相关性。从基于髌关节角度的预测结果同样可以看出，CNN 和 LSTM 网络得到膝关节预测角度差别不大。使用多源信号融合方法进行膝关节预测时，CNN、RNN 和 LSTM 网络的 MAV 结果分别是 $2.01 \pm 0.62^\circ$ 、 $2.36 \pm 0.92^\circ$ 和 $1.94 \pm 0.58^\circ$ ；RMSE 结果分别是 $3.05 \pm 0.89^\circ$ 、 $2.90 \pm 0.88^\circ$ 和 $2.78 \pm 0.84^\circ$ ； R^2 分数的结果分别是 0.93 ± 0.03 、 0.94 ± 0.03 和 0.94 ± 0.03 ；RMSE 的结果相比于单独使用 sEMG 信号分别减少了约 40%、41% 和 42%，这说明髌关节角度能够极大地提高预测精度。从基于 sEMG 信号和多源信号融合方法预测结果可以看出，三种回归模型中 LSTM 网络的预测结果最好，说明 LSTM 网络在处理肌电特征时具有更好的性能。基于 SVR 模型，相关研究人员对 6 通道的 sEMG 信号提取了均方根、小波系数和排列熵（Permutation Entropy）三种肌电特征并将其用于膝关节角度连续预测，得到的 RMSE 为 3.73° ^[140]；相关研究人员提取了 8 通道的均方根等特征并用 LSTM 网络进行膝关节角度预测，得到的 RMSE 为 3.47° ^[141]；基于 CNN 和 LSTM 模型，相关研究人员使用 8 通道 sEMG 信号中的 WL 和 MAV 两个肌电特征对膝关节角度进行连续预测，得到的 R^2 分数为 0.905 ± 0.0115 ，RMSE 为 $3.0 \pm 0.1896^\circ$ ^[142]；Moghadam^[143]等基于机器学习回归模型对下肢的运动学、动力学和肌肉力进行预测，得到的膝关节角度 MAE 为 5.27° ，RMSE 为 7.07° 。与上述研究相比，本研究不但减少了附着在人体的传感器数量，还提高了膝关节连续预测的精度，且只采用人体大腿处的 sEMG 信号在人机交互的实际应用中能发挥更好的效果。




图 4.15 膝关节预测结果的 MAV(one-way ANOVA, $P < 0.05$)

Fig. 4.15 MAV of knee prediction results



图 4.16 膝关节预测结果的 RMSE(one-way ANOVA, $P < 0.05$)

Fig. 4.16 RMSE of knee prediction results

图 4.17 膝关节预测结果的 R^2 分数(one-way ANOVA, $P < 0.05$)Fig. 4.17 R^2 of knee prediction results

绘制三种回归模型在基于多源信号融合、基于 sEMG 信号和基于髌关节角度预测时某位受试者实际膝关节角度和预测的膝关节角度曲线，分别如图 4.18、图 4.19 和图 4.20 所示。从图 4.18、图 4.19 和图 4.20 中可以看出，本研究中膝关节角度是连续预测的，可用于人机协同运动控制技术中关节角度的连续输入。从图 4.18 中可知，基于 sEMG 信号预测得到的膝关节角度曲线不平滑且与实际值差别较大，特别是 CNN 模型与原始数据最大角度差约 7° ，这说明基于 sEMG 信号预测得到的膝关节角度不宜直接用于外骨骼机器人控制。从图 4.19 中可知，基于髌关节的

预测得到的膝关节角度峰值通常比原始值要小，曲线平滑，但是存在滞后的问题；图 4.19 左侧波谷处的预测角度与原始数据相比滞后约 66.67ms，如果将该预测值作为外骨骼机器人的输入会影响人机协同性能。从图 4.20 中可知，基于多源信号融合方法预测得到的膝关节角度与原始数据拟合较好，曲线较平滑，且 LSTM 模型比 CNN 模型和 RNN 模型能更好地跟踪目标值。即基于多源信号融合方法的 LSTM 模型预测结果能够较精确反映膝关节运动意图且适合用于外骨骼机器人的控制。




图 4.18 基于 sEMG 信号的膝关节角度预测结果

Fig. 4.18 Knee joint angle prediction results based on sEMG signal




图 4.19 基于髋关节角度的膝关节角度预测结果

Fig. 4.19 Knee joint angle prediction results based on hip angle




图 4.19 基于多源融合信号的膝关节角度预测结果

Fig. 4.19 Knee joint angle prediction results based on multi-source signal

为了验证基于多源信号融合方法的 LSTM 模型预测实时性,对每位受试者验证集的数据预处理、肌电特征提取和模型预测时间进行了统计。由于模型训练不包含在人机交互控制中,所以只计算了受试者各自最优 LSTM 模型的预测用时。表 4.5 记录了每位受试者测试集的 4 通道 sEMG 信号经过滤波、归一化和特征提取所需要的时间,还记录了基于多源信号融合方法的 LSTM 模型在进行膝关节连续预测所需要的时间。在配置了 Intel 2.6GHz 酷睿 i7 6 核处理器的笔记本电脑上, LSTM 模型在 Python 环境中从信号预处理到特征提取最后输出单个膝关节角度预测结果的时间均在 2.80ms 左右,小于滑动窗口的步长时间 16.67ms 且远小于人体感觉到延迟的 300ms^[144]。因此,该 sEMG 信号的预处理和特征提取以及基于多源信号融合方法的 LSTM 模型预测能够用于实时、连续的人机协同控制系统中。

表 4.5 基于 LSTM 模型的膝关节角度连续预测耗时

Table 4.5 Time for knee joint angle prediction based on LSTM model

受试者	滤波	归一化	特征提取	模型预测	样本总数 (个)	单个样本 预测耗时
P1	0.77s	0.45s	2.50s	6.43s	3593	2.82ms
P2	0.91s	0.69s	3.35s	8.64s	4793	2.89ms
P3	0.72s	0.45s	2.50s	6.36s	3593	2.79ms
P4	0.83s	0.68s	3.39s	8.26s	4793	2.75ms

表 4.5 基于 LSTM 模型的膝关节角度连续预测耗时（续）

Table 4.5 Time for knee joint angle prediction based on LSTM model

受试者	滤波	归一化	特征 提取	模型 预测	样本总数 (个)	单个样本 预测耗时
P5	0.95s	0.70s	3.38s	8.41s	4793	2.80ms
P6	1.00s	0.71s	3.37s	8.55s	4793	2.84ms
P7	0.89s	0.62s	3.30s	8.09s	4793	2.69ms
P8	0.94s	0.64s	3.37s	8.36s	4793	2.78ms
P9	0.92s	0.68s	3.10s	8.18s	4793	2.69ms
P10	0.99s	0.67s	3.37s	8.31s	4793	2.78ms

4.5 本章小结

本章提出了基于多源信号融合的膝关节角度连续预测。将 sEMG 肌电特征和髌关节角度融合并作为 CNN、RNN 和 LSTM 回归模型输入，分别对膝关节角度进行连续预测。同时，基于三种回归模型，还对比了仅采用髌关节预测和仅采用 sEMG 信号预测的结果。最后，采用平均绝对误差、均方根误差和 R^2 分数对模型性能进行评估。实验结果和分析表明，基于多源信号融合的膝关节角度预测优于仅采用髌关节预测和仅采用 sEMG 信号预测，同时还优于相关研究，且 LSTM 模型比 CNN 和 RNN 模型具有更好的性能。同时，本研究减少了附着在人体下肢的传感器数量，在增加人体舒适度的同时更有利于人机协同，具有实际应用价值。

第5章 人体行走的步态识别

步态作为人体行走特征之一和人体意图识别的前提，是外骨骼或者假肢控制方法中对状态切换点的分类和布置的首要条件，是基于 sEMG 信号来理解人体下肢动作的依据。步态识别是通过视觉观察、传感器技术、视频、光学相机或者这些技术的集成来实现。随着微电子技术的发展，微型传感器如加速度计、陀螺仪、磁力计、力传感器、足部开关以及肌电传感器等也被用于人体步态分析；上述各种电子技术和数学算法相结合也被广泛用于区分老年人或者行动不便患者的异常步态。选择合适的传感器类型是在实际应用中实现可靠、准确步态识别的关键。根据第一章的内容可知，在步态识别方面，IMU 和 FSR 是应用最广泛的两种穿戴式生物力传感器，但它们也各自存一些不足；如 FSR 仅限于对时间参数的估计，且当压力信号达不到阈值时，有 80% 的可能性导致步态识别失败^[145]；IMU 对除了 HS 和 TO 外的其它步态事件和步态阶段识别能力差^[146]。而 FSR 与 IMU 相结合可以获得较高的步态识别精度^[147]，它综合了 FSR 和 IMU 传感器各自的优点。如何充分利用 FSR 和 IMU 在步态识别中的优势，将二者信息结合来提升步态识别精度是值得研究的问题。

本章基于 FSR 和 IMU 传感器采集的足底压力和足部加速度信号，结合阈值法和连续小波变换，设计了一种精确区分步态相位的复合步态识别算法，实现了对多个步态阶段的划分和对异常步态的识别。

5.1 步态识别算法

5.1.1 阈值法

单个步态阶段与足底压力区间具有一一对应关系，足底压力分析能实现以下步态参数的估计：步频、单下肢摆动相所占的步态百分比、单下肢站立动相所占的步态百分比、双下肢摆动相所占的步态百分比和双下肢站立相所占的步态百分比等。然而人体运动状态的信息不能直接从足底压力信号得出，需要利用相关算法将此类信息从信号中提取出来，阈值法是一种处理足底压力信号的常用方法。阈值法通过设定合适的阈值来判断脚掌处于“在地”还是“离地”状态，然后根据足底压力分布曲线得到相应的步态相位。阈值法不仅可以防止足部趾屈和背屈导致传感器压力改变而产生的误判，还可以避免足底与地面接触时测得的足底压力在某个

压力值附近振荡而导致的识别紊乱。阈值的计算是阈值法识别步态的关键，Mariani^[148]等定义受试者体重的 5% 作为阈值。然而由于受试者的体重存在差异，每次实验前都必须对阈值进行重复计算和实验验证。此外，在步态识别过程中，无论受试者步行速度快或慢，对同一受试者只设置了一个阈值。

相比较而言，Lopez-Meyer (LM) 法是一种基于压力阈值的高精度步态识别方法^[149]。基于足底压力数据，LM 法通过定义行走过程中平均最大和最小足底压力的值，计算得到相应的压力阈值进而对 HS 和 TO 步态事件进行识别。平均最大和最小足底压力的值可以由下式计算得到：

$$\begin{aligned} T_{\max} &= \frac{1}{k} \sum_{i=1}^k T_{\max}(i) \\ T_{\min} &= \frac{1}{l} \sum_{j=1}^l T_{\min}(j) \end{aligned} \quad (5.1)$$

式 5.1 中， $T_{\max}(i), i=1, \dots, k$ ，是局部最大足底压力点； $T_{\min}(j), j=1, \dots, l$ ，是局部最小足底压力点。通过最大和最小足底压力平均值之间的差异对阈值 T 进行了定义，可以表示为：

$$T = T_{\min} + \alpha(T_{\max} - T_{\min}) \quad (5.2)$$

式 5.2 中，阈值 T 用来识别压力信号中的 HS 和 TO 等步态事件。 α 是一个比例调节因子，针对的不同受试者，传统的阈值法通过多次实验和验证可以得到 α 的具体值。在式 5.2 中，阈值 T 设定在总足底压力信号变化范围内，这意味着比例因子 α 可以对阈值进行调整。 $\alpha(T_{\max} - T_{\min})$ 作为信号平均最大值和平均最小值差异的一部分，能够补偿个体压力水平的变化。

5.1.2 连续小波变换法

除了基于足底压力对步态进行识别外，基于足部加速度信号的步态识别也是一种常用方法。人体行走过程中，足部加速度呈现周期性变化，这种动态特性非常适合连续小波变换对其进行分解。连续小波变换是波变换的一种，波变换最早由 Morlet 和 Grossman 在 1984 年共同提出^[150]。Mallat^[151]等在 1989 年首次提出了多尺度分析 (Multiresolution Analysis) 的概念，基于这一概念的小波变换可实现信号的分解与重构。小波变换首先选择某一合适的母小波 (Mother Wavelet)，然后对

母小波执行平移和伸缩变换进而获得一组小波基，最后使用该组小波基去逼近并表示待分析信号，由此完成了对待分析信号时域和频域的局部分析。小波变换的过程可以通过图 5.1 进行类比，将对待分析信号的小波变换类比于用镜头对信号进行分析；母小波对信号的卷积或者滤波处理即为镜头对图中信号的分析；母小波在待分析信号上的平移即为镜头相对于图中信号的平移；母小波对待分析信号的伸缩变换即为镜头相对于图中信号在垂直方向移动。基于上述特点，小波变换在信号分析中又被称为“数字显微镜”，即它的时间-频率窗口可以根据信号的高频或者低频分析进行自动调节，从而具有多种分辨率（多种尺度）。基于多分辨率的特性，信号经过小波变换可以被由远及近、由粗及细地分析。因此，小波变换在图像编码与压缩、信号处理和信号奇异性识别方面得到了广泛的应用。




图 5.1 小波变换示意图

Fig. 5.1 Schematic diagram of wavelet transform

连续小波变换具有随尺度变化而调整的时频窗，允许信号在所有尺度和位置上的变换，进而提供信号的完整表示，适用于峰值识别和模式匹配等任务。上世纪九十年代左右，国外学者首先开展了大量基于连续小波变换的模式参数辨识研究。例如，Staszewski^[152]最先利用以连续小波变换为基础的不同方法对模态阻尼比进行估算；Ruzzene^[153]等根据多自由度系统的响应，使用连续小波变换辨别其模态参数，得到的结果比 Hilbert 变换识别出的瞬时频率更精确。在国内，基于连续小波变换的参数辨识研究仍刚展开。但是随着计算机技术的发展，连续小波变换被越来越多地用于加速度信号的分解与重构。例如，在机械系统的故障识别中，振动加速度信号的频谱分析不易找出其所蕴含的故障特征频率，而连续小波变换的物理特性使

其对强背景噪声下的弱信号特征提取有很好地效果^[154]。在步态分析中，连续小波变换也被越来越多地应用于加速度信号的处理和步态相位的识别。在 HS 和 TO 等步态事件识别过程中，对加速度信号的连续小波分析由于不受受试者体重的影响具有很强的鲁棒性，相关学者在此领域进行了研究^[155, 156]。

连续小波变换因子由待分析信号经过连续小波变换得到，用来表示待分析信号局部区域与相应的母小波的相似度，其值越大表明相似度越高。因此，母小波应该与待分析信号特征的时频和周期密切相关，以便清楚地区分这些频谱在时间上的构成。Morlet 小波^[157]是常用于生物信号分析和步态相位识别的母小波之一，具有高度对称性。而且，步态循环中步态事件所引起的加速度信号变化往往表现为脉冲冲击，其形状与 Morlet 小波较为相似（图 5.2）。所以，本研究中选择 Morlet 母小波进行加速度信号分析，它通过式进行定义：

$$\psi_{a,b}(t) = \exp(i\omega_0 \frac{(t-b)}{a}) \exp(-\frac{(t-b)^2}{2a^2}) \quad (5.3)$$




图 5.2 Morlet 母小波

Fig. 5.2 Morlet mother wavelet

Morlet 母小波 $\Psi_{a,b}(t)$ 可以通过式 5.3 中两函数的乘积求得；左侧的函数为复三角函数，右侧为指数衰减函数。函数中的 ω_0 为频率， a 为尺度 $a>0$ ， b 为时间偏移量 $b \in R$ 。本研究中，连续小波变换被用来提取加速度信号的潜在特征，基于 $\Psi_{a,b}(t)$ 的连续小波变换表达为：

$$CWT(a,b) = \frac{1}{\sqrt{a}} \int_{-\infty}^{+\infty} f(t) \psi_{a,b}^*(t) dt \quad (5.4)$$

式 5.4 中, $f(t)$ 表示与时间有关加速度信号, $\psi_{a,b}^*$ 表示 Morlet 母小波 $\psi_{a,b}(t)$ 的共轭复数。加速度信号经过连续小波变换得到小波变换因子 $CWT(a,b)$, $CWT(a,b)$ 的波峰和波谷可以用来表示原始信号与母小波的相似度(峰值越高, 相似度越好)。

时间边际能量(Time Marginal Energy)表示不同尺度下能量波的周期性分布, 是一种二维的波能量密度函数, 可以用来分析信号的总能量分布。为了方便在二维图像上对步态事件进行描述, 通过公式 5.5 可以计算小波变换因子的时间边际能量 $E(t)$ 。 $E(t)$ 的峰值代表了频谱图中对信号总能量贡献最大的主导能量尺度, 在步态识别中表示周期性步态事件在谱域中贡献的大部分信号能量, 即 HS 和 TO 步态事件。

$$E(t) = \sqrt{\sum_a CWT(a,b)^2} \quad (5.5)$$

5.1.3 复合步态识别算法

在基于足底压力的 LM 法中, 比例因子 α 的值一般通过重复和交叉训练获得, 对于不同的受试者不具有鲁棒性和适应性; 而基于加速度信号的连续小波变换方法中, 只对 HS 和 TO 两个步态事件敏感, 对其它步态事件和子步态阶段识别能力差。不同受试者行走时, 脚趾、脚掌中部和足跟的压力大小不同, 其压力阈值也存在差异, 但是同一受试者而言 α 大小是相同的。复合步态识别算法(图 5.3)首先基于连续小波变换计算得到 HS 和 TO 步态事件, 然后根据相同时间线上足底压力和 HS、TO 步态事件反算出比例因子, 最后基于该比例因子和足底压力对足部的完整步态进行识别。复合步态识别算法结合 LM 法和小波变换法的优点, 不需要大量重复实验即可得到每位受试者的比例因子 α 而且能对多个步态阶段进行识别, 在提高步态识别精度的同时具有鲁棒性。




图 5.3 复合步态识别算法

Fig. 5.3 Composite gait recognition algorithm

假定一个确定的样本时间内，基于受试者足部加速度信号，通过连续小波变换计算得到的 HS 和 TO 事件的总数为 n 次，则 α 的平均值可以由式 5.6 计算得到：

$$\alpha = \frac{1}{n} \sum_{m=1}^n \frac{T_a - T_{\min}}{T_{\max} - T_{\min}} \quad (5.6)$$

相同时间内，在足底压力信号时间序列上，通过连续小波变换得到的各 HS 和 TO 事件对应的压力值即其对应的阈值大小。式 5.6 中， T_a 表示 HS 和 TO 事件处的平均压力阈值， $T_{\min}$ 表示 HS 和 TO 事件的最小压力阈值， $T_{\max}$ 表示 HS 和 TO 事件的最大压力阈值。将式 5.6 计算得到的比例因子用于脚掌中部的压力阈值设定，进而能对其离地状态进行分析。通过压力阈值进行步态识别的表达式定义为：

$$R_f(i) = \begin{cases} 1, F(i) \geq T \\ 0, F(i) < T \end{cases} \quad (5.7)$$

式中，当足底压力大于等于压力阈值，接触点 $R_f(i)=1$ ，被认为处于“在地”状态；当足底压力小于压力阈值，接触点 $R_f(i)=0$ ，被认为处于“离地”状态。 $F(i=1)$ 表示传感器测得的脚趾处压力， $F(i=2)$ 表示脚掌中部压力， $F(i=3)$ 表示足跟处压力， $R_f(i)$ 表示接触点的在地或者离地状态。由于步态事件和步态相位按照一定顺序连续且重复出现，基于表中 5.1 的步态事件识别规则，可以得到足部的步态相位。

表 5.1 步态事件识别规则

Table 5.1 Gait event recognition rule

$R_f(1)$	$R_f(2)$	$R_f(3)$	步态事件
0	0	1	Heel Strike
1	1	1	Foot Flat
1	1	0	Heel Off
1	0	0	Mid-foot Off
0	0	0	Toe Off

5.2 步态识别实验

为了验证 5.1.3 节中提出的复合步态识别算法对人体行走过程中步态相位识别的准确性和有效性,设计了步态识别实验。传感器的布置如图 5.4 所示,实验分别采用压力传感器和 IMU 来测量足底压力和足部加速度。IMU 使用的是北京超核电子公司研制的 CH110,它集成了加速度计、陀螺仪和单片机,具有低成本、高性能、小体积和低延迟等优点。压力传感器 ZNX-01 由苏州能斯达电子制造,它集成了图示的 8 个 FSR 模块,每个 FSR 的测量区间是 0~10kg,响应时间小于 1ms。根据 FSR 在足底的分布,将其分为脚趾、脚掌中部和足跟三部分。脚趾处测得的足底压力记为 $F1$,表示编号为 1、2 和 5 的 FSR 处压力合力;脚掌中部测得的足底压力记为 $F2$,表示编号为 3 和 4 的 FSR 处压力合力;足跟测得的足底压力记为 $F3$,表示编号为 6、7 和 8 的 FSR 处压力合力。本研究将压力传感器和 IMU 放置在受试者的右鞋,对其右脚步态进行识别。




图 5.4 步态识别实验传感器布置

Fig. 5.4 Sensor placement in gait recognition experiment

5 名健康受试者参与了本次实验，对受试者右下肢足底压力和足部加速度信号进行采集。在确认传感器放置是否带来不适后，受试者被要求以各自舒适的速度在水平地面上分别以正常和异常步态行走 30s 左右。异常步态具有明显的步态不对称性，患者的负重能力降低，患侧的站立相减少、摆动相增加。为此，如图 5.5 所示，利用橡胶绑带限制受试者下肢关节正常活动来模拟步态异常患者行走。



图 5.5 正常步态和异常步态实验区别

Fig. 5.5 Difference between normal and abnormal gait in the experiment

5.3 基于复合步态识别算法的步态识别结果与分析

5.3.1 步态识别结果

基于 IMU 传感器测得受试者正常步态下足部的三轴加速度信号 A_x 、 A_y 和 A_z ，则复合加速度信号 A_c 由式 5.8 计算得到。某位受试者正常步态下行走 6s 的复合加速度如图 5.6 所示。

$$A_c = \sqrt{A_x^2 + A_y^2 + A_z^2} \quad (5.8)$$

基于图 5.6 的复合加速度信号，使用连续小波变换对其进行时频分解；小波变换后的该信号在时间序列上、不同尺度下的时频图如图 5.7 所示，图中小尺度对应高频信号分量，持续时间短的高频信号被视为噪声，波峰和波谷代表相应的步态事件。根据时频图可在三维图像上对 HS 和 TO 时间进行大致区分，为了在二维图像进行准确描述步态事件还需要计算小波变换因子的时间边际能量图。




图 5.6 正常行走的复合加速度信号

Fig. 5.6 Composite acceleration signals during normal walking




图 5.7 正常行走的时频图

Fig. 5.7 A time-frequency representation during normal walking

同时,根据公式 5.5 计算了图 5.7 中小波变换因子的时间边际能量(图 5.8),在二维坐标系对步态事件进行描述。图 5.8 中曲线的峰值表示 HS 和 TO 两个步态事件。由于 HS 和 TO 在步态周期中重复且交替出现,且 HS 事件产生的加速度更大,所以均值较大的峰值被认为是 HS 事件,均值较小的峰值被认为是 TO 事件。基于时间边际能量图,实现了该时间段内 HS 和 TO 步态事件的识别。

此外,基于 FSR 传感器测得该受试者相同时间下的脚趾、脚掌中部和足跟的压力信号。绘制脚趾、足跟处的足底压力曲线,并将连续小波变换计算得到的 HS 和 TO 步态事件在压力曲线(图 5.9)上标识出,为计算比例因子做准备。




图 5.8 正常行走的时间边际能量图

Fig. 5.8 Time marginal energy during normal walking




图 5.9 正常行走的脚趾、足跟处压力曲线

Fig. 5.9 Force curves in the toe and heel during normal walking

根据图 5.9 中的曲线可以得到步态事件处足底压力的具体值。将上述各点的压力阈值带入公式 5.6，求得到各点的比例因子如表 5.2 所示，则该受试者比例因子的平均值为 0.44。0.44 作为该受试者特定的比例因子，可用于脚掌中部步态事件的识别。

表 5.2 步态事件处各点的压力和相应比例因子

Table 5.2 Force and scale factor in each gait event

No.	1	2	3	4	5	6	7	8
$T(N)$	26.95	42.58	29.66	45.36	29.58	30.29	25.17	39.98
$T_{max}(N)$	47.68	76.94	53.59	94.09	61.74	84.42	60.58	66.94
$T_{min}(N)$	5.90	6.80	5.90	6.80	5.90	6.80	5.90	6.80
α	0.50	0.51	0.50	0.44	0.42	0.32	0.35	0.50

基于 FSR 传感器测得该受试者 6s 时间内脚掌中部的压力如图 5.10 所示, 则脚掌中部的平均最大阈值 $T_{\max}$ 和平均最小阈值 $T_{\min}$ 分别为 6.23N 和 5.03N, 代入式 5.2 计算得到脚掌中部的压力阈值为 5.56N。




图 5.10 正常行走的脚掌中部压力曲线

Fig. 5.10 Force curve in the mid-foot during normal walking

基于足部的压力阈值和足底压力, 根据表 5.1 的步态识别规则可以得到步态循环中的足部所处的步态相位。为了对站立相的步态变换进行详细说明, 以该受试者单个步态循环 (图 5.11) 为例进行分析。首先, 基于连续小波变换和足部加速度信号对 HS 事件进行了识别, 这意味着足跟压力 F_3 达到了其阈值, LR 阶段开始, 如图 5.11 (a) 所示。然后, 由于人体重心前移和足部放平, F_2 和 F_1 相继达到其阈值。当 F_1 达到其阈值时, LR 阶段结束且 MSt 阶段开始, 如图 5.11 (b) 所示。在 MSt 阶段, F_1 、 F_2 和 F_3 都超过了其阈值并且持续了一段时间。随着步行时人体重心逐渐向另一侧腿转移, F_3 逐渐减小到其阈值, MSt 阶段结束且 TSt 阶段开始, 如图 5.11 (c) 所示。随着重心转移和身体继续前倾, F_2 越来越小并最终低于其阈值, 这也标志着 TSt 阶段的结束, 如图 5.11 (c) 所示。如图 5.11 (d) 所示, PSw 阶段开始于 F_2 减小到其阈值, 结束于 TO 事件被识别到。如图 5.11 (e) 所示, PSw 阶段的结束意味着摆动相的开始。对于正常步态, 在给定时间内有且仅有一个步态事件被识别且步态阶段应该遵循 LR、MSt、TSt、PSw 和摆动相的顺序, 如图 5.11 (f) 所示。因此, 如果识别的步态阶段没有遵循该自然步态序列, 就能推断该步态出现异常。

为了验证该复合步态识别算法对步态异常识别的可行性，该健康受试者被要求以异常步态行走。同样选取 6s 的步态样本进行分析，异常步态的复合加速度信号如图 5.12 所示。从图 5.12 可知，相较于正常行走复合加速度信号，该加速度信号步态事件间的间隔差异较大，TO 事件的加速度幅值大幅减小。




图 5.11 正常步态行走单个步态循环

Fig. 5.11 One gait cycle during normal walking




图 5.12 异常行走的复合加速度

Fig. 5.12 Composite acceleration signals during abnormal walking

将异常步态的复合加速度信号进行连续小波变换得到其时频图（图 5.13），然后求得时频图的时间边际能量（图 5.14）。从图 5.13 可知，在异常行走加速度信号的时频图上，步态事件处的小波变换因子颜色较浅，波峰和波谷处不具备明显特征。从图 5.14 可知，与正常步态相位比，异常步态的步态事件具有明显的不对称性，具体表现为 HS 和 TO 时间间隔变化很大；而且，时间边际能量图上 HS 和 TO 处的波峰也存在较大波动。

同理，基于 LM 法和该受试者特定的比例因子 0.44，对异常步态下受试者足部的离地状态进行识别，得到的结果如图 5.15 所示。从图 5.15 中可以看出，由于足部垂直载荷的减少，足跟和脚趾压力不能达到其阈值，在行走过程中表现为脚趾拖拉；且由于压力未达到阈值，导致步态事件识别失败。如图 5.16 所示，与正常步态相比，异常步态的足部在矢状面内角度明显减小，这意味着踝关节不能正常弯曲。对异常步态识别的结果表明，该复合步态识别算法能够很好地区分异常步态。




图 5.13 异常步态的时频图

Fig. 5.13 A time-frequency representation during abnormal walking




图 5.14 异常行走时间边际能量图

Fig. 5.14 A time-frequency representation during abnormal walking




图 5.15 异常行走足底压力信号

Fig. 5.15 Force curve in the foot during abnormal walking




图 5.16 正常和异常行走足部在矢状面内角度

Fig. 5.16 Foot angle in sagittal plane during normal and abnormal walking

5.3.2 步态识别结果分析

实验中 5 名受试者各行走了 30 步，检测到了其中的 146 步（96%），检测成功率在 95% 的置信区间内。以第 2 章所述的步态子阶段占单个步态循环的百分比为标准，与本研究检测得到的步态子阶段进行对比，得到各个步态子阶段的检测误差。以 LR 阶段为例，其误差可以表示为：

$$E_{\text{error}}(\text{ms}) = \left[\left(\frac{GC_{\text{time}} \times \%LR}{100} \right) - LR_{LM_{\text{time}}} \right] \quad (5.9)$$

式 5.9 中， GC_{time} 表示单个步态循环的总时间， $\%LR$ 表示 LR 阶段占单个步态循环的百分比， $LR_{LM_{\text{time}}}$ 表示本研究中使用 LM 法得到的 LR 阶段检测时间。其

它步态子阶段采用相似的计算方法。最终计算得到的 LR, MSt, TSt, PSw 和摆动相的平均误差和标准差分别为 $22 \pm 32\text{ms}$, $55 \pm 102\text{ms}$, $-48 \pm 58\text{ms}$, $33 \pm 40\text{ms}$ 和 $18 \pm 22\text{ms}$ 。

计算本章得到的步态相位百分比与标准百分比之间的差值, 得到二者的百分比误差。表 5.3 表示 5 名受试者行走 30 步时, 不同步态阶段百分比误差的平均值。结果表明复合步态识别算法能够识别所有受试者的步态子阶段, 同时整体识别成功率 (96%) 要比只用足底压力信号的 LM 法 (89.18%) 更好; 在相关研究中, 基于 FSR 或者 IMU 的步态识别平均误差为 85ms 和 100ms^[158, 159], 比本研究中的 80ms 要高; 这说明复合步态识别算法结合了两传感器的优势, 提高了识别精度。基于 LM 法进行步态识别得到的站立相和摆动相百分比误差分别是 3.6% 和 6.4%, 表 5.3 中摆动相和步态子阶段的误差范围与之相比是可接受的。同时, 从表中可以看出比例因子 α 对不同受试者具有自适应性, 可以用来补偿个体差异, 而且复合步态识别算法免除了比例因子计算时所需的大量、重复性实验和验证。由于测量的足底压力数值较大, 不必担心传感器是否与足部紧密贴合, 而且比例因子也可对接触力进行调节。

表 5.3 步态相位的百分比误差和比例因子

Table 5.3 Percentage error and scale factor of gait phase

受试者	LR(%)	MSt(%)	TSt(%)	PSw(%)	Swing(%)	α
A	-3	7	-5	6	4	0.44
B	-4	6	-9	8	6	0.45
C	3	-1	-4	1	1	0.38
D	6	-4	-2	0	-1	0.36
E	0	5	-5	3	4	0.42

5.4 本章小结

基于 FSR 和 IMU 传感器在步态识别中存在的不足, 本章提出了一种综合 IMU 和 FSR 传感器优势的复合步态识别算法。该复合步态识别算法结合了阈值法和连续小波变换, 提高了原有阈值法的识别精度并实现了对多个步态阶段和异常步态的识别。该复合步态识别算法具有很好的鲁棒性, 具有补偿个体差异的比例因子且该比例因子的计算免除了原有的大量、重复性实验验证。

第 6 章 下肢外骨骼实验

根据第一章内容可知，人体意图连续识别和步态识别在人机协同控制中发挥着关键作用，具体可以通过图 6.1 表示。采集足部的加速度信号和足底压力信号，通过步态识别算法区分行走过程中的站立相和摆动相；基于两种动作模式可以控制外骨骼机器人助力方向，还能为 sEMG 信号分析提供参考。采集人体行走过程中的 sEMG 信号和关节角度，采用基于多源信号融合方法的 LSTM 模型对膝关节角度进行连续预测；将预测得到的角度作为参考和外骨骼机器人的实时运动角度一起作为外骨骼机器人的控制输入，采用控制算法对机器人位置进行修正，从而实现外骨骼机器人对人体关节角度的跟踪。




图 6.1 运动意图和步态识别在机器人控制中的作用

Fig. 6.1 The role of motion intention and gait recognition in robot control

本章将下肢运动意图，即通过多源信号融合方法预测得到的膝关节角度作为控制输入对 Indego 商用外骨骼机器人进行位置控制。比较受试者穿戴外骨骼在不同速度下行走与不穿戴外骨骼正常行走的步态、膝关节角度和肌肉的肌电特征差异，说明将人体意图信号用于外骨骼机器人控制的可行性并分析不同速度下外骨骼机器人的辅助效果。由于本文的重点在于人体运动意图和步态识别研究，并未涉及力控制等复杂的控制算法，因此采用最简单的位置控制器—PD 控制器对外骨骼机器人进行控制。但是本章所设计的实验涉及人体运动意图识别的实际应用，能够为外骨骼的控制和辅助有效性提供一定的指导。

6.1 PD 控制理论和建模

位置控制是控制机器人关节按照预定的轨迹运行，此过程中不考虑人机交互力。比例微分（PD）控制器由于其简单易实现、鲁棒性好、响应速度快、易于调试和优化的特点，在机器人控制中得到了广泛的应用^[160]。在 PD 控制器中，比例控制器（P 控制器）使用当前误差的大小来产生控制输出，微分控制器（D 控制器）使用误差的变化率来产生控制输出。将比例控制器和微分控制器输出相加，可得到机器人的最终控制信号。PD 控制器可以表示为下式：

$$\tau = K_P(\theta_d - \theta) - K_D\dot{\theta} \quad (6.1)$$

式中， θ 表示实际关节位置， θ_d 表示期望的关节位置，在实际应用中 θ_d 通常是连续的， K_P 和 K_D 均为正定义的对称矩阵。机器人关节误差 e 可以表示为：

$$e = \theta_d - \theta \quad (6.2)$$

基于 PD 控制器的系统稳定性可以通过李亚普洛夫函数（Lyapunov Function）进行验证^[161]。由于李亚普洛夫稳定性理论和基于能量法的拉格朗日方程之间存在联系，李亚普洛夫函数可以构造为：

$$V = \frac{1}{2}S^2 = \frac{1}{2}\dot{\theta}^T M(q)\dot{\theta} + \frac{1}{2}e^T K_P e \geq 0 \quad (6.3)$$

其中， S 表示误差， $M(q)$ 表示第二章中定义的惯性矩阵，对式 6.3 求导可得：

$$\dot{V} = \dot{\theta}^T M\ddot{\theta} + \frac{1}{2}\dot{\theta}^T \dot{M}\dot{\theta} - e^T K_P \dot{\theta} = \dot{\theta}^T (\tau - S\dot{\theta} + \frac{1}{2}\dot{M}\dot{\theta}) - e^T K_P \dot{\theta} \quad (6.4)$$

基于能量守恒定律对 6.4 式进行简化并将 6.1 式代入 6.4 式可得：

$$\begin{aligned} \dot{V} &= \dot{\theta}^T \tau - e^T K_P \dot{\theta} = \dot{\theta}^T K_P e - \dot{\theta}^T K_D \dot{\theta} - e^T K_P \dot{\theta} \\ &= -\dot{\theta}^T K_D \dot{\theta} \leq 0 \end{aligned} \quad (6.5)$$

基于 Barbalat 引理^[162]，李亚普洛夫函数 $V \geq 0$ 且其导数小于等于 0，系统是稳定的。且在原点处，根据全局不变性定理，存在下式：

$$\dot{V} = 0 \Leftrightarrow \dot{\theta} = 0 \quad (6.6)$$

将式 6.6 代入 6.4 可得：

$$M\ddot{\theta} = K_p e \Rightarrow \ddot{\theta} = M^{-1} K_p e \quad (6.7)$$

式 6.7 中右侧的等式是可逆的。只有当 $e=0$ ，上式成立，即期望关节位置和实际关节位置相等。

基于 PD 控制的理论模型模型，搭建了 Indego 外骨骼机器人系统的控制原理图（图 6.2）。图 6.2 中， K_p 和 K_d 分别表示比例参数和微分参数； K 表示增益常量，可以对比例和微分参数的大小进行调整，进而使外骨骼速度与跑步机速度一致。该调整是必要的，因为外骨骼设定参数后会在跑步机上匀速行走，外骨骼速度快于或者慢于跑步机都会导致二者速度不匹配，出现受试者穿戴外骨骼从跑步机上掉落等问题。在 Matlab 的 Simulink/Stateflow 环境中搭建 PD 控制器模型，控制信号通过 CAN 串口传递到外骨骼机器人的 PIC 微控制器中，数据传输速率为 200Hz。




图 6.2 PD 控制器框架

Fig. 6.2 PD controller framework

6.2 下肢外骨骼实验

Indego 下肢外骨骼机器人是由美国的运动和控制巨头派克汉尼汾公司研发的动力外骨骼^[163]，能为完全或者不完全脊髓损伤、下肢无力或者瘫痪患者提供特定任务的步态训练。Indego 下肢外骨骼机器人（图 6.3）膝关节和髋关节处的电机能在矢状面内为人体下肢助力；踝关节处内置了踝足纠形器，用来保证踝关节的稳定并将外骨骼重量转移到地面。Indego 外骨骼机器人是唯一提供模块化快速连接设

计的外骨骼，可拆解成两个大腿、两个小腿和臀部五部分。外骨骼的总质量约为 12kg（带电池），是目前最轻的商用外骨骼。同时，该外骨骼适用于身高 155~191cm 之间的受试者，能承受的最大重量为 113kg、最大臀部宽度为 42.2cm。该外骨骼机器人的每条腿上有两个微控制器，它们通过串行外设接口相互通信^[164]；一个微型控制器 PIC32，用来处理状态机控制器，解析传感器和网络；另一个微控制器 dsPIC，用来控制两个直流无刷电机。来自上位机的控制指令通过 CAN 通信传递给微控制器，进而对髋、膝关节进行驱动和控制。考虑到 Indego 下肢外骨骼机器人的上述优良特性，选择其作为试验平台来验证意图识别实际应用的可行性。



图 6.3 Indego 下肢外骨骼机器人

Fig. 6.3 Indego lower limb exoskeleton robot

人体穿戴 Indego 下肢外骨骼机器人的实验照片如图 6.4 所示，图中包括外骨骼、受试者和信号采集模块。信号采集模块与第三章中的相同，包括 IMU、足底压力传感器和 sEMG 传感器。此实验中 sEMG 信号的采样频率为 2000Hz，IMU 和足底压力传感器为 100Hz。由于 PD 控制器是位置控制，外骨骼机器人带动受试者下肢按照预定的轨迹完成各种运动，即外骨骼和人体下肢的关节角度相同。将 IMU 传感器放置在外骨骼机器人的腰部、大腿、小腿和人体的足部，能采集人体和外骨骼矢状面内髋、膝关节和踝关节角度信号。足底压力传感器用来采集双足的足底压力，识别得到的步态相位能够为外骨骼控制和肌肉活动提供参考。




图 6.4 受试者穿戴外骨骼机器人示意图

Fig. 6.4 Schematic diagram of participant wearing exoskeleton robot

本次下肢外骨骼实验分为穿戴外骨骼的跑步机行走实验和不穿戴外骨骼的地面行走实验；跑步机行走实验可以方便调速且保证受试者匀速行走。外骨骼机器人主要用来辅助不完全脊髓损伤患者或者下肢无力患者正常行走，根据第二章中人体行走运动学数据，将受试者的行走速度控制在 0.44m/s 左右。受试者穿戴外骨骼在跑步机上分别以低速（0.8MPH，0.36m/s），中速（1.2MPH，0.54m/s）和高速（1.4MPH，0.63m/s）实验三次，采集受试者行走 50s 的数据。地面实验中，受试者不穿戴外骨骼；采集受试者 10m 行走数据，用来与跑步机行走实验的数据进行对比。跑步机行走实验中 PD 控制器的参数见表 6.1。

表 6.1 不同速度下 PD 控制器参数

Table 6.1 PD controller parameters at different speeds

	低速		中速		高速	
	髋关节	膝关节	髋关节	膝关节	髋关节	膝关节
K_P	0.5	0.1	0.5	0.1	0.5	0.1
K_D	0.05	0.01	0.05	0.01	0.05	0.01
K	1.9	1.9	1.7	1.7	1.3	1.3

下肢外骨骼机器人对人体的辅助效果可以通过 sEMG 信号的肌电特征进行评估，该方法是一种客观评价方法且得到了广泛的应用。韩国科学技术高级研究院的 Park^[165]等发现 sEMG 信号幅值越高产生的肌肉力越大，并通过对比穿戴外骨骼机器人时肌肉的 MAV 变化来说明外骨骼辅助的有效性。军事科学研究所的 Zhang^[166]

等推荐使用 sEMG 信号的均方根值(Root Mean Square, RMS)、平均肌电图(Average EMG, AEMG)和肌电积分值(Integrated Electromyogram, IEMG)来表示肌肉贡献的主要性能指标,并通过对比单个步态循环内三种肌电特征的变化来说明外骨骼的辅助效果。Treussart^[167]等通过对比同一任务中 sEMG 信号的相对最大收缩(Relative Maximum Contraction, RMC)来验证上肢外骨骼机器人的辅助效果。由此可见,将 sEMG 信号的肌电特征在同一步态相或者相同任务中进行对比进而来验证外骨骼的辅助有效性是可行的。而且,跑步机行走实验中受试者的行走速度不同,为了方便比较关节角度跟踪结果和肌肉状态,在同一步态相位内进行结果分析可以解决速度和时间不同的问题。

为了验证外骨骼辅助能够减少肌肉群的肌肉力,在与下肢运动相关的肌肉群位置放置 sEMG 传感器。股二头肌与髋关节和膝关节运动有关,腓肠肌与膝关节和踝关节运动有关。将 sEMG 传感器布置在股二头肌和腓肠肌位置,可以评估穿戴外骨骼后对与髋关节、膝关节和踝关节运动相关肌肉的影响。此外,放置在股二头肌和腓肠肌位置的 sEMG 传感器避免了人机连接部位对传感器的干涉,保证信号测量精度。

采集受试者穿戴外骨骼在不同速度下行走的 sEMG 信号,对比是否穿戴外骨骼时的肌电特征来验证外骨骼和行走速度对相关肌肉的影响。本研究选择的两个肌电特征是 RMS 和 IEMG,它们都与肌肉力有关。RMS 与肌肉恒力和肌肉的非疲劳收缩有关,是时域内肌肉疲劳的一种表示方法。通过 RMS 可以深入了解 sEMG 信号的幅值信息,所以 RMS 常被用作基于 sEMG 信号的实时控制^[168]。同时, RMS 计算简单且速度快,可以表示为:

$$R_{MS} = \sqrt{\frac{1}{N} \sum_{i=1}^N |x_i|^2} \quad (6.8)$$

式中, N 表示样本长度,本研究中为 20。通过第三章中定义的滑动窗口对 sEMG 信号进行读取然后计算 RMS 值。

IEMG 是 sEMG 信号绝对值的积分,通常被用于 sEMG 的模式识别和与 sEMG 有关的运动控制中^[169]。相关研究表明 IEMG 与肌肉力的大小存在某种关系,总的来说肌肉力随着 IEMG 幅值的增加而增加^[170, 171]。IEMG 可以通过下式进行计算:

$$I_{\text{EMG}} = \sum_{i=1}^N |x_i| \quad (6.9)$$

其中， N 表示样本长度，本研究中为 20。同样通过第三章中定义的滑动窗口对 sEMG 信号进行读取然后计算 IEMG 值。

6.3 下肢外骨骼实验结果分析

步态相位能够用于切换外骨骼机器人的控制模式，基于步态相位还能够从 sEMG 信号上获得肌肉的激活时间和肌肉动作区间。在进行外骨骼控制和肌肉激活分析时只需要对站立相和摆动相步态进行识别，因此采用基于足部加速度信号的小波变换方法识别 HS 和 TO 步态事件。图 6.5 表示跑步机行走实验中受试者右腿的步态相位。



图 6.5 跑步机行走实验受试者步态相位

Fig. 6.5 Gait phase of participant in treadmill walking experiment

通过 IMU 传感器测得受试者地面行走实验和跑步机行走实验中足部复合加速度信号如图 6.6 所示，图中均表示受试者行走 5 步的复合加速度信号。以地面行走复合加速度信号为例，采用连续小波变换得到信号的时频图和时间边际能量如图 6.7 所示；图 6.7 (c) 中时间边际能量的峰值表示识别得到的 HS 和 TO 步态事件，二者形成的区间表示站立相和摆动相。同理，采用连续小波变换对跑步机行走实验中站立相和摆动相进行区分，得到单个步态中站立相和摆动相占比如表 6.2 所示。

从表 6.2 中的数据可知,即使在不同步行实验中,单个步态循环的站立相和摆动相的占比几乎相同;站立相占比约 40%,摆动相占比约 60%,站立相和摆动相百分比误差均在 $\pm 2.5\%$ 的范围内。这说明在地面行走和以不同速度在跑步机行走时步态相位差别不大,也说明将不同速度的关节角度信号和 sEMG 信号放在同一步态循环内进行分析是可行的。




图 6.6 受试者足部复合加速度信号

Fig. 6.6 Composite acceleration signals of the participant foot




图 6.7 地面行走步态识别: (a) 地面行走复合加速度信号; (b) 复合加速度信号时频图; (c) HS 和 TO 步态事件

Fig. 6.7 Gait recognition when walking on ground: (a) Composite acceleration signals when walking on ground; (b) A time-frequency representation of composite acceleration signals; (c) HS and TO gait events

表 6.2 单个步态中站立相和摆动相占比

Table 6.2 Stance and swing phase proportion in single gait

	步态循环 1		步态循环 2		步态循环 3		步态循环 4		步态循环 5	
	摆	站	摆	站	摆	站	摆	站	摆	站
	动	立	动	立	动	立	动	立	动	立
	相	相	相	相	相	相	相	相	相	相
	%	%	%	%	%	%	%	%	%	%
地面	38.75	61.25	40.13	59.87	39.07	60.93	39.74	60.26	40.79	59.21
低速	40.53	59.47	39.05	60.95	40.59	59.41	38.69	61.31	41.11	58.89
中速	39.35	60.65	38.67	61.33	39.07	60.93	39.60	60.40	41.06	58.94
高速	41.35	58.65	41.98	58.02	42.31	57.69	40.15	59.85	40.91	59.09

通过 Pedar 鞋垫测得的足力压力信号如图 6.8 所示，从图中可以看出不同行走实验中足底压力信号变化趋势基本相同。基于不同步行实验中步态相位的相似性，在图中绘制了地面行走实验中识别得到的步态相。图 6.8 中的足底压力和步态相位进一步说明了将不同速度的关节角度信号和 sEMG 信号放在同一步态循环内进行分析是可行的，且在后面研究中均依据此步态相位进行相关数据分析。




图 6.8 受试者足底压力和步态循环

Fig. 6.8 Plantar pressure and gait cycle of the participant

由于本文主要研究矢状面内膝关节角度预测,因此只考虑 PD 控制中膝关节角度跟踪结果。通过 IMU 传感器采集得到三种速度下外骨骼膝关节转角如图 6.9 所示,图中的输入表示为该受试者基于多源信号融合方法的 LSTM 模型预测得到的膝关节角度。该受试者在进行膝关节角度预测时的行走速度为 0.54m/s,即输入信号与跑步机中速行走的速度相同。从图 6.9 中可以看出,在相同步态循环内,当外骨骼辅助人体速度降低时,站立相的膝关节角度减小;当外骨骼辅助人体速度增加时,站立相的膝关节角度增加;该结论与第 2 章中人体在跑步机上行走的结论相同。




图 6.9 不同速度下外骨骼机器人膝关节角度

Fig. 6.9 Knee joint angle of exoskeleton robot at different speeds

根据图 6.9 中的数据,得到不同速度下跑步机行走与地面行走的膝关节角度均方根误差如表 6.3 所示。表 6.3 中,总计 1 表示 5 个步态循环内膝关节角度在摆动相和站立相的均方根误差平均值,总计 2 表示 5 个步态循环内膝关节角度均方根误差平均值。在 5 个步态循环内,输入信号与穿戴外骨骼机器人低速行走的膝关节角度均方根误差为 5.60° ,与中速行走时膝关节角度的均方根误差为 4.00° ,与高速行走时膝关节角度的均方根误差为 8.40° 。由此可见,穿戴外骨骼行走速度和输入信号的速度相同时,外骨骼机器人对预定轨迹跟踪最好; 4.00° 的均方根误差也说明预测得到的膝关节角度能够用于外骨骼机器人的控制。在摆动相内,外骨骼行走速度增加时均方根误差增加,这是由于外骨骼主要在摆动相内提供辅助;行走速度越快,外骨骼与人体的相互作用越大,对轨迹跟踪的影响越大。在站立相内,中

速行走时均方根误差大幅减小，这是由于外骨骼行走速度与人体正常行走速度相同，人体和外骨骼运动达到协调。

表 6.3 膝关节角度均方根误差 (°)
Table 6.3 RMSE of knee joint angle (°)

	步态循环		步态循环		步态循环		步态循环		步态循环		总计 1		总
	1		2		3		4		5				计 2
	摆	站	摆	站	摆	站	摆	站	摆	站	摆	站	
速度	动	立	动	立	动	立	动	立	动	立	动	立	
	相	相	相	相	相	相	相	相	相	相	相	相	
低速	1.52	1.49	4.20	5.70	6.68	9.54	4.52	4.66	2.74	7.03	3.93	5.68	5.60
中速	3.56	1.70	4.46	3.36	4.10	5.38	7.03	1.64	4.93	1.34	4.82	2.68	4.00
高速	6.38	7.34	6.01	9.77	4.90	9.01	11.14	10.30	7.41	9.52	7.17	9.19	8.40

将地面行走和跑步机行走的 sEMG 信号进行特征提取，得到股二头肌的 RMS 如图 6.10 所示。根据图 6.10 中的数据，统计得到不同速度下股二头肌 RMS 幅值如表 6.4 所示。表 6.4 中，总计 1 表示 5 个步态循环内股二头肌在摆动相和站立相的 RMS 平均值，总计 2 表示 5 个步态循环内股二头肌 RMS 平均值。表 6.4 中的 5 个完整步态循环内，地面行走 RMS 的均值为 0.34 ± 0.24 ，跑步机低速行走 RMS 的均值为 0.25 ± 0.29 ，跑步机中速行走 RMS 的均值为 0.25 ± 0.3 ，跑步机高速行走 RMS 的均值为 0.35 ± 0.49 。穿戴外骨骼低速和中速行走时，由于人体行走速度低且存在外骨骼辅助，RMS 均值相比于正常行走减少约 26.47%。对比跑步机中速行走和地面行走的 RMS 数据，相同速度下外骨骼辅助时股二头肌 RMS 均值更小，说明外骨骼辅助能够减小股二头肌的肌肉收缩。人体穿戴外骨骼高速行走时，由于人体运动幅度更大、速度更快，虽然存在外骨骼辅助，但股二头肌 RMS 幅值比地面行走增加 2.86%。此外，从站立相和摆动相的 RMS 幅值可以看出，下肢外骨骼辅助大幅减小了股二头肌的摆动相 RMS 幅值（中速时减小最多约 73.33%），但是却导致站立相 RMS 幅值随行走速度增加而增加。该结果表明，外骨骼主要减少股

二头肌摆动相内的肌肉收缩，但是会导致站立相肌肉收缩增加，需要注意站立相肌肉疲劳。




图 6.10 股二头肌不同速度下 RMS 曲线

Fig. 6.10Biceps femoris RMS curves at different speeds

表 6.4 不同速度下股二头肌 RMS 值

Table 6.4 RMS values of biceps femoris at different speeds

步态循环		步态循环		步态循环		步态循环		步态循环		总计 1		总	
1		2		3		4		5				计 2	
速度	摆	站	摆	站	摆	站	摆	站	摆	站	摆	站	
	动	立	动	立	动	立	动	立	动	立	动	立	
	相	相	相	相	相	相	相	相	相	相	相	相	
地面 低速 中速 高速	0.35	0.24	0.42	0.24	0.50	0.29	0.44	0.26	0.52	0.30	0.45	0.27	0.34
	0.26	0.32	0.18	0.33	0.13	0.27	0.17	0.29	0.14	0.28	0.18	0.30	0.25
	0.15	0.34	0.09	0.28	0.11	0.32	0.20	0.35	0.07	0.43	0.12	0.34	0.25
	0.14	0.43	0.16	0.43	0.13	0.57	0.21	0.55	0.13	0.39	0.15	0.47	0.35

同样得到 5 个完整步态循环内股二头肌的 IEMG 如图 6.11 所示，其具体数据如表 6.5 所示。表 6.5 中，总计 1 表示 5 个步态循环内股二头肌在摆动相和站立相

的 IEMG 平均值，总计 2 表示 5 个步态循环内股二头肌 IEMG 平均值。从表中数据可知，地面行走 IEMG 均值为 5.45 ± 3.95 ，跑步机低速行走 IEMG 均值为 4.13 ± 4.85 ，跑步机中速行走 IEMG 均值为 4.23 ± 4.99 ，跑步机高速行走 IEMG 均值为 5.89 ± 8.23 。与地面行走相比，跑步机低速行走 IEMG 均值减少约 24.22%；跑步机中速行走 IEMG 均值减少约 22.39%；跑步机高速行走 IEMG 均值增加 8.07%，即在外骨骼辅助时行走速度越慢 IEMG 幅值越小。与股二头肌 RMS 幅值变化类似，外骨骼辅助大幅减小摆动相内股二头肌 IEMG 幅值，即肌肉力大小，而站立相 IEMG 幅值和肌肉力增加；该结果侧面反映了外骨骼辅助对特定肌肉具有辅助效果但也会给肌肉带来负担。




图 6.11 股二头肌不同速度下 IEMG 曲线

Fig. 6.11 Biceps femoris IEMG curves at different speeds

表 6.5 不同速度下股二头肌 IEMG 值

Table 6.5 IEMG values of biceps femoris at different speeds

		步态循环		步态循环		步态循环		步态循环		步态循环		总计 1		总 计 2
		1		2		3		4		5				
速度 地面	摆 动 相	站 立 相	摆 动 相	站 立 相	摆 动 相	站 立 相	摆 动 相	站 立 相	摆 动 相	站 立 相	摆 动 相	站 立 相	摆 动 相	站 立 相
	5.80	3.77	7.04	3.71	8.32	4.77	7.23	3.96	8.35	4.71	7.35	4.18	5.45	

表 6.5 不同速度下股二头肌 IEMG 值 (续)

Table 6.5 IEMG values of biceps femoris at different speeds

	步态循环 1		步态循环 2		步态循环 3		步态循环 4		步态循环 5		总计 1		总计 2
	摆 动 相	站 立 相	摆 动 相	站 立 相	摆 动 相	站 立 相	摆 动 相	站 立 相	摆 动 相	站 立 相	摆 动 相	站 立 相	
低 速	4.36	5.23	2.99	5.41	2.15	4.44	2.77	4.88	2.41	4.58	2.94	4.85	4.13
中 速	2.49	5.60	1.50	4.58	1.81	5.24	3.43	5.78	1.16	7.15	2.08	5.67	4.23
高 速	2.51	7.22	2.66	7.44	2.28	9.82	3.54	9.24	2.18	6.53	2.63	8.05	5.89

位于小腿处的腓肠肌与踝关节的趾屈、背屈和膝关节的屈曲有关。经过特征提取得到腓肠肌 5 个完整步态循环内的 RMS 如图 6.12 所示,其具体数据如表 6.6 所示。表 6.6 中,总计 1 表示 5 个步态循环内腓肠肌在摆动相和站立相的 RMS 平均值,总计 2 表示 5 个步态循环内腓肠肌 RMS 平均值。从表 6.6 中数据可知,地面行走 RMS 幅值为 0.22 ± 0.25 ,跑步机低速行走 RMS 幅值为 0.37 ± 0.34 ,跑步机中速行走 RMS 幅值为 0.28 ± 0.21 ,跑步机高速行走 RMS 幅值为 0.25 ± 0.25 。相对于地面行走,跑步机低速行走的 RMS 幅值增加约 68.18%;跑步机中速行走的 RMS 幅值增加约 27.27%;跑步机高速行走的 RMS 幅值增加约 13.64%。由于外骨骼机器人不能在踝关节处提供辅助,受试者穿戴外骨骼机器人行走会给踝关节带来额外的消耗,所以穿戴外骨骼机器人行走比地面行走的 RMS 幅值高,即腓肠肌需要增大肌肉收缩为支撑外骨骼提供额外的肌肉力。而随着外骨骼机器人行走速度增加,外骨骼机器人在屈曲膝关节时提供的辅助增大,减小了腓肠肌 RMS 幅值。从站立相和摆动相的结果可以看出,人体正常行走腓肠肌的肌肉收缩主要在站立相提供;相同速度下,人体穿戴外骨骼后摆动相内腓肠肌肌肉收缩大量增加,而站立相的区别不大。




图 6.12 腓肠肌不同速度下 RMS 曲线

Fig. 6.12 Gastrocnemius RMS curves at different speeds

表 6.6 不同速度下腓肠肌 RMS 值

Table 6.6 RMS values of gastrocnemius at different speeds

	步态循环 1		步态循环 2		步态循环 3		步态循环 4		步态循环 5		总计 1		总计 2
	摆	站	摆	站	摆	站	摆	站	摆	站	摆	站	
	动	立	动	立	动	立	动	立	动	立	动	立	
速度	相	相	相	相	相	相	相	相	相	相	相	相	
地面	0.11	0.31	0.12	0.30	0.10	0.24	0.14	0.29	0.17	0.30	0.13	0.29	0.22
低速	0.33	0.32	0.32	0.36	0.32	0.36	0.39	0.40	0.44	0.46	0.36	0.38	0.37
中速	0.32	0.34	0.29	0.24	0.24	0.29	0.27	0.28	0.26	0.28	0.28	0.29	0.28
高速	0.14	0.30	0.17	0.32	0.34	0.19	0.20	0.25	0.33	0.24	0.24	0.26	0.25

对腓肠肌的 sEMG 信号进行特征提取，得到 5 个完整步态循环内的 IEMG 幅值如图 6.13 所示，其具体数据如表 6.7 所示。表 6.7 中，总计 1 表示 5 个步态循环内腓肠肌在摆动相和站立相的 IEMG 平均值，总计 2 表示 5 个步态循环内腓肠肌 IEMG 平均值。从表 6.7 中数据可知，地面行走 IEMG 幅值为 3.60 ± 4.00 ，跑步机低速行走 IEMG 幅值为 6.79 ± 6.57 ，跑步机中速行走 IEMG 幅值为 5.13 ± 3.99 ，跑

步机高速行走 IEMG 幅值为 4.58 ± 4.79 。相对于地面行走,跑步机低速行走的 IEMG 幅值增加约 88.61%; 跑步机中速行走的 IEMG 幅值增加约 42.5%; 跑步机高速行走的 IEMG 幅值增加约 27.22%。腓肠肌 IEMG 幅值增加比 RMS 更为明显,说明穿戴外骨骼导致腓肠肌肌肉力大幅增加。但随着外骨骼辅助速度、强度增加,腓肠肌 IEMG 幅值逐渐减小。此外,穿戴外骨骼机器人会导致摆动相和站立相 IEMG 幅值即肌肉力同时增加,但都随着外骨骼行走速度的增加而减小。




图 6.13 腓肠肌不同速度下 IEMG 曲线

Fig. 6.13 Gastrocnemius IEMG curves at different speeds

表 6.7 不同速度下腓肠肌 IEMG 值

Table 6.7 IEMG values of gastrocnemius at different speeds

		步态循环		步态循环		步态循环		步态循环		步态循环		总计 1		总
		1		2		3		4		5				计 2
速度	摆	站	摆	站	摆	站	摆	站	摆	站	摆	站		
	动	立	动	立	动	立	动	立	动	立	动	立		
	相	相	相	相	相	相	相	相	相	相	相	相		
地面 低速	1.77	4.96	1.93	4.97	1.65	3.81	2.14	4.71	2.69	4.81	2.04	4.65	3.60	
	5.92	5.96	5.74	6.59	5.97	6.59	7.19	7.29	8.01	8.38	6.57	6.96	6.79	

表 6.7 不同速度下腓肠肌 IEMG 值（续）
Table 6.7 IEMG values of gastrocnemius at different speeds

	步态循环 1		步态循环 2		步态循环 3		步态循环 4		步态循环 5		总计 1		总 计 2
速度	摆 动 相	站 立 相	摆 动 相	站 立 相	摆 动 相	站 立 相	摆 动 相	站 立 相	摆 动 相	站 立 相	摆 动 相	站 立 相	
中 速	5.74	6.28	5.30	4.44	4.28	5.32	4.73	4.98	4.84	5.15	4.98	5.23	5.13
高 速	2.49	5.52	3.04	5.88	6.23	3.55	3.65	4.65	5.98	4.42	4.28	4.80	4.58

从对股二头肌和腓肠肌的肌电特征分析可知，外骨骼辅助对特定肌肉群有辅助效果，具体表现为肌肉收缩和肌肉力减少。根据摆动相和站立相的肌电特征可知，本研究中外骨骼机器人主要在摆动相内为人体提供辅助。同时，部分肌肉群在穿戴外骨骼机器人后肌肉收缩和肌肉力增加，即外骨骼机器人也会给相关肌肉和受试者带来负面效果。为此，患者穿戴外骨骼进行康复过程中，需要密切关注外骨骼辅助下受试者的行走速度，以及肌肉收缩和肌肉力增加的相关肌肉群，防止肌肉疲劳。

6.4 本章小结

本章建立了 PD 控制器理论模型，将基于多源信号融合方法的 LSTM 模型预测得到的膝关节角度作为控制输入对 Indego 外骨骼机器人进行位置控制。通过对比和分析受试者地面行走和穿戴外骨骼以不同速度行走的步态、膝关节角度和股二头肌、腓肠肌的肌电特征，说明了人体意图识别的方法用于外骨骼机器人控制的可行性，还说明外骨骼机器人能够减少人体特定肌肉的肌肉收缩和肌肉力，即外骨骼对人体具有辅助效果。

第7章 总结与展望

7.1 总结

下肢外骨骼机器人可以为四肢运动弱化的老年患者和下肢功能障碍患者提供日常运动辅助和个性化康复训练,提高其生活质量、生理机能和生理职能。目前下肢外骨骼机器人技术取得了很大的进展,尤其是在人机交互过程中机器人逐渐由被动接受人体指令转变为主动识别并理解人体运动意图。基于人机协同控制技术,下肢外骨骼机器人可以获取人体运动信息并识别下肢运动意图和步态等信息,从而达到实时跟踪和适时辅助的效果。然而,目前在下肢运动意图的实时、连续识别和步态识别等方面仍然存在问题,这些问题影响了人机协同运动的柔顺度和外骨骼的辅助效果。

因此,为了解决人机协调运动控制技术中下肢运动意图识别和步态识别等关键问题,以实现高效的人机共融为目标,本文以行走运动中膝关节角度和步态为研究对象探索了基于多源信号融合的人体运动意图和步态识别新方法,为实现人机协同运动控制提供了新思路。本文的主要研究工作如下:

(1) sEMG 信号的预处理和特征提取

通过对人体意图识别国内外研究现状分析,提出了基于多源信号融合的膝关节角度连续预测。根据人体解剖学结构,对大腿部位与膝关节运动相关的肌肉进行选取,采集人体行走过程中的 sEMG 信号和关节角度信号。由于 sEMG 信号的相关特性,依次使用了陷波滤波、带通滤波和峰值归一化的预处理方法。最后,基于 sEMG 信号模糊性强的特点,采用滑动窗口对其进行读取并提取了 MAV、WL、ZC 和 SSC 四个时域肌电特征。

(2) 基于多源信号融合的膝关节角度预测

本文将 sEMG 信号的肌电特征和髌关节角度融合并以时间序列的形式输入到 CNN、RNN 和 LSTM 回归模型中。同时,基于三种回归模型,还比较了仅采用 sEMG 信号的肌电特征和仅采用髌关节角度进行膝关节连续预测的结果。通过 MAE、RMSE 和 R^2 分数三种回归模型性能评估指标对上述模型进行评估和比较。结果表明基于多源信号融合方法的 LSTM 模型具有最好的预测结果,仅采用 sEMG 信号的肌电特征预测时精度低且仅采用髌关节角度预测存在滞后。

(3) 基于复合步态识别算法的行走步态识别

针对 IMU 和 FSR 两种传感器在步态识别中的不足, 本文将基于足底压力信号的阈值法和基于足部加速度信号的连续小波变换相结合, 设计了一种复合步态识别方法并通过实验验证该算法的有效性和鲁棒性。实验结果表明, 该复合步态识别方法比传统的阈值法精度高, 且能识别异常步态和更多步态阶段。

(4) 下肢外骨骼机器人控制实验

本文将人体意图识别得到的膝关节角度作为控制输入对 Indego 下肢外骨骼机器人进行位置控制, 通过对比和分析受试者不穿戴外骨骼地面行走和穿戴外骨骼以不同速度行走的步态、膝关节角度和相关肌肉的肌电特征来说明本研究中人体意图识别方法在下肢外骨骼机器人控制中的可行性和外骨骼对人体的辅助效果。

本文以解决人机协调运动控制技术中人体运动意图和步态识别等关键问题为研究目标, 以行走运动中膝关节运动和步态为研究对象提出了多源信号融合的膝关节角度连续预测和复合步态识别方法并通过实验验证本文所提方法的可行性。

7.2 展望

本文以人体行走运动为研究案例, 探索了基于多源信号融合的膝关节角度连续预测和步态识别新方法, 在人体意图和步态识别方面的研究工作中取得了部分有意义的研究成果和新进展, 但受限于作者自身能力和实验条件, 将来可从以下方面继续展开:

在实验方法上, 本文采用常见的行走运动为研究对象, 且考虑到老年患者和残疾患者的下肢不便, 运动过程中未对受试者进行负重。但在实际生活中, 除了行走运动外, 还包括跑步、上下楼梯和上下台阶等模式, 且老年患者和残疾患者日常生活中也存在负重行走的情况。因此, 今后的研究中, 可以研究不同运动模式下人体运动意图和步态识别的问题, 且可以研究受试者负重情况下对人体运动意图和步态的影响。此外, 本研究中的受试者都是健康受试者, 为了验证算法适用性, 也需要对老年患者和残疾患者的进行进一步研究。

在识别算法中, 本文基于 Python 环境的 tensorflow 框架对 CNN、RNN 和 LSTM 算法模型进行搭建, 通过人工调整学习率进行训练, 得到的结果未经任何优化算法优化。与相关参考文献相比, 在此情况下获得了较好的效果也证明了多源信号融合方法的实用性。但是采用一些优化方法或许可以进一步提升模型性能, 如 L1 和 L2 正则化等, 同时也可以采用双向 LSTM 模型和自注意力机制等。

在外骨骼实验中，本文证明了所提出的意图识别用于外骨骼控制的可行性并对健康受试者的特定肌肉具有辅助效果。但是 PD 控制器是一种位置控制器，PD 控制时受试者不能根据自身需求对外骨骼进行实时调整，所以需要采用力控制器等更高级的控制算法提高受试者的参与度。

参 考 文 献

- [1] 黄匡时, 刘鸿雁. 中华人民共和国成立以来中国历史人口数据的比对分析—基于《世界人口展望》2017 年修订版的深度解读[J]. 人口与计划生育, 2017, (08): 15-18.
- [2] 张现苓, 明艳. 第七次全国人口普查年龄数据准确性分析[J]. 人口研究, 2022, 46(04): 27-39.
- [3] 赖泽飞, 黄岚, 樊萍. 重复经颅磁刺激联用语言康复训练治疗脑卒中后言语功能障碍患者的临床观察[J]. 当代医学, 2022, 28(07): 42-44.
- [4] 许胡梅. 个体化早期康复锻炼对脑卒中偏瘫患者运动能力、生活活动能力及生活质量的影响[J]. 临床护理杂志, 2017, 16(01): 17-19.
- [5] LYNNE M W. The use of robots in stroke rehabilitation: a narrative review[J]. NeuroRehabilitation, 2018, 43(1): 99-110.
- [6] KITAGO T, KRAKAUER J W. Motor learning principles for neurorehabilitation[J]. Handbook of Clinical Neurology, 2013, 110(8): 93-103.
- [7] LOUIE D R, ENG J J. Powered robotic exoskeletons in post-stroke rehabilitation of gait: a scoping review[J]. Journal of Neuroengineering & Rehabilitation, 2016, 13(1): 1-10.
- [8] 谢陈磊. 基于肌音信号的人体膝关节运动加速度估计研究[D]. 合肥: 中国科学技术大学, 2021: 3-15.
- [9] GROSU V, GROSU S, VANDERBORGHT B, et al. Multi-axis force sensor for human-robot interaction sensing in a rehabilitation robotic device[J]. Sensors, 2017, 17(6): 1294-1307.
- [10] DUAN L-T, LAWO M, WANG Z-G, et al. Human lower limb motion capture and recognition based on smartphones [J]. Sensors, 2022, 22(14): 5273-5289.
- [11] MAGGIONI S, REINERT N, LÜNNENBURGER L, et al. An adaptive and hybrid end-point/joint impedance controller for lower limb exoskeletons[J]. Frontiers in Robotics and AI, 2018, 5(104): 1-17.
- [12] NAM K Y, KIM H J, KWON B S, et al. Robot-assisted gait training (Lokomat) improves walking function and activity in people with spinal cord injury: a systematic review[J]. Journal of neuroengineering and rehabilitation, 2017, 14(1): 1-13.
- [13] SIVIY C, BAKER L M, QUINLIVAN B T, et al. Opportunities and challenges in the development of exoskeletons for locomotor assistance[J]. Nature Biomedical Engineering, 2022, 7(2023): 456-472.

- [14] SHI D, ZHANG W, ZHANG W, et al. A review on lower limb rehabilitation exoskeleton robots[J]. Chinese Journal of Mechanical Engineering, 2019, 32(1): 1-11.
- [15] BAUD R, MANZOORI A R, IJSPEERT A, et al. Review of control strategies for lower-limb exoskeletons to assist gait[J]. Journal of NeuroEngineering and Rehabilitation, 2021, 18(1): 1-34.
- [16] SWIFT T A, STRAUSSER K A, ZOSS A B, et al. Control and experimental results for post stroke gait rehabilitation with a prototype mobile medical exoskeleton[C]. Proceedings of the Dynamic Systems and Control Conference, Cambridge, Massachusetts, USA, 2010: 405-411.
- [17] XIONG Y, SHE H, LU H, et al. State of the art: bipedal robots for lower limb rehabilitation[J]. Applied Sciences, 2017, 7(11): 1182-1200.
- [18] 孙建, 余永, 葛运建, 等. 基于接触力信息的可穿戴型下肢助力机器人传感系统研究[J]. 中国科学技术大学学报, 2008, 38(12): 1432-1438.
- [19] 徐菲. 用于检测三维力的柔性触觉传感器结构及解耦方法研究[D]. 合肥: 中国科学技术大学, 2011: 35-53.
- [20] 靳兴来. 液压驱动下肢外骨骼机器人摆动相控制系统研究[D]. 杭州: 浙江大学, 2017: 75-85.
- [21] 陈朝峰. 穿戴式下肢外骨骼系统设计与交互控制策略研究[D]. 哈尔滨: 哈尔滨工业大学, 2020: 46-71.
- [22] DONG L, CHEN W, RICARDO C, et al. Decoding of self-paced lower-limb movement intention: a case study on the influence factors[J]. Frontiers in Human Neuroscience, 2017, 11(560): 1-12.
- [23] SALAHUDDIN U, GAO P-X. Signal generation, acquisition, and processing in brain machine interfaces: a unified review[J]. Frontiers in Neuroscience, 2021, 1174(12): 1-21.
- [24] FLESHER S N, DOWNEY J E, WEISS J M, et al. A brain-computer interface that evokes tactile sensations improves robotic arm control[J]. Science, 2021, 372(6544): 831-836.
- [25] ARPAIA P, DURACCIO L, MOCCALDI N, et al. Wearable brain-computer interface instrumentation for robot-based rehabilitation by augmented reality[J]. IEEE Transactions on instrumentation and measurement, 2020, 69(9): 6362-6371.
- [26] GUI K, REN Y, ZHANG D. Online brain-computer interface controlling robotic exoskeleton for gait rehabilitation[C]. Proceedings of the 2015 IEEE International Conference on Rehabilitation Robotics (ICORR), Singapore, 2015: 931-936.
- [27] 刘志辉. 外骨骼上肢运动功能康复系统的人因工程研究[D]. 上海: 东华大学, 2017: 77-88.

- [28] 王海莲. 人体下肢运动意图的脑肌多源感知方法研究[D]. 西安: 西北工业大学, 2018: 27-44.
- [29] IFTIKHAR M, KHAN S A, HASSAN A. A survey of deep learning and traditional approaches for EEG signal processing and classification[C]. Proceedings of the 2018 IEEE 9th Annual Information Technology, Electronics and Mobile Communication Conference (IEMCON), Vancouver, BC, Canada, 2018: 395-400.
- [30] WEI J, MENG Q, BADI A. Classification of human hand movements using surface EMG for myoelectric control[M]. Advances in Computational Intelligence Systems. Springer. 2017: 331-339.
- [31] HAN M, ZANDIGO HAR M, GÜNAY S Y, et al. Inference of upcoming human grasp using EMG during reach-to-grasp movement[J]. Frontiers in Neuroscience, 2022, 16: 1-14.
- [32] GOEN A, TIWARI D. Review of surface electromyogram signals: its analysis and applications[J]. International Journal of Electrical and Computer Engineering, 2013, 7(11): 1429-1437.
- [33] ZI-YOU L, XIN-GANG Z, BI Z, et al. Review of sEMG-based motion intent recognition methods in non-ideal conditions[J]. Acta Automatica Sinica, 2021, 47(5): 955-969.
- [34] XIONG D, ZHANG D, ZHAO X, et al. Deep learning for EMG-based human-machine interaction: a review [J]. IEEE/CAA Journal of Automatica Sinica, 2021, 8(3): 512-533.
- [35] WANG Y, VERHEUL J, YEO S-H, et al. Differentiable simulation of inertial musculotendons[J]. ACM Transactions on Graphics (TOG), 2022, 41(6): 1-11.
- [36] ZHAO J, YU Y, WANG X, et al. A musculoskeletal model driven by muscle synergy-derived excitations for hand and wrist movements[J]. Journal of Neural Engineering, 2022, 19(1): 016027.
- [37] ZHANG Q, FRAGNITO N, FRANZ J R, et al. Fused ultrasound and electromyography-driven neuromuscular model to improve plantarflexion moment prediction across walking speeds[J]. Journal of NeuroEngineering and Rehabilitation, 2022, 19(1): 86-106.
- [38] ZHANG Q, KIM K, SHARMA N. Prediction of ankle dorsiflexion moment by combined ultrasound sonography and electromyography[J]. IEEE Transactions on Neural Systems and Rehabilitation Engineering, 2019, 28(1): 318-327.
- [39] KARAVAS N, AJODANI A, TSAGARAKIS N, et al. Tele-impedance based assistive control for a compliant knee exoskeleton[J]. Robotics & Autonomous Systems, 2015, 73: 78-90.

- [40] DURANDAU G, SARTORI M, BORTOLE M, et al. EMG-driven models of human-machine interaction in individuals wearing the H2 exoskeleton[J]. IFAC-PapersOnLine, 2016, 49(32): 200-203.
- [41] LIU H, TAO J, LYU P, et al. Human-robot cooperative control based on sEMG for the upper limb exoskeleton robot[J]. Robotics and Autonomous Systems, 2020, 125: 1-35.
- [42] RAJ R, REJITH R, SIVANANDAN K. Real time identification of human forearm kinematics from surface EMG signal using artificial neural network models[J]. Procedia Technology, 2016, 25: 44-51.
- [43] ZHANG F, LI P, HOU Z-G, et al. sEMG-based continuous estimation of joint angles of human legs by using BP neural network [J]. Neurocomputing, 2012, 78(1): 139-148.
- [44] 王卫星. 面向运动意图识别的上肢外骨骼生物电信号控制研究[D]. 杭州: 浙江大学, 2017: 30-48.
- [45] 李国欣. 面向人机混合智能的上肢穿戴机器人系统设计与协同控制技术研究[D]. 合肥: 中国科学技术大学, 2022: 34-57.
- [46] KAWABATA T, SATOH H, SANKAI Y. Working posture control of robot suit HAL for reducing structural stress[C]. Proceedings of the International Conference on Robotics & Biomimetics, Guilin, China, 2009: 2013-2018.
- [47] TAKETOMI T, SANKAI Y. Stair ascent assistance for cerebral palsy with robot suit HAL[C]. Proceedings of the IEEE/SICE International Symposium on System Integration, Fukuoka, Japan, 2012: 331-336.
- [48] 刘笃信. 下肢外骨骼机器人多模融合控制策略研究[D]. 深圳: 中国科学院大学(中国科学院深圳先进技术研究院), 2018: 45-58.
- [49] MURO-DE-LA-HERRAN A, GARCÍA-ZAPIRAIN B, MÉNDEZ-ZORRILLA A. Gait analysis methods: an overview of wearable and non-wearable systems, highlighting clinical applications[J]. Sensors, 2014, 14(2): 3362-3394.
- [50] ANSAH S, CHEN D. Wearable-gait-analysis-based activity recognition: a review[J]. International Journal on Smart Sensing and Intelligent Systems, 2022, 15(1): 1-14.
- [51] TABORRI J, PALERMO E, ROSSI S, et al. Gait partitioning methods: a systematic review[J]. Sensors, 2016, 16(1): 66-86.
- [52] TARNIȚĂ D. Wearable sensors used for human gait analysis[J]. Rom J Morphol Embryol, 2016, 57(2): 373-382.

- [53] DE MARSICO M, MECCA A. Gait recognition: the wearable solution[M]. Human Recognition in Unconstrained Environments, 2017: 177-195.
- [54] MACLEOD C A, CONWAY B A, ALLAN D B, et al. Development and validation of a low-cost, portable and wireless gait assessment tool[J]. Medical engineering & physics, 2014, 36(4): 541-546.
- [55] YU F, ZHENG J, YU L, et al. Adjustable method for real-time gait pattern detection based on ground reaction forces using force sensitive resistors and statistical analysis of constant false alarm rate[J]. Sensors, 2018, 18(11): 3764-3778.
- [56] ZHANG Q, WANG Y L, XIA Y, et al. A low-cost and highly integrated sensing insole for plantar pressure measurement[J]. Sensing and Bio-Sensing Research, 2019, 26: 1-8.
- [57] OMID D, MOJTABA T, RAGHVENDAR C V. IMU-based gait recognition using convolutional neural networks and multi-sensor fusion[J]. Sensors, 2017, 17(12): 2735-2757.
- [58] HUO W, MOHAMMED S, AMIRAT Y, et al. Fast gait mode detection and assistive torque control of an exoskeletal robotic orthosis for walking assistance[J]. IEEE Transactions on Robotics, 2018, PP(4): 1-18.
- [59] JUNG D, NGUYEN M, HAN J, et al. Deep neural network-based gait classification using wearable inertial sensor data[C]. Proceedings of the Annu Int Conf IEEE Eng Med Biol Soc, Berlin, Germany, 2019: 3624-3628.
- [60] WEI P, ZHANG J, WANG B, et al. Surface electromyography and electroencephalogram-based gait phase recognition and correlations between cortical and locomotor muscle in the seven gait phases[J]. Frontiers in Neuroscience, 2021, 15: 1-12.
- [61] WEI P, ZHANG J, TIAN F, et al. A comparison of neural networks algorithms for EEG and sEMG features based gait phases recognition[J]. Biomedical Signal Processing and Control, 2021, 68: 1-9.
- [62] YAO T, GAO F, ZHANG Q, et al. Multi-feature gait recognition with DNN based on sEMG signals[J]. Math Biosci Eng, 2021, 18(4): 3521-3542.
- [63] 何从军. 正常人体结构 [M]. 正常人体结构, 2005: 15-22.
- [64] 朱文玉. 人体解剖生理学[M]. 人体解剖生理学, 2002: 59-88.
- [65] 路新亮. 液压驱动下肢外骨骼控制技术研究[D]. 南京: 东南大学, 2016: 27-38.
- [66] 伊蕾. 助行康复机器人控制策略研究[D]. 哈尔滨: 哈尔滨工程大学, 2012: 23-24.
- [67] 单大卯. 人体下肢肌肉功能模型及其应用的研究[D]. 上海: 上海体育学院, 2003: 1-3.

- [68] 唐刚. 人体典型运动生物力学仿真分析[D]. 上海: 上海交通大学, 2011: 1-7.
- [69] 冯治国. 步行康复训练助行腿机器人系统[D]. 上海: 上海大学, 2009: 16-17.
- [70] 刘富强. 行走辅助训练机器人研究[D]. 哈尔滨: 哈尔滨工程大学, 2012: 17-19.
- [71] DI GREGORIO R, VOCENAS L. Identification of gait-cycle phases for prosthesis control[J]. *Biomimetics*, 2021, 6(2): 22-38.
- [72] STRZALKOWSKI N D, PETERS R M, INGLIS J T, et al. Cutaneous afferent innervation of the human foot sole: what can we learn from single-unit recordings?[J]. *Journal of neurophysiology*, 2018, 120(3): 1233-1246.
- [73] 秦涛. 踏板式步行训练机器人研究[D]. 哈尔滨: 哈尔滨工程大学, 2015: 19-23.
- [74] 白大鹏. 多功能助行机器人机构研究[D]. 哈尔滨: 哈尔滨工程大学, 2013: 21-23.
- [75] EDWARDS D J, FORREST G, CORTES M, et al. Walking improvement in chronic incomplete spinal cord injury with exoskeleton robotic training (WISE): a randomized controlled trial[J]. *Spinal Cord*, 2022, 60(6): 522-532.
- [76] GRIMMER M, SEYFARTH A. Mimicking human-like leg function in prosthetic limbs[J]. *Neuro-robotics: from brain machine interfaces to rehabilitation robotics*, 2014, 2(5): 105-155.
- [77] 陈冲. 下肢康复外骨骼机器人研究[D]. 北京: 中国石油大学(北京), 2020: 40-66.
- [78] THOMAS M J, SANJEEV M M, SUDHEER A, et al. Comparative study of various machine learning algorithms and Denavit–Hartenberg approach for the inverse kinematic solutions in a 3-PP SS parallel manipulator[J]. *Industrial Robot: the international journal of robotics research and application*, 2020, 47(5): 683-695.
- [79] 范渊杰. 基于 sEMG 与交互力等多源信号融合的下肢外骨骼康复机器人及其临床实验研究[D]. 上海: 上海交通大学, 2014: 81-83.
- [80] 范伯骞. 液压驱动下肢外骨骼机器人关键技术研究[D]. 杭州: 浙江大学, 2017: 32-38.
- [81] 李军. 偏瘫外骨骼步态策略与规划研究[D]. 上海: 上海大学, 2017: 76-84.
- [82] 张国安. 主被动结合式全身外骨骼助力机器人研究[D]. 哈尔滨: 哈尔滨工业大学, 2018: 17-18.
- [83] 陈峰. 可穿戴型助力机器人技术研究[D]. 合肥: 中国科学技术大学, 2007: 50-55.
- [84] 方郁. 可穿戴下肢助力机器人动力学建模及其控制研究[D]. 合肥: 中国科学技术大学, 2009: 18-28.

- [85] XU D, WU Q, ZHU Y. Development of a sEMG-based joint torque estimation strategy using Hill-type muscle model and neural network[J]. Journal of Medical and Biological Engineering, 2021, 41: 34-44.
- [86] HAN J, DING Q, XIONG A, et al. A state-space EMG model for the estimation of continuous joint movements[J]. IEEE Transactions on Industrial Electronics, 2015, 62(7): 4267-4275.
- [87] LI Q, SONG Y, HOU Z. Estimation of lower limb periodic motions from sEMG using least squares support vector regression[J]. Neural Processing Letters, 2015, 41: 371-388.
- [88] LI Z, GUAN X, ZOU K, et al. Estimation of knee movement from surface EMG using random forest with principal component analysis[J]. Electronics, 2019, 9(1): 43-56.
- [89] XIAO F, WANG Y, GAO Y, et al. Continuous estimation of joint angle from electromyography using multiple time-delayed features and random forests[J]. Biomedical Signal Processing and Control, 2018, 39: 303-311.
- [90] WANG C, GUO W, ZHANG H, et al. sEMG-based continuous estimation of grasp movements by long-short term memory network[J]. Biomedical Signal Processing and Control, 2020, 59: 1-14.
- [91] SUTSKEVER I, VINYALS O, LE Q V. Sequence to sequence learning with neural networks[J]. Advances in neural information processing systems, 2014, 27: 1-9.
- [92] CARPENTER W B. Principles of human physiology[M]. Blanchard and Lea, 1860: 216-238.
- [93] SÖRNMO L, LAGUNA P. Bioelectrical signal processing in cardiac and neurological applications[M]. Academic press, 2005: 71-75.
- [94] TERAMAE T, NODA T, MORIMOTO J. EMG-based model predictive control for physical human-robot interaction: application for assist-as-needed control[J]. IEEE Robotics and Automation Letters, 2017, 3(1): 210-217.
- [95] CHEN Y, YU S, MA K, et al. A continuous estimation model of upper limb joint angles by using surface electromyography and deep learning method[J]. IEEE Access, 2019, 7: 174940-174950.
- [96] 李怀仙. 助力外骨骼人机交互关键技术研究[D]. 成都: 西南交通大学, 2019: 67-81.
- [97] 李庆玲. 基于 sEMG 信号的外骨骼式机器人上肢康复系统研究[D]. 哈尔滨: 哈尔滨工业大学, 2009: 44-46.
- [98] CHALARD A, BELLE M, MONTANÉ E, et al. Impact of the EMG normalization method on muscle activation and the antagonist-agonist co-contraction index during active elbow extension:

- practical implications for post-stroke subjects[J]. Journal of Electromyography and Kinesiology, 2020, 51: 1-7.
- [99] PAPAGIANNIS G I, TRIANTAFYLLOU A I, ROUMPELAKIS I M, et al. Methodology of surface electromyography in gait analysis: review of the literature[J]. Journal of medical engineering & technology, 2019, 43(1): 59-65.
- [100] BURDEN A, TREW M, BALZPOULOS V. Normalisation of gait sEMG: a re-examination[J]. Journal of Electromyography and Kinesiology, 2003, 13(6): 519-532.
- [101] ARDESTANI M M, ZHANG X, WANG L, et al. Human lower extremity joint moment prediction: a wavelet neural network approach[J]. Expert Systems with Applications, 2014, 41(9): 4422-4433.
- [102] DING Z, YANG C, TIAN Z, et al. sEMG-based gesture recognition with convolution neural networks[J]. Sustainability, 2018, 10(6): 1865-1877.
- [103] ZHENG K, LIU S, YANG J, et al. sEMG-based continuous hand action prediction by using key state transition and model pruning[J]. Sensors, 2022, 22(24): 9949-9961.
- [104] MA C, LIN C, SAMUEL O W, et al. Continuous estimation of upper limb joint angle from sEMG signals based on SCA-LSTM deep learning approach[J]. Biomedical Signal Processing and Control, 2020, 61: 1-13.
- [105] WARIS A, KAMAVUAKO E N. Effect of threshold values on the combination of EMG time domain features: surface versus intramuscular EMG[J]. Biomedical Signal Processing and Control, 2018, 45: 267-273.
- [106] TKACH D, HUANG H, KUIKEN T A. Study of stability of time-domain features for electromyographic pattern recognition[J]. Journal of neuroengineering and rehabilitation, 2010, 7(1): 1-13.
- [107] ABBASPOUR S, LINDÉN M, GHOLAMHOSSEINI H, et al. Evaluation of surface EMG-based recognition algorithms for decoding hand movements[J]. Medical & biological engineering & computing, 2020, 58: 83-100.
- [108] WANG Q, WANG M, YANG Y, et al. Multi-modal emotion recognition using EEG and speech signals[J]. Computers in Biology and Medicine, 2022, 149: 1-13.
- [109] NASTOS V, ARJMAND A, TSAKAI K, et al. Human activity recognition using machine learning techniques[C]. Proceedings of the 2022 7th South-East Europe Design Automation,

- Computer Engineering, Computer Networks and Social Media Conference (SEEDA-CECNSM), Ioannina, Greece, 2022: 1-5.
- [110] SALEHZADEH A, CALITZ A P, GREYLING J. Human activity recognition using deep electroencephalography learning[J]. Biomedical Signal Processing and Control, 2020, 62: 1-11.
- [111] KUMARI P, MATHEW L, SYAL P. Increasing trend of wearables and multimodal interface for human activity monitoring: a review[J]. Biosensors and Bioelectronics, 2017, 90: 298-307.
- [112] 丁其川, 赵新刚, 韩建达. 基于肌电信号的上肢多关节连续运动估计[J]. 机器人, 2014, 36(04): 469-476.
- [113] KARIMI M, WU D, WANG Z, et al. Interpretable deep learning of compound-protein affinity through unified recurrent and convolutional neural networks[J]. Bioinformatics, 2019, 35(18): 3329-3338.
- [114] DING Z, YANG C, WANG Z, et al. Online adaptive prediction of human motion intention based on sEMG[J]. Sensors, 2021, 21(8): 2882-2901.
- [115] XIA P, HU J, PENG Y. EMG-based estimation of limb movement using deep learning with recurrent convolutional neural networks[J]. Artificial organs, 2018, 42(5): 67-77.
- [116] YI C, JIANG F, ZHANG S, et al. Continuous prediction of lower-limb kinematics from multi-modal biomedical signals[J]. IEEE Transactions on Circuits and Systems for Video Technology, 2021, 32(5): 2592-2602.
- [117] WEI B, DING Z, YI C, et al. A novel sEMG-based gait phase-kinematics-coupled predictor and its interaction with exoskeletons[J]. Frontiers in Neurorobotics, 2021, 15: 1-14.
- [118] HUBEL D H, WIESEL T N. Receptive fields, binocular interaction and functional architecture in the cat's visual cortex[J]. The Journal of physiology, 1962, 160(1): 106-157.
- [119] 苏锦程. 基于学习的红外云图超分辨率重建算法研究[D]. 上海: 中国科学院大学(中国科学院上海技术物理研究所), 2018: 44-49.
- [120] FUKUSHIMA K, MIYAKE S. Neocognitron: A new algorithm for pattern recognition tolerant of deformations and shifts in position[J]. Pattern recognition, 1982, 15(6): 455-469.
- [121] WERBOS P J. Backpropagation through time: what it does and how to do it[J]. Proceedings of the IEEE, 1990, 78(10): 1550-1560.
- [122] LE CUN Y, BOTTOU L, BENGIO Y. Reading checks with multilayer graph transformer networks[C]. Proceedings of the 1997 IEEE International Conference on Acoustics, Speech, and Signal Processing, Munich, Germany, 1997: 151-154.

- [123] HINTON G E, SALAKHUTDINOV R R. Reducing the dimensionality of data with neural networks[J]. Science, 2006, 313(5786): 504-507.
- [124] 陈星如. 基于编码损伤修复与超分辨率的视频空间可伸缩编码算法研究[D]. 西安: 西安电子科技大学, 2021: 6-7.
- [125] 代菊. 基于语义投影学习和深度特征学习的行人重识别算法研究[D]. 大连: 大连理工大学, 2020: 22-25.
- [126] 郑骁. 基于脑电信号的视觉信息解码与视觉场景重建[D]. 长春: 吉林大学, 2022: 14-21.
- [127] 马帅. 基于卷积神经网络的立体视频质量评价方法研究[D]. 天津: 天津大学, 2019: 16-22.
- [128] DILEEP P, DAS D, BORA P K. Dense layer dropout based CNN architecture for automatic modulation classification[C]. Proceedings of the 2020 national conference on communications (NCC), Kharagpur, India, 2020: 1-5.
- [129] 胡超. 基于深度神经网络的高性能人脸特征提取器设计[D]. 南京: 东南大学, 2021: 3-7.
- [130] HOCHREITER S, SCHMIDHUBER J. Long short-term memory[J]. Neural computation, 1997, 9(8): 1735-1780.
- [131] 许峰. 基于深度学习的网络舆情识别研究[D]. 北京: 北京邮电大学, 2019: 40-41.
- [132] 苗岩. 基于深度学习的宏基因组病毒序列识别及其毒性预测方法研究[D]. 长春: 吉林大学, 2022: 24-28.
- [133] YU Y, SI X, HU C, et al. A review of recurrent neural networks: LSTM cells and network architectures[J]. Neural computation, 2019, 31(7): 1235-1270.
- [134] SUN Y, XU C, LI G, et al. Intelligent human computer interaction based on non redundant EMG signal[J]. Alexandria Engineering Journal, 2020, 59(3): 1149-1157.
- [135] JAYALAKSHMI T, SANTHAKUMARAN A. Statistical normalization and back propagation for classification[J]. International Journal of Computer Theory and Engineering, 2011, 3(1): 1793-8201.
- [136] VABALAS A, GOWEN E, POLIAKOFF E, et al. Machine learning algorithm validation with a limited sample size[J]. PloS one, 2019, 14(11): 1-20.
- [137] MEYER A J, PATTEN C, FREGLY B J. Lower extremity EMG-driven modeling of walking with automated adjustment of musculoskeletal geometry[J]. PloS one, 2017, 12(7): 1-24.

- [138] MA F, SONG F, LIU Y, et al. sEMG-based neural network prediction model selection of gesture fatigue and dataset optimization[J]. Computational Intelligence and Neuroscience, 2020, 2020(1): 1-17.
- [139] GARCÍA-VELLISCA M, MATRAN-FERNANDEZ A, POLI R, et al. Hand-movement prediction from EMG with LSTM-recurrent neural networks[C]. Proceedings of the 2021 Global Medical Engineering Physics Exchanges/Pan American Health Care Exchanges (GMEPE/PAHCE), Sevilla, Spain, 2021: 1-5.
- [140] YANG C, XI X, CHEN S, et al. sEMG-based multifeatures and predictive model for knee-joint-angle estimation[J]. Aip Advances, 2019, 9: 1-10.
- [141] MA X, LIU Y, SONG Q, et al. Continuous estimation of knee joint angle based on surface electromyography using a long short-term memory neural network and time-advanced feature[J]. Sensors, 2020, 20(17): 4966-4984.
- [142] LU Y, WANG H, ZHOU B, et al. Continuous and simultaneous estimation of lower limb multi-joint angles from sEMG signals based on stacked convolutional and LSTM models[J]. Expert Systems with Applications, 2022, 203: 1-20.
- [143] MOGHADAM S M, YEUNG T, CHOISNE J. A comparison of machine learning models' accuracy in predicting lower-limb joints' kinematics, kinetics, and muscle forces from wearable sensors[J]. Scientific Reports, 2023, 13(1): 5046-5062.
- [144] 吴海峰. 基于肌音和 CNN-SVM 模型的人体膝关节运动意图识别研究[D]. 合肥: 中国科学技术大学, 2018: 63-66.
- [145] SENANAYAKE C M, SENANAYAKE S M N A. Computational intelligent gait-phase detection system to identify pathological gait[J]. IEEE Transactions on Information Technology in Biomedicine A Publication of the IEEE Engineering in Medicine & Biology Society, 2010, 14(5): 1173-1179.
- [146] NOVAK D, REBERŠEK P, DE ROSSI S M M, et al. Automated detection of gait initiation and termination using wearable sensors[J]. Medical engineering & physics, 2013, 35(12): 1713-1720.
- [147] PRASANTH H, CABAN M, KELLER U, et al. Wearable sensor-based real-time gait detection: a systematic review[J]. Sensors, 2021, 21(8): 2727-2755.
- [148] MARIANI B, ROUHANI H, CREVOISIER X, et al. Quantitative estimation of foot-flat and stance phase of gait using foot-worn inertial sensors[J]. Gait & Posture, 2013, 37(2): 229-234.

- [149] LOPEZ-MEYER P, FULK G D, SAZONOV E S. Automatic detection of temporal gait parameters in poststroke individuals[J]. IEEE Transactions on Information Technology in Biomedicine, 2011, 15(4): 594-601.
- [150] GROSSMANN A, MORLET J. Decomposition of hardy functions into square integrable wavelets of constant shape[J]. SIAM journal on mathematical analysis, 1984, 15(4): 723-736.
- [151] MALLAT S G. Multiresolution approximations and wavelet orthonormal bases of $L^2(R)$ [J]. Transactions of the American mathematical society, 1989, 315(1): 69-87.
- [152] STASZEWSKI W, TOMLINSON G. Application of the wavelet transform to fault detection in a spur gear[J]. Mechanical Systems and Signal Processing, 1994, 8(3): 289-307.
- [153] RUZZENE M, FASANA A, GARIBALDI L, et al. Natural frequencies and dampings identification using wavelet transform: application to real data[J]. Mechanical systems and signal processing, 1997, 11(2): 207-218.
- [154] 郭盛. 基于卷积神经网络的旋转机械变工况故障诊断方法研究[D]. 武汉: 华中科技大学, 2019: 39-44.
- [155] CARAMIA C, DE MARCHIS C, SCHMID M. Optimizing the scale of a wavelet-based method for the detection of gait events from a waist-mounted accelerometer under different walking speeds[J]. Sensors, 2019, 19(8): 1869-1879.
- [156] REZVANIAN S, LOCKHART T E. Towards real-time detection of freezing of gait using wavelet transform on wireless accelerometer data[J]. Sensors, 2016, 16(4): 475-486.
- [157] MAZIDI M H, ESHGHI M. Detection of heart attack using cross wavelet transformation and support vector machine[J]. Applied Medical Informatics, 2019, 41(3): 77-92.
- [158] SMITH B T, COIRO D J, FINSON R, et al. Evaluation of force-sensing resistors for gait event detection to trigger electrical stimulation to improve walking in the child with cerebral palsy[J]. IEEE Transactions on Neural Systems and Rehabilitation Engineering, 2002, 10(1): 22-29.
- [159] BEHBOODI A, ZAHRADKA N, WRIGHT H, et al. Real-time detection of seven phases of gait in children with cerebral palsy using two gyroscopes[J]. Sensors, 2019, 19(11): 2517-2533.
- [160] LI K, BOONTO S, NUCHKRUA T. On-line self tuning of contouring control for high accuracy robot manipulators under various operations[J]. International Journal of Control, Automation and Systems, 2020, 18(7): 1818-1828.

- [161] PERRUSQUIA A, FLORES-CAMPOS J A, TORRES-SAN-MIGUEL C R. A novel tuning method of PD with gravity compensation controller for robot manipulators[J]. IEEE Access, 2020, 8: 114773-114783.
- [162] ZHANG R, LIU Y. A new Barbalat's lemma and Lyapunov stability theorem for fractional order systems[C]. Proceedings of the 2017 29th Chinese control and decision conference (CCDC), Chongqing, China, 2017: 3676-3681.
- [163] TEFERTILLER C, HAYS K, JONES J, et al. Initial outcomes from a multicenter study utilizing the indego powered exoskeleton in spinal cord injury[J]. Topics in spinal cord injury rehabilitation, 2018, 24(1): 78-85.
- [164] EKELEM A. Control methods for improving mobility for persons with lower limb paralysis [M]. Vanderbilt University, 2018: 18-21.
- [165] PARK J, PARK H, KIM J. Performance estimation of the lower limb exoskeleton for plantarflexion using surface electromyography (sEMG) signals[J]. Journal of Biomechanical Science and Engineering, 2017, 12(2): 1-9.
- [166] ZHANG X, CHEN X, HUO B, et al. An integrated evaluation approach of wearable lower limb exoskeletons for human performance augmentation[J]. Scientific Reports, 2023, 13(1): 4251-4264.
- [167] TREUSSART B, GEFFARD F, VIGNAIS N, et al. Controlling an upper-limb exoskeleton by EMG signal while carrying unknown load[C]. Proceedings of the 2020 IEEE International Conference on Robotics and Automation (ICRA), Paris, France, 2020: 9107-9113.
- [168] SPIEWAK C, ISLAM M, ZAMAN A, et al. A comprehensive study on EMG feature extraction and classifiers[J]. Open Access Journal of Biomedical Engineering and Biosciences, 2018, 1(1): 1-10.
- [169] WANG M, WANG X A, PENG C, et al. Research on EMG segmentation algorithm and walking analysis based on signal envelope and integral electrical signal[J]. Photonic network communications, 2019, 37: 195-203.
- [170] MARCHETTI P H, MIYATAKE M M, MAGALHAES R A, et al. Different volumes and intensities of static stretching affect the range of motion and muscle force output in well-trained subjects[J]. Sports biomechanics, 2022, 21(2): 155-164.

- [171] LV Y, ZHENG Q, CHEN X, et al. Analysis on muscle forces of extrinsic finger flexors and extensors in flexor movements with sEMG and ultrasound[J]. Mathematical Problems in Engineering, 2022, 2022: 1-10.

学位论文数据集

论文题目	行走过程中人体膝关节角度连续预测与步态识别			论文语种	中文
论文英文题目	Continuous prediction of knee joint angle and gait recognition during human walking				
关键词	膝关节角度预测；特征提取；多源信号融合；膝关节角度预测；步态识别			密级	公开
中图分类号	TP242		UDC	621	
作者姓名	刘显文	学号	2017314006	学制	4 年
学科专业	机械工程		研究方向	机器人技术	
答辩日期	2023. 5. 24	授予学位年	2023	学位类别	博士
学位授予单位	中国石油大学（北京）		学位授予单位代码		11414
导师姓名	张仕民		导师职称	教授	
论文评阅人	姓名		工作单位		
论文答辩委员会	姓名		工作单位		
	主席	唐晓强	清华大学		
	成员	申瑞臣	中国石油集团工程技术研究院有限公司煤层气与储库工程研究所		
		王启明	中国科学院国家天文台		
		刘书海	中国石油大学（北京）		
		朱霄霄	中国石油大学（北京）		

注：所有项均必须如实填写。